

STUDIERENDENMITSCHRIFT ZUR
VORLESUNG: EINFÜHRUNG IN DIE
INFERENZSTATISTIK (SoSe 2022)

ORIGINAL SoSe21 HERGESTELLT VON: JIM FELLER
AKTUALISIERUNG SoSe22: JELENA POPADIC

The template is based on a free template from Typesetters.
The Book icon is a free icon from Icons8.

GNU General Public License v3.0

Inhaltsverzeichnis

1	Parametrische Modelle	5
1.1	Parametrische Modelle und Parameterschätzung	7
1.2	Die Momenten-Methode (MM)	9
1.3	Die Maximum-Likelihood Methode (ML)	21
1.4	Zulässigkeit, Effizienz und die Cramér-Rao-Schranke	31
1.5	Das Verhalten von ML-Schätzer in großen Stichproben	42
2	Testen von Hypothesen	47
2.1	Neyman-Pearson Paradigma	47
2.2	Likelihood-Ratio-Tests und das Neyman-Pearson Lemma	55
2.3	L-R-Tests in großen Stichproben	62
3	Zufallsvektoren und Zufallsmatrizen	66
3.1	Erwartungswerte und Varianz/Kovarianz-Matrizen	66
3.2	Die Multivariate Normalverteilung	75
3.3	Der Multivariate Zentrale Grenzwertsatz	84
3.4	Normalverteilungen - stetig und singular (degeneriert)	84
	Index	87

1. Parametrische Modelle

Siehe für eine Einführung zu diesem Kapitel S. 255-260 in *Rice (2007)*.



Beispiel 1.1 (Ein Modell für den radioaktiven Zerfall) Atome eines Elements zerfallen unabhängig voneinander in scheinbar zufälliger Reihenfolge. Im Moment des Zerfalls wird ein α -Teilchen abgegeben. Im Experiment beobachtet man eine enorm große Zahl von Atomen über eine gewisse Zeitspanne. Dabei wird die (relativ kleine) Zahl der α -Teilchen beobachtet.

S_{n_0} = # α -Teilchen pro Zeitintervall

Modell 1

$$S_{n_0} \sim B(n_0, p_0)$$

← unpraktisch zum Rechnen (n_0 unbekannt)

Atome (enorm) Zerfallswkeit (extrem klein)

Modell 2

$$\sqrt{n_0} \left(\frac{1}{n_0} S_{n_0} - p_0 \right) \xrightarrow{w} N(0, p_0(1 - p_0)) \quad \leftarrow \text{unsinnig.}$$

$n_0 \rightarrow \infty$
 p_0 fest

$$\mathbb{E}(S_{n_0}) = n_0 p_0 \rightarrow \infty$$

← passt nicht zu der Tatsache, dass im Experiment eine relativ kleine Anzahl von α -Teilchen, also ein relativ kleiner Wert von S_{n_0} , beobachtet wird.

Modell 3

$$S_{n_0} \sim P(\underbrace{\lambda_0}_{n_0 p_0})$$

← praktikabel und sinnvoll

sehr groß sehr klein,
sodass λ_0 moderat

Begründung: Gesetz der kleinen Zahlen

Damit lässt sich Modell 1 durch Modell 3 approximieren

Sei $X \sim B(n, p)$. Dann gilt für jedes $k \in \mathbb{N}_0$:

$$\mathbb{P}(X = k) \xrightarrow{n \rightarrow \infty, np = \lambda \text{ fest}} \frac{\lambda^k}{k!} e^{-\lambda}.$$

Nachrechnen.

$$\begin{aligned}
 \mathbb{P}(X = k) &= \binom{n}{k} p^k (1-p)^{n-k} \\
 &= \frac{\overbrace{n(n-1) \cdot \dots \cdot (n-k+1)}^{k \text{ Faktoren}}}{k!} \overset{k \text{ Faktoren}}{\downarrow} p^k (1-p)^{n-k} \\
 &= \frac{np(n-1)p \cdot \dots \cdot (n-k+1)p}{k!} (1-p)^n (1-p)^{-k} \\
 &= \frac{np(n-1)p \cdot \dots \cdot (n-k+1)p}{k!} \left(1 - \frac{np}{n}\right)^n \left(1 - \frac{np}{n}\right)^{-k} \\
 &= \frac{np \cdot np \cdot \left(1 - \frac{1}{n}\right) \cdot \dots \cdot np \cdot \left(1 - \frac{k+1}{n}\right)}{k!} \left(1 - \frac{np}{n}\right)^n \left(1 - \frac{np}{n}\right)^{-k} \\
 &\xrightarrow[np=\lambda]{n \rightarrow \infty} \frac{\lambda^k}{k!} e^{-\lambda} 1.
 \end{aligned}$$

Bemerge:



$$\begin{aligned}
 np &= \lambda, \\
 \left(1 - \frac{1}{n}\right) &\rightarrow 1, \\
 e^{-x} &= \lim_{n \rightarrow \infty} \left(1 - \frac{x}{n}\right)^n, \\
 \left(1 - \frac{np}{n}\right)^n &\approx \left(1 - \frac{\lambda}{n}\right)^n \approx e^{-\lambda}.
 \end{aligned}$$

□

Beispiel 1.2 (Daten von Berkson (1966)) Daten übernommen aus *Rice (2007, S. 256)*.

α -Teilchen von Americum 241 innerhalb von 10 Sekunden.

Dieses Experiment wird 1207 mal (unabhängig) wiederholt.

$n = 1207$ Beobachtung X_1, \dots, X_n iid mit $X_i \sim P(\lambda_0)$.

Im Poisson Modell X_i iid $P(\lambda_0)$ ist $\mathbb{E}(X_i) = \lambda_0$ $\text{Var}(X_i) = \lambda_0$

Für $\bar{X}_n = \sum_{i=1}^n (X_i)$ ist $E(\bar{X}_n) = \lambda_0$, $\text{Var}(\bar{X}_n) = \frac{\lambda_0}{n}$.

Schätzer für $\mathbb{E}(X_i) = \lambda_0$: $\hat{\lambda}_n = \bar{X}_n \leftarrow$ unverzerzte und konsistente Schätzer

Schätzer für $\text{Var}(X_i) = \lambda_0$: \bar{X}_n oder $\frac{1}{n-1} \sum_{i=1}^n (X_i - \hat{\mu})^2 = \hat{\sigma}_n^2$

Man findet aus den Daten: $\hat{\lambda}_n = 8.37$, $(\hat{\sigma}_n)^2 = 8.37$, $\hat{\sigma}_n^2 = 8.53$.

Konfidenzintervall für λ_0 mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$:

- Normalapproximation:

$$\hat{\lambda}_n \pm \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \dots \text{für } \alpha = 0.05 : [8.206, 8.533]$$

- Bootstrap:

Population	"Bootstrap Population"
$\begin{array}{c} \text{Population} \\ \text{---} \\ \text{P}(\lambda_0) \\ \text{Mittelwert } \lambda_0 \end{array}$	$\begin{array}{c} \text{"Bootstrap Population"} \\ \text{---} \\ X_1, \dots, X_n \\ \text{Mittelwert } \hat{\lambda}_n \end{array}$
\downarrow $X_1, \dots, X_n \text{ i.i.d. } P(\lambda_0)$ \downarrow $\bar{X} = \hat{\lambda}_n$	\downarrow $X_1^*, \dots, X_n^* \text{ (ziehen mit Zurücklegen)}$ \downarrow $\bar{X}^* = \hat{\lambda}_n^*$
Fehler $\hat{\lambda} - \lambda_0$	Fehler $\hat{\lambda}^* - \hat{\lambda}$
Wiederhole (u.a.), m -mal: $\hat{\lambda}^{(1)} - \lambda_0, \dots, \hat{\lambda}^{(m)} - \lambda_0$	Wiederhole (u.a.), m -mal: $\hat{\lambda}^{*(1)} - \hat{\lambda}, \dots, \hat{\lambda}^{*(m)} - \hat{\lambda}$
Schätze die Verteilungsfunktion des Fehlers wie folgt: $F(t) = \mathbb{P}(\hat{\lambda}_n - \lambda_0 \leq t)$ $\hat{F}_M(t) = \frac{1}{m} \sum_{i=1}^m \mathbb{1}\{\hat{\lambda}_n^{(i)} - \lambda_0 \leq t\}$	Schätze die Verteilungsfunktion des Fehlers wie folgt: $F(t)$ $\hat{F}_M^*(t) = \frac{1}{m} \sum_{i=1}^m \mathbb{1}\{\hat{\lambda}_n^{*i} - \hat{\lambda} \leq t\}$

95% Konfidenzintervall mit der Bootstrap-Methode:

$$\left[\hat{\lambda}_n - \hat{F}_n^{*m-1}\left(1 - \frac{\alpha}{2}\right), \hat{\lambda}_n - \hat{F}_n^{*m-1}\left(\frac{\alpha}{2}\right) \right] =$$

$$[8.205, 8.531]$$

1.1 Parametrische Modelle und Parameterschätzung

- Experiment:

Beobachtungen X_1, \dots, X_n

- Parametrisches Modell:

Angenommen die X_1, \dots, X_n sind i.i.d. Beobachtung einer Zufallsvariable X , deren Verteilung von einer bestimmten Form ist:

$$X \sim \text{Verteilung abhängig von einem Parameter } \theta_0 \in \Theta \subseteq \mathbb{R}^p$$

Die funktionale Form des Modells ist bekannt, der Parameter θ_0 ist unbekannt!

Beispiel 1.3 Beispiele von parametrischen Modellen:

$X \sim P(\lambda_0)$	$\lambda_0 = \theta_0$ $\Theta = (0, \infty)$
$X \sim B(p_0)$	$p_0 = \theta_0$ $\Theta = (0, 1)$ bzw. $[0, 1]$
$X \sim \text{Bin}(n, p)$	$p_0 = \theta_0$ $\Theta = (0, 1)$ bzw. $[0, 1]$
$X \sim N(\mu, \sigma_0^2)$	$\sigma_0^2 = \theta_0$ $\Theta = (0, \infty)$ bzw. $[0, \infty)$
$X \sim N(\mu_0, \sigma^2)$	$\mu_0 = \theta_0$ $\Theta = \mathbb{R}$
$X \sim N(\mu_0, \sigma_0^2)$	$\begin{pmatrix} \mu_0 \\ \sigma_0^2 \end{pmatrix} = \theta_0 \dots 2\text{-dim.}$ $\Theta = \mathbb{R} \times (0, \infty)$



Betrachte einen Schätzer $\hat{\theta}$ für θ_0 ; das ist eine Größe $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$, die alleine aus den Daten X_1, \dots, X_n berechenbar ist (oft auch $\hat{\theta}_n$).

Beachte: Für $\theta_0 \in \mathbb{R}^p$ mit $p > 1$ ist auch $\hat{\theta} \in \mathbb{R}^p$.

Definition 1.1 (Unverzerrtheit) Der Schätzer $\hat{\theta}$ für θ_0 ist unverzerrt (bzw. erwartungstreu), wenn gilt:

$$\forall \theta \in \Theta, \forall i = 1, \dots, p : \mathbb{E}_{\theta_n}((\hat{\theta})_i) = (\theta)_i.$$

\uparrow
 Erwartungstreu, wenn θ_n
 der wahre Parameter ist.



Beachte: Für $\hat{\theta} = \begin{pmatrix} \hat{\theta}_1 \\ \vdots \\ \hat{\theta}_p \end{pmatrix}$ ist $\mathbb{E}_{\theta_n}(\hat{\theta}) = \begin{pmatrix} \mathbb{E}_{\theta_n}(\hat{\theta}_1) \\ \vdots \\ \mathbb{E}_{\theta_n}(\hat{\theta}_p) \end{pmatrix}$.

Ist $\hat{\theta}$ unverzerrt, dann ist die i -te Komponente von $\hat{\theta}$ ein unverzerrter Schätzer für die i -te Komponente von θ_0 .

Definition 1.2 (Konsistenz) Ein Schätzer $\hat{\theta}_n$ für θ_0 heißt konsistent, wenn gilt:

\uparrow
 Stichprobengröße

$$\forall \epsilon > 0, \forall i = 1, \dots, p, \forall \theta \in \Theta : \mathbb{P}_{\theta_0}(\|(\hat{\theta}_n)_i - (\theta)_i\| > \epsilon) \xrightarrow{n \rightarrow \infty} 0.$$

Kurz:

$$\hat{\theta}_n \xrightarrow{p} \theta_0.$$

Beachte: $\hat{\theta}_n$ ist konsistent für θ_0 genau dann, wenn $(\hat{\theta}_n)_i$ konsistent ist für $(\theta_0)_i$ für alle $i = 1, \dots, p$.



Nachrechnen. Siehe Übung.



Wunschliste für Schätzer:

- Unverzerrtheit \leftarrow keinen systematischen Fehler.
- Konsistenz \leftarrow Genauigkeit wächst mit n .
- kleine Varianz
- Verteilung des $\hat{\theta}_n - \theta_0$ bekannt oder approximierbar.

Zwei Strategien:

- Momentenmethode
- Maximum-Likelihood-Methode.

1.2 Die Momenten-Methode (MM)

Siehe zu diesem Kapitel S. 260-267. in *Rice (2007)*.



Betrachte ein parametrisches Modell wie in Abschnitt 1.1: X_1, \dots, X_n i.i.d. Kopien von X , wobei $X \sim$ Verteilung abhängig von $\theta_0 \in \Theta \subseteq \mathbb{R}^p$ ($p \geq 1$).

In vielen Fällen gibt es eine eindeutige Beziehung zwischen dem Parameter θ_0 und den Momenten der zugrundeliegende Verteilung X (1:1 Beziehung).

	Parameter	Funktionen von $\mathbb{E}(X), \mathbb{E}(X^2), \dots$
Beispiel 1.4	$X \sim P_{\lambda_0}$	$\lambda_0 > 0 \quad = \mathbb{E}_{\lambda_0}(X) = \lambda_0$
	$X \sim \text{Bin}(n, p_0)$	$p_0 \in [0, 1] \quad = \frac{1}{n} \mathbb{E}(X)_{p_0} \text{ weil } E_{\text{Bin}}(X) = n * p_0$
	$X \sim N(\mu_0, \sigma_0^2)$	$\begin{array}{l} \mu \in \mathbb{R} \quad = \mathbb{E}(X) \\ \sigma_0^2 > 0 \quad = \mathbb{E}(X^2) - (\mathbb{E}(X))^2 = \text{Var}(X) \end{array}$

Bemerkung: (MM) Allgemein:

Für $\theta \in \Theta$ und $k \geq 1$ setzt man $\mathbb{E}_{\theta_0}(X^k) = m_k(\theta_0)$ (Moment=Funktion des Parameters)



Angenommen es gibt eine Funktion $f: \mathbb{R}^p \rightarrow \mathbb{R}^p$, sodass $f\left(\begin{pmatrix} m_1(\theta_0) \\ \vdots \\ m_n(\theta_0) \end{pmatrix}\right) = \theta_0$ für jedes $\theta_0 \in \Theta$ die "glatt" ist.

Dann erhält man einen **Momenten-Methoden-Schätzer** $\hat{\theta}_{MM}$

- durch:

$$\hat{\theta} = \hat{\theta}_{MM} = f(\hat{m}_1, \dots, \hat{m}_p)$$

- wobei

$$\hat{m}_j = \frac{1}{n} \sum_{i=1}^n X_i^j$$

für $1 \leq j \leq p$.



Bemerkung: Es gibt im Allgemeinen mehrere MM-Schätzer.

Beispiel 1.5 (Gleichverteilung) X_1, \dots, X_n i.i.d. $U([0, \theta])$, $\theta > 0$.

$$\mathbb{E}(X_1) = \frac{\theta}{2} \quad \Rightarrow \quad \theta = 2\mathbb{E}(X_1)$$

$$\hat{\theta}_{MM} = 2 \frac{1}{n} \sum_{i=1}^n X_i.$$

$$E(X_1^2) = \frac{\theta^2}{3} \quad \Rightarrow \quad \theta = \sqrt{3\mathbb{E}(X_1^2)}$$

$$\hat{\theta}_{MM} = \sqrt{3 \frac{1}{n} \sum_{i=1}^n X_i^2}.$$

$$E(X_1^3) = \dots \quad \Rightarrow \quad \dots$$



Erinnerung (Stetigkeit):

$g: \mathbb{R} \rightarrow \mathbb{R}$ ist **stetig** im Punkt $m \in \mathbb{R}$, wenn gilt:

$$\forall \epsilon > 0 \exists \delta > 0: |m' - m| < \delta \Rightarrow |g(m') - g(m)| < \epsilon.$$

$g: \mathbb{R}^p \rightarrow \mathbb{R}$ ist **stetig** im Punkt $m \in \mathbb{R}^p$, wenn gilt:

$$\forall \epsilon > 0 \exists \delta > 0: \|m' - m\| < \delta \Rightarrow |g(m') - g(m)| < \epsilon.$$

$g: \mathbb{R}^p \rightarrow \mathbb{R}^q$ ist **stetig** im Punkt $m \in \mathbb{R}^p$, wenn gilt:

$$\forall j = 1, \dots, q \text{ ist } f(\cdot)_j: \mathbb{R}^p \rightarrow \mathbb{R} \text{ stetig im Punkt } m.$$

Lemma 1.1 Sind X_1, \dots, X_n i.i.d. mit $\mathbb{E}(X^k) = m_k$ für $k = 1, \dots, p$ und ist $g : \mathbb{R}^p \rightarrow \mathbb{R}$ stetig im Punkt $(m_1, \dots, m_p) = m$, dann gilt für jedes $\epsilon > 0$

$$\mathbb{P}(|g(\hat{m}) - g(m)| > \epsilon) \xrightarrow{n \rightarrow \infty} 0.$$

(Hier ist $\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ und $\hat{m} = (\hat{m}_1, \dots, \hat{m}_p)$)

Beweis. Sei $\epsilon > 0$. Weil g stetig ist im Punkt m , gibt es ein $\delta > 0$, sodass gilt:

$$\|m' - m\| < \delta \Rightarrow |g(m') - g(m)| < \epsilon.$$

Setze $\hat{m} = \begin{pmatrix} \hat{m}_1 \\ \vdots \\ \hat{m}_p \end{pmatrix}$. Dann gilt:

$$\begin{aligned} \{\|\hat{m} - m\| < \delta\} &\subseteq \{|g(\hat{m}) - g(m)| < \epsilon\} \\ \Rightarrow \{|g(\hat{m}) - g(m)| \geq \epsilon\} &\subseteq \{\|\hat{m} - m\| \geq \delta\} \end{aligned}$$

Also:

$$\begin{aligned} \mathbb{P}(|g(\hat{m}) - g(m)| > \epsilon) &\leq \mathbb{P}(|g(\hat{m}) - g(m)| \geq \epsilon) \\ &\leq \mathbb{P}(\|\hat{m} - m\| \geq \delta) \\ &\leq \mathbb{P}(\sqrt{p} * \max\{|\hat{m}_k - m_k|, 1 \leq k \leq p\} \geq \delta) \\ &= \mathbb{P}\left(\bigcup_{k=1}^p |\hat{m}_k - m_k| > \frac{\delta}{\sqrt{p}}\right) \\ &\leq \sum_{k=1}^p \underbrace{\mathbb{P}\left(|\hat{m}_k - m_k| > \frac{\delta}{\sqrt{p}}\right)}_{\xrightarrow{n \rightarrow \infty} 0 \text{ (wegen LLN)}} \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

Mit dem Gesetz der großen Zahlen gilt:

$$\hat{m}_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{p} m_k \quad (\ast\ast)$$

für jedes $k = 1, \dots, p$.

□

Satz 1.1 Betrachte $X_i, i \geq 1$, i.i.d. wie in (MM).

Ist die Funktion $f : \mathbb{R}^p \rightarrow \mathbb{R}^p$ stetig in jedem Punkt der Menge $\{(m_1(\theta_0), \dots, m_p(\theta_0))' = \theta \in \Theta\}(\ast)$, dann ist $\hat{\theta}_{MM}$ konsistent für θ_0 .

alle möglichen Werte
der Momente

alle möglichen Werte
des Parameters

Beweis.

Zz: Jede Komponente von $\hat{\theta}_n$ ist konsistent für die entsprechende Komponente von θ_0 .

Sei $j \in \{1, \dots, p\}$. Laut Voraussetzung ist $f: \mathbb{R}^p \rightarrow \mathbb{R}^p$ stetig im jedem Punkt der Menge $(*)$. Dann ist auch $f(\cdot)_j: \mathbb{R}^p \rightarrow \mathbb{R}$ stetig im jedem Punkt von $(*)$.

Sei $\theta_0 \in \Theta$ sodass $m := (m_1(\theta_0), \dots, m_p(\theta_0)) \in (*)$. Mit dem Lemma 1.1 folgt dass

$$\forall \epsilon > 0: \mathbb{P}(\underbrace{|f(\hat{m})_j - f(m)_j|}_{=(\hat{\theta}_n)_j} > \epsilon) \rightarrow 0$$

Also ist $(\hat{\theta}_n)_j$ konsistent für $(\theta_0)_j$.

□

Satz 1.2 Betrachte ein parametrisches Modell wo X Verteilung abh. von $\theta \in \Theta \subseteq \mathbb{R}$. Seien X_1, X_2 i.i.d. Kopien von X falls $\theta_0 = f(m_1(\theta_0))$ (für $\theta \in \Theta$) für eine Funktion f , die auf der Menge $\{m_1(\theta) : \theta \in \Theta\}$ stetig ist. Dann ist der MM-Schätzer

$$\hat{\theta}_n = f\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

konsistent für θ_0 .



Erinnerung aus GZ

Falls $X_n \xrightarrow{P} c$ und falls $f: \mathbb{R} \rightarrow \mathbb{R}$ stetig ist im Punkt c , dann folgt aus $f(X_n) \xrightarrow{P} f(c)$.

Wissen: $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ist ein konsistenter Schätzer für $E_{\theta_0}(X) = m_1(\theta_0)$.

D.h. $\bar{X}_n \xrightarrow{P} m_1(\theta_0)$. Laut Voraussetzung ist die Funktion $f(\cdot)$ stetig im Punkt $m_1(\theta_0) \Rightarrow$

$$f(\bar{X}_n) \xrightarrow{P} f(m_1(\theta_0)), \text{ also } \hat{\theta}_n \xrightarrow{P} \theta_0$$

mit andere Worten $\hat{\theta}_n$ ist ein konsistenter Schätzer für θ_0 .

Beispiel 1.6 (Poissonverteilung) X_1, \dots, X_n i.i.d. $P(\lambda_0)$, $\lambda_0 \in (0, \infty)$. Beachte $\mathbb{E}_{\lambda_0}(X_1) = \lambda_0$, dass gibt dann der MM-Schätzer

$$\hat{\lambda}_n = \frac{1}{n} \sum_{i=1}^n X_i.$$

Der Schätzer ist unverzerrt und konsistent. ✓

Wissen: $\lambda_0 = \text{Var}_{\lambda_0}(X_1) = \mathbb{E}_{\lambda_0}(X_1^2) - (\mathbb{E}_{\lambda_0}(X_1))^2$ daraus kann man einen weiteren MM-Schätzer mit λ_0 erhalten.

Beispiel 1.7 (Normalverteilung) X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma_0^2)$ mit $\mu_0 \in \mathbb{R}, \sigma_0^2 \in (0, \infty)$.

$$\mathbb{E}_{\mu_0, \sigma_0^2}(X_1) = \mu_0, \mathbb{E}_{\mu_0, \sigma_0^2}(X_1^2) = \sigma_0^2 + \mu_0^2,$$

$$\text{Var}(X_1) = \mathbb{E}(X_1^2) - (\mathbb{E}(X_1))^2 = \sigma_0^2$$

Das gibt den MM-Schätzer:

$$\begin{pmatrix} \hat{\mu}_n \\ \hat{\sigma}_n^2 \end{pmatrix} = \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n X_i \\ \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \end{pmatrix}.$$

$$\mathbb{E}_{\mu_0, \sigma_0^2}(X_1) = \mu_0$$

$$\mathbb{E}_{\mu_0, \sigma_0^2}(\hat{\sigma}_n^2) = \frac{n-1}{n} \sigma_0^2 \neq \sigma_0^2 \dots \text{verzerrt}$$

$$\hat{\sigma}_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \text{ Vo-GZS}$$

Konsistenz:

Die Funktion $f \begin{pmatrix} m_1 \\ m_2 \end{pmatrix} \mapsto \begin{pmatrix} m_1 \\ m_2 - m_1^2 \end{pmatrix}$ ist stetig auf ganz \mathbb{R}^2 .

Damit ist $\begin{pmatrix} \hat{\mu} \\ \hat{\sigma}^2 \end{pmatrix}$ konsistent für $\begin{pmatrix} \mu_0 \\ \sigma_0^2 \end{pmatrix}$. ✓

Beispiel 1.8 (Geometrische Verteilung) X_1, \dots, X_n i.i.d. $G(p_0)$, $p_0 \in (0, 1)$.

Wissen: Für $X \sim G(p)$ ist

$$\mathbb{E}_{p_0}(X_1) = \frac{1}{p_0}, \Rightarrow p_0 = \frac{1}{\mathbb{E}_{p_0}(X)}$$

Das erzeugt den MM-Schätzer:

$$\hat{p}_0 = \frac{1}{\frac{1}{n} \sum_{i=1}^n X_i}.$$

Dieser Schätzer ist verzerrt! $\mathbb{E}(f(X)) \neq f(\mathbb{E}(X))$!

falls $f(\cdot)$ linear ist, also $f(X) = aX + b$ ist, $\mathbb{E}(aX + b) = a\mathbb{E}(X) + b = f(\mathbb{E}(X))$;

$$\mathbb{E}_p(\hat{p}_n) \neq \frac{1}{\mathbb{E}_p\left(\frac{1}{n} \sum_{i=1}^n X_i\right)} = \frac{1}{\frac{1}{p}} = p.$$

Konsistenz:

Die Funktion $f(t) = \frac{1}{t}$ ist stetig auf $(0, \infty)$.

Die möglichen Werte von $\mathbb{E}_{p_0}(X_1)$ ist die Menge

$$\left\{ \frac{1}{p} : p \in (0, 1) \right\} = (1, \infty). (\star)$$

Damit ist die Funktion $f(\cdot)$ stetig in jedem Punkt der Menge (\star) und mit dem letzten Satz ist

$$\hat{p}_n = f\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

konsistent für p_0 . ✓

Beispiel 1.9 X_1, \dots, X_n i.i.d. $\sim \mathcal{U}([\theta_0, \theta_0 + 1])$, $\theta_0 \in \mathbb{R}$

Hier ist $\mathbb{E}_{\theta_0}(X_1) = \theta_0 + \frac{1}{2}$. Das gibt dem MM-Schätzer

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{2}.$$

Der Schätzer ist unverzerrt (weil $f(x) = x - \frac{1}{2}$ linear ist) und es ist konsistent (weil $f(x)$ stetig ist auf ganz \mathbb{R}).

Verteilung des Schätzfehlers/Konfidenzintervalls:

Beispiel 1.10 (Normalverteilung) X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma_0^2)$, $\mu_0 \in \mathbb{R}, \sigma_0^2 > 0$.

- Konfidenzintervall (KI) für μ_0 :

Wissen:

$$\sqrt{n} \frac{\bar{X}_n - \mu_0}{\hat{\sigma}_n} \sim t_{n-1},$$

wobei $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i = \hat{\mu}_{MM}$ und $\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{n}{n-1} \hat{\sigma}_{MM}^2$.

Gegeben $\alpha \in (0, 1)$. Wähle $a = F_{t_{n-1}}^{-1}\left(\frac{\alpha}{2}\right)$ und $b = F_{t_{n-1}}^{-1}\left(1 - \frac{\alpha}{2}\right)$ (Quantile der t_{n-1} -Verteilung).

Dann ist

$$\begin{aligned} (\star) = \mathbb{P}\left(a \leq \sqrt{n} \frac{\bar{X}_n - \mu_0}{\hat{\sigma}_n} \leq b\right) &= \underbrace{F_{n-1}(b) - F_{n-1}(a)}_{\text{Verteilungsfunktionen der } t_{n-1}} \\ &= 1 - \frac{\alpha}{2} - \frac{\alpha}{2} \\ &= 1 - \alpha. \end{aligned}$$

$$\begin{aligned} (\star) &= \mathbb{P}\left(a \frac{\hat{\sigma}_n}{\sqrt{n}} \leq \bar{X}_n - \mu_0 \leq b \frac{\hat{\sigma}_n}{\sqrt{n}}\right) \\ &= \mathbb{P}\left(-\bar{X}_n + a \frac{\hat{\sigma}_n}{\sqrt{n}} \leq -\mu_0 \leq -\bar{X}_n + b \frac{\hat{\sigma}_n}{\sqrt{n}}\right) \\ &= \mathbb{P}\left(\bar{X}_n - b \frac{\hat{\sigma}_n}{\sqrt{n}} \leq \mu_0 \leq \bar{X}_n - a \frac{\hat{\sigma}_n}{\sqrt{n}}\right) \\ &= \mathbb{P}\left(\mu_0 \in \left[\bar{X}_n - b \frac{\hat{\sigma}_n}{\sqrt{n}}, \bar{X}_n - a \frac{\hat{\sigma}_n}{\sqrt{n}}\right]\right). \end{aligned}$$

Also: Das KI für μ_0 mit Überdeckungswahrscheinlichkeit $1 - \alpha$: $\left[\bar{X}_n - b \frac{\hat{\sigma}_n}{\sqrt{n}}, \bar{X}_n - a \frac{\hat{\sigma}_n}{\sqrt{n}}\right]$

Informell: $\left[\bar{X}_n \pm b \frac{\hat{\sigma}_n}{\sqrt{n}}\right]$, Beobachte: $a = -b$

- KI für σ_0^2 :

Wissen:

$$\begin{aligned}\sum_{i=1}^n (X_i - \bar{X}_n)^2 &\sim \sigma_0^2 \chi_{n-1}^2 \\ \Rightarrow \hat{\sigma}_n^2 &\sim \frac{\sigma_0^2 \chi_{n-1}^2}{n-1} \\ (n-1) \frac{\hat{\sigma}_n^2}{\sigma_0^2} &\sim \chi_{n-1}^2.\end{aligned}$$

Gegeben $\alpha \in (0, 1)$ wählt man hier $a = F_{\chi_{n-1}^2}^{-1}\left(\frac{\alpha}{2}\right)$ und $b = F_{\chi_{n-1}^2}^{-1}\left(1 - \frac{\alpha}{2}\right)$ (Quantile der χ_{n-1}^2 -Verteilung).

Damit ist

$$\begin{aligned}(\star) = \mathbb{P}\left(a \leq (n-1) \frac{\hat{\sigma}_n^2}{\sigma_0^2} \leq b\right) &= F_{\chi_{n-1}^2}(b) - F_{\chi_{n-1}^2}(a) \\ &= 1 - \frac{\alpha}{2} - \frac{\alpha}{2} \\ &= 1 - \alpha.\end{aligned}$$

$$\begin{aligned}(\star) &= \mathbb{P}\left(\frac{a}{(n-1)\hat{\sigma}_n^2} \leq \frac{1}{\sigma_0^2} \leq \frac{b}{(n-1)\hat{\sigma}_n^2}\right) \\ &= \mathbb{P}\left(\frac{(n-1)\hat{\sigma}_n^2}{b} \leq \sigma_0^2 \leq \frac{(n-1)\hat{\sigma}_n^2}{a}\right) \\ &= \mathbb{P}\left(\sigma_0^2 \in \left[\frac{(n-1)\hat{\sigma}_n^2}{b}, \frac{(n-1)\hat{\sigma}_n^2}{a}\right]\right).\end{aligned}$$

Also KI für σ_0^2 mit Überdeckungswahrscheinlichkeit $1 - \alpha$: $\left[\frac{(n-1)\hat{\sigma}_n^2}{b}, \frac{(n-1)\hat{\sigma}_n^2}{a}\right]$.

Beispiel 1.11 (Poisson-Modell) X_1, \dots, X_n i.i.d. $P(\lambda_0)$, ($\lambda_0 > 0$).

Hier ist $\mathbb{E}(X_1) = \lambda_0$, $\text{Var}(X_1) = \lambda_0$.

(*) Erinnerung aus der Vorlesung Grundzüge der Statistik: Für Z_1, \dots, Z_n i.i.d. mit $\mathbb{E}(Z_1) = \mu_0$ und $\text{Var}(Z_1) = \sigma^2$. Ist ein KI für μ mit **nominaler** Überdeckungswahrscheinlichkeit $1 - \alpha$

$$\left[\hat{\mu}_n - \frac{\tilde{\sigma}_n}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \hat{\mu}_n + \frac{\tilde{\sigma}_n}{\sqrt{n}} \Phi^{-1}\left(\frac{\alpha}{2}\right)\right]$$

hierbei ist $\hat{\mu}_n = \frac{1}{n} \sum_{i=1}^n Z_i$ und $\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_i - \hat{\mu}_n)^2$.

Damit erhält man das KI für λ_0 nämlich

$$\left[\bar{X}_n - \frac{\hat{\sigma}_n}{\sqrt{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \bar{X}_n + \frac{\hat{\sigma}_n}{\sqrt{n}} \Phi^{-1}\left(\frac{\alpha}{2}\right)\right] \leftarrow \text{Generisches Intervall}$$

mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$ wobei $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, $\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$

Beachte: \bar{X}_n schätzt $\mathbb{E}(X_1) = \lambda_0$, $\hat{\sigma}_n^2$ schätzt $\text{Var}(X_1) = \lambda_0$.

Im Kontext von $(*)$ gilt (Siehe VO GZ: Beispiel 8.8):

$$\sqrt{n} \frac{\hat{\mu}_n - \mu}{\sigma} \xrightarrow{w} N(0, 1),$$

und auch

$$\sqrt{n} \frac{\hat{\mu}_n - \mu}{\hat{\sigma}_n} \xrightarrow{w} N(0, 1).$$

Sei $\tilde{\sigma}_n^2$ ein anderer konsistenter Schätzer für σ^2

$$\sqrt{n} \frac{\hat{\mu}_n - \mu}{\tilde{\sigma}_n^2} = \sqrt{n} \underbrace{\frac{\hat{\mu}_n - \mu}{\sigma}}_{\xrightarrow{w} N(0,1)} \underbrace{\frac{\sigma}{\tilde{\sigma}_n^2}}_{\xrightarrow{p} 1} \xrightarrow{p} 1.$$

$f(\tilde{\sigma}_n^2)$ für $f(t) = \sqrt{\frac{\sigma^2}{t}}$:

f ist stetig auf $(0, \infty)$ und insbesondere im Punkt σ^2

Der Schätzer $\tilde{\sigma}_n^2$ ist konsistent für σ^2 : $\tilde{\sigma}_n^2 \xrightarrow{p} \sigma^2$

Rechenregel: $f(\tilde{\sigma}_n^2) \xrightarrow{p} f(\sigma^2)$

M.a.W. $\frac{\sigma}{\tilde{\sigma}_n} \xrightarrow{p} 1$.

Mit Rechenregeln aus GZ folgt: $\sqrt{n} \frac{\hat{\mu}_n - \mu}{\tilde{\sigma}_n^2} \xrightarrow{w} N(0, 1) \cdot 1 \equiv N(0, 1).$

Also: Im Poisson-Modell ist \bar{X}_n ein konsistenter Schätzer für $\text{Var}(X_1) = \lambda_0$. Damit gilt:

$$\sqrt{n} \frac{\bar{X}_n - \lambda_0}{\sqrt{\bar{X}_n}} \xrightarrow{w} N(0, 1). \quad (**)$$

Gegeben $\alpha \in (0, 1)$ wähle hier $a = \Phi^{-1}\left(\frac{\alpha}{2}\right)$ und $b = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$.
Dann ist

$$\begin{aligned} \mathbb{P}\left(a \leq \sqrt{n} \frac{\bar{X}_n - \lambda_0}{\sqrt{\bar{X}_n}} \leq b\right) &\stackrel{(**)}{=} \mathbb{P}\left(\sqrt{n} \frac{\bar{X}_n - \lambda_0}{\sqrt{\bar{X}_n}} \leq b\right) - \mathbb{P}\left(\sqrt{n} \frac{\bar{X}_n - \lambda_0}{\sqrt{\bar{X}_n}} \leq a\right) \\ &\approx \Phi(b) - \Phi(a) \\ &= 1 - \frac{\alpha}{2} - \frac{\alpha}{2} \\ &= 1 - \alpha. \end{aligned}$$

$$\begin{aligned} (**) &= \mathbb{P}\left(\sqrt{\frac{\bar{X}_n}{n}} a \leq \bar{X}_n - \lambda_0 \leq \sqrt{\frac{\bar{X}_n}{n}} b\right) \\ &= \mathbb{P}\left(-\bar{X}_n + \sqrt{\frac{\bar{X}_n}{n}} a \leq -\lambda_0 \leq -\bar{X}_n + \sqrt{\frac{\bar{X}_n}{n}} b\right) \\ &= \mathbb{P}\left(\bar{X}_n - b \sqrt{\frac{\bar{X}_n}{n}} \leq \lambda_0 \leq \bar{X}_n - a \sqrt{\frac{\bar{X}_n}{n}}\right). \end{aligned}$$

Also ein KI für λ_0 mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$ ist

$$\left[\bar{X}_n - b \sqrt{\frac{\bar{X}_n}{n}}, \bar{X}_n - a \sqrt{\frac{\bar{X}_n}{n}}\right] \leftarrow \text{Spezielles Intervall im Poisson-Modell}$$

(Beachte! -a=b)

Beispiel 1.12 (Geometrische Verteilung) $X_1, \dots, X_n \sim G(p_0)$, $p_0 \in (0, 1)$.

Wissen: $\mathbb{E}(X_1) = \frac{1}{p_0} = \mu_0$, $(p_0 = \frac{1}{\mathbb{E}(X_1)})$ $\text{Var}(X_1) = \frac{1-p_0}{p_0^2}$, MM-Schätzer für p_0 : $\hat{p}_n = \frac{1}{\bar{X}_n}$ (nicht linear!).

Hinweis zur geometrischen Verteilung:

- # Versuche bis zum 1. Erfolg (wird in der Vorlesung verwendet)
- # Misserfolge bis zum 1. Erfolg + 1 (wird in R verwendet).

$$\frac{1-p_0}{p_0^2} = \frac{\frac{1}{p_0}-1}{p_0} = \frac{1}{p_0} \left(\frac{1}{p_0} - 1 \right) = \mu_0(\mu_0 - 1),$$

$$\mathbb{E}(X_1) = \mu_0, \text{Var}(X_1) = \mu_0(\mu_0 - 1)$$

Suche KI für $\mu_0 = \mathbb{E}(X_1) = \frac{1}{p_0}$

Wie im letzten Beispiel erhält man das KI

$$\left[\bar{X}_n - \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right), \bar{X}_n + \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(\frac{\alpha}{2} \right) \right],$$

mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$, wobei

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \text{ und } \hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

Im geometrischen Modell ist $\hat{\sigma}_n^2 = \bar{X}_n(\bar{X}_n - 1)$ ein Schätzer für $\text{Var}(X_1)$ der konsistent ist.

Das gibt ein weiteres KI für μ_0 nämlich:

$$\left[\bar{X}_n - \sqrt{\frac{\tilde{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right), \bar{X}_n + \sqrt{\frac{\tilde{\sigma}_n^2}{n}} \Phi^{-1} \left(\frac{\alpha}{2} \right) \right]$$

mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$.

Betrachte: Z_1, \dots, Z_n i.i.d; $\mathbb{E}(Z_1) = \mu$, $\text{Var}(Z_1) = \sigma^2$

KI für μ : $\bar{Z}_n \mp \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right)$

KI für $f(\mu)$ =?

- Fall 1: $f(\cdot)$ linear, $f(t) = At + B$, $A > 0$, A und B bekannt;

$$\text{Wissen: } 1 - \alpha \approx \mathbb{P} \left(\bar{Z}_n - \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \leq \mu \leq \bar{Z}_n + \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right)$$

$$= \mathbb{P} \left(A \left(\bar{Z}_n - \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right) + B \leq f(\mu) \leq A \left(\bar{Z}_n + \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right) + B \right)$$

...gibt KI für $f(\mu)$ mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$

$f(\cdot)$ linear wie oben, $A < 0$... analog.

- Fall 2: $f(\cdot)$ nicht linear + Skizze

$$\bar{X}_n \pm \sqrt{\frac{\hat{\sigma}_n^2}{n}} \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \text{ KI für } \frac{1}{p_0} \text{ für } X_1 \text{ i.i.d. } G(p_0)$$

$$\text{1.Schätzer: } \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$\text{2.Schätzer: } \bar{X}_n(\bar{X}_n - 1)$$

$$\text{Hinweis: } \frac{1-p_0}{p_0^2} = \frac{1}{p_0} \left(\frac{1}{p_0} - 1\right)$$

Z_1, \dots, Z_m i.i.d. und

- $\mathbb{E}(Z_1) = q$... Überdeckungswahrscheinlichkeit
- $\text{Var}(Z_1) = q(q-1)$

$$\bar{Z}_m: \text{KI für } q: \bar{Z}_m \pm \underbrace{\sqrt{\frac{\cdot}{m}} \Phi^{-1}\left(1 - \frac{0.05}{2}\right)}_{\text{Typische Fehler} = 2 \frac{\text{std. Abweichung}}{\sqrt{m}}}$$

X_1, \dots, X_n i.i.d. $G(p_0)$

? KI für $p_0 = \frac{1}{\mathbb{E}_{p_0}(X_1)}$

- $f(\cdot)$ linear: $(f(x) = ax + b)$

$$\begin{aligned} \sqrt{n}(\bar{X}_n - \mathbb{E}(X_1)) &\xrightarrow{w} N(0, \text{Var}(X_1)) \\ \sqrt{n}(f(\bar{X}_n) - f(\mathbb{E}(X_1))) &\xrightarrow{w} N(0, a^2 \text{Var}(X_1)) \\ \underbrace{\sqrt{n}(a\bar{X}_n + b - (a\mathbb{E}(X_1) + b))}_{a\sqrt{n}(\bar{X}_n - \mathbb{E}(X_1))} &\xrightarrow{w} N(0, \text{Var}(X_1)) \\ &\xrightarrow{w} N(0, a^2 \text{Var}(X_1)) \end{aligned}$$

- $f(\cdot)$ nicht linear: siehe nächste Satz!

Satz 1.3 (δ -Methode) Es seien Z_i i.i.d. Kopien von Z , mit $\mathbb{E}(Z) = \mu_Z$ und $\text{Var}(Z) = \sigma_Z^2 > 0$.

Ist die Funktion $f: \mathbb{R} \rightarrow \mathbb{R}$ im Punkt μ_Z **differenzierbar**, dann gilt:

$$\sqrt{n}(f(\bar{Z}_n) - f(\mu_Z)) \xrightarrow{w} N(0, (f'(\mu_Z))^2 \sigma_Z^2),$$

wobei $\bar{Z}_n = \frac{1}{n} \sum_{i=1}^n Z_i$.



Illustration: Siehe R-script vom 22.04.2021.

Beweis. Erinnerung:

$\sqrt{n}(\bar{Z}_n - \mu_Z) \xrightarrow{w} N(0, \sigma_Z^2)$	Zentraler Grenzwertsatz
$\bar{Z}_n \xrightarrow{p} \mu_Z$	Gesetz der großen Zahlen
$X_n \xrightarrow{p} c, f(\cdot)$ stetig in c $\Rightarrow f(X_n) \xrightarrow{p} f(c)$ $X_n \xrightarrow{w} X, Y_n \xrightarrow{p} c$ $\Rightarrow X_n + Y_n \xrightarrow{w} X + c$ $\Rightarrow X_n \cdot Y_n \xrightarrow{w} X \cdot c$	Rechenregeln für $\xrightarrow{p}, \xrightarrow{w}$, GZS S. 80
$f'(\mu_Z) = \lim_{Z \rightarrow \mu_Z} \frac{f(Z) - f(\mu_Z)}{Z - \mu_Z}$	VO Analysis

Definiere eine Funktion $R(Z)$ als

$$R(Z) = \begin{cases} f'(\mu_Z) - \frac{f(Z) - f(\mu_Z)}{Z - \mu_Z} & : Z \neq \mu_Z, \\ 0 & : Z = \mu_Z. \end{cases}$$

Dann ist $R(\cdot)$ stetig im Punkt μ_Z :

$$\begin{array}{ccc} & \lim_{Z \rightarrow \mu_Z} R(Z) = 0 = R(\mu_Z). & \\ & \swarrow \quad \searrow & \\ \text{weil } f \text{ differenzierbar} & & \text{siehe} \\ \text{ist im Punkt } \mu_Z & & \text{oben} \end{array}$$

Ersetze Z durch \bar{Z}_n

$$f'(\mu_Z) = \frac{f(\bar{Z}_n) - f(\mu_Z)}{\bar{Z}_n - \mu_Z} + R(\bar{Z}_n)$$

Multiplizieren mit $\sqrt{n}(\bar{Z}_n - \mu_Z)$

$$f'(\mu_Z) \sqrt{n}(\bar{Z}_n - \mu_Z) = \sqrt{n}(f(\bar{Z}_n) - f(\mu_Z)) + \sqrt{n}(\bar{Z}_n - \mu_Z) R(\bar{Z}_n)$$

$$\begin{aligned} \sqrt{n}(f(\bar{Z}_n) - f(\mu_Z)) &= \underbrace{f'(\mu_Z) \sqrt{n}(\bar{Z}_n - \mu_Z)}_{\xrightarrow{w} N(0, \sigma_Z^2)} - \underbrace{\sqrt{n}(\bar{Z}_n - \mu_Z)}_{\xrightarrow{w} N(0, \sigma_Z^2)} \underbrace{R(\bar{Z}_n)}_{\xrightarrow{p} R(\mu_Z)=0} \\ &= \underbrace{\sqrt{n}(\bar{Z}_n - \mu_Z)}_{\xrightarrow{w} N(0, \sigma_Z^2)} \underbrace{f'(\mu_Z)}_{\xrightarrow{w} N(0, (f'(\mu_Z))^2 \sigma_Z^2)} - \underbrace{\sqrt{n}(\bar{Z}_n - \mu_Z) R(\bar{Z}_n)}_{\xrightarrow{w} N(0, \sigma_Z^2) \cdot 0 = 0} \\ &\xrightarrow{w} N(0, (f'(\mu_Z))^2 \sigma_Z^2). \end{aligned}$$

□

Beispiel 1.13 (Fortsetzung des oberen Beispiels - Geometrische Verteilung)

$X_i, i \geq 1$, i.i.d. $G(p_0)$, $p_0 \in (0, 1)$.

Wissen:

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mathbb{E}_{p_0}(X_1) = \frac{1}{p_0},$$

$$\underbrace{\hat{p}_0}_{\text{MM-Schätzer}} = \frac{1}{\bar{X}_n} \xrightarrow{p} p_0.$$

$$\sqrt{n} \left(\bar{X}_n - \frac{1}{p_0} \right) \xrightarrow{w} N \left(0, \frac{1-p_0}{p_0^2} \right).$$

Betrachte $f(t) = \frac{1}{t}$, sodass

$$\hat{p}_n = f(\bar{X}_n) \text{ und } p_0 = f\left(\frac{1}{p_0}\right)$$

$f(\cdot)$ ist stetig an der Stelle $\frac{1}{p_0}$

$$f'(t) = -\frac{1}{t^2}$$

$$f'\left(\frac{1}{p_0}\right) = -\frac{1}{\left(\frac{1}{p_0}\right)^2} = -p_0^2$$

$$\left(f'\left(\frac{1}{p_0}\right)\right)^2 = p_0^4$$

Mit δ -Methode:

$$\sqrt{n} \left(\underbrace{f(\bar{X}_n)}_{\hat{p}_n} - \underbrace{f\left(\frac{1}{p_0}\right)}_{p_0} \right) \xrightarrow{w} N \left(0, \underbrace{\left(f'\left(\frac{1}{p_0}\right)\right)^2 \frac{1-p_0}{p_0^2}}_{p_0^4 \frac{1-p_0}{p_0^2} = p_0^2(1-p_0)} \right)$$

$$\text{Also: } \sqrt{n}(\hat{p}_n - p_0) \xrightarrow{w} N(0, p_0^2(1-p_0)).$$

$$\text{bzw. } \sqrt{n} \frac{\hat{p}_n - p_0}{\sqrt{p_0^2(1-p_0)}} \xrightarrow{w} N(0, 1)$$

$$\tilde{\sigma}_n^2 = \hat{p}_n^2(1-\hat{p}_n) \xrightarrow{p} p_0^2(1-p_0)$$

(weil $\hat{p}_n \xrightarrow{p} p_0$ und weil $g(t) = t^2(1-t)$ stetig ist im Punkt p_0)

$$\text{Damit gilt auch } \sqrt{n} \frac{\hat{p}_n - p_0}{\sqrt{\hat{p}_n^2(1-\hat{p}_n)}} \xrightarrow{w} N(0, 1)$$

Für $\alpha \in (0, 1)$ ist ein Konfidenzintervall für p_0 mit nominaler Überdeckungswahrscheinlichkeit $1 - \alpha$ damit gegeben durch

$$\left[\hat{p}_n \pm \sqrt{\frac{\hat{p}_n^2(1-\hat{p}_n)}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right), \right]$$



Bemerkung: Das letzte Beispiel zeigt die Konstruktion von Konfidenzintervallen mit zentralem Grenzwertsatz und δ -Methode. Eine alternative Konstruktion liefert der Bootstrap.

Bemerkung: Es gibt auch eine multivariate Version der δ -Methode.



Die tatsächliche U-Wkeit dieses Intervalls hängt von n und p_0 ab.

Wissen: für jedes $p_0 \in (0, 1)$ gilt

$$\mathbb{P}_{p_0} \left(p_0 \in \hat{p}_n \pm \sqrt{\frac{\hat{p}_n^2(1-\hat{p}_n)}{n}} \Phi^{-1} \left(1 - \frac{\alpha}{2} \right) \right) \xrightarrow{n \rightarrow \infty} 1 - \alpha$$

Wie groß muss n sein, damit diese Wahrscheinlichkeit gleich 0.95 ± 0.01 ist.

Simulation in R:

n/p_0	5	20	80	320	640	1280	2560
0.01	✓	✓	✓	✓	✓	✓	✓
0.1	✓	✓	✓	✓	✓	✓	✓
0.5	×	✓	✓	✓	✓	✓	✓
0.9	×	×	×	✓	✓	✓	✓
0.99	×	×	×	×	×	×	✓

Die Qualität der Approximation hängt von n und p_0 ab. Beachte: p_0 ist konsistent schätzbar!

Betrachte n, \hat{p}_n

Diese Approximation (Überdeckungswahrscheinlichkeit $\approx 1 - \alpha$) ist punktweise:

$$\forall p_0: \text{Fehler}(n, p_0) \xrightarrow{n \rightarrow \infty} 0,$$

In eigenen Fällen ist auch eine gleichmäßige Approximation verfügbar.

$$\sup_{n, p_0} \text{Fehler}(p_0) \xrightarrow{n \rightarrow \infty} 0.$$

In vorliegenden Fall (geom. Modell) gibt es leider keine gleichmäßige Approximation.

1.3 Die Maximum-Likelihood Methode (ML)

Siehe zu diesem Kapitel S. 267-285. in *Rice (2007)*.



Betrachte i.i.d. Zufallsvariablen X_1, \dots, X_n deren jeweilige Dichte bzw. Wahrscheinlichkeitsfunktion von folgender Form ist:

$$f(x|\theta_0), \quad \theta_0 \in \Theta \subseteq \mathbb{R}^p.$$

Die funktionale Form von $f(x|\theta_0)$ ist bekannt, aber der Parameter θ_0 ist unbekannt.

Idee: Gegeben Beobachtungen x_1, \dots, x_n von X_1, \dots, X_n schätzt man θ_0 durch jenen Wert von $\theta \in \Theta$, für welchen die Beobachtungen "am Wahrscheinlichsten" sind. Man wählt also jenes $\theta \in \Theta$, das die Beobachtungen "am Besten beschreibt".



Diskrete Modelle:

Betrachte i.i.d. Zufallsvariablen X_1, \dots, X_n , die diskret sind mit Wahrscheinlichkeitsfunktion

$$p(x|\theta_0), \quad \theta_0 \in \Theta \subseteq \mathbb{R}^p, \quad x \in \mathbb{N}.$$

Betrachte Beobachtungen x_1, \dots, x_n von X_1, \dots, X_n . Ist der wahre Parameter gleich $\theta \in \Theta$, dann ist die Wahrscheinlichkeit, die Werte x_1, \dots, x_n zu beobachten, gegeben durch

$$p_\theta(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) := L(\theta).$$

$L(\theta)$ nennt man die **Likelihood**.

Beachte $L(\theta) = \mathbb{P}_\theta(X_1 = x_1) \cdot \mathbb{P}_\theta(X_2 = x_2) \cdot \dots \cdot \mathbb{P}_\theta(X_n = x_n) = p(x_1|\theta) \cdot p(x_2|\theta) \cdot \dots \cdot p(x_n|\theta)$.

Alternativ dazu betrachtet man oft die sogenannte Log-Likelihood

$$\begin{aligned} l(\theta) &= \log(L(\theta)) \\ &= \sum_{i=1}^n \log p(x_i|\theta). \end{aligned}$$



Beachte: $L(\theta)$ und $l(\theta)$ hängen von den beobachteten Werten x_1, \dots, x_n ab.

Die Maximum-Likelihood Methode maximiert $L(\theta)$ bzw. $l(\theta)$ über $\theta \in \Theta$:

$$\hat{\theta}_{ML} = \operatorname{argmax}_{\theta \in \Theta} L(\theta) = \operatorname{argmax}_{\theta \in \Theta} l(\theta),$$

wobei $\hat{\theta}_{ML}$ ein Maximum-Likelihood-Schätzer für θ ist.



Beachte: Ein Maximierer von $L(\theta)$ ist auch ein Maximierer von $l(\theta)$, und umgekehrt.



Bemerkung: Manchmal gibt es mehr als einem Maximierer der Likelihood.



Beachte: $L(\theta)$ und $l(\theta)$ hängen von den beobachteten Werten X_1, \dots, X_n ab.

Beispiel 1.14 (Bernoulli-Verteilung) X_1, \dots, X_n i.i.d. $B(\theta_0)$, $\theta_0 \in (0, 1)$. Die Wahrscheinlichkeitsfunktion ist hier

$$\begin{aligned} p(x|\theta_0) &= \begin{cases} \theta_0 & : x = 1, \\ 1 - \theta_0 & : x = 0 \end{cases} \\ &= \theta_0^x (1 - \theta_0)^{1-x}. \end{aligned}$$

Für Beobachtungen x_1, \dots, x_n von X_1, \dots, X_n ist die Likelihood gegeben durch

•

$$\begin{aligned}
 L(\theta) &= p(x_1|\theta) \cdot \dots \cdot p(x_n|\theta) \\
 &= \underbrace{\left(\theta^{x_1}(1-\theta)^{1-x_1}\right) \left(\theta^{x_2}(1-\theta)^{1-x_2}\right) \cdot \dots \cdot \left(\theta^{x_n}(1-\theta)^{1-x_n}\right)}_{n \text{ Faktoren. Jeder Faktor ist entweder gleich } \theta \text{ oder } 1-\theta} \\
 &= \theta^{S_n} (1-\theta)^{n-S_n} \\
 \text{wobei } S_n &= \sum_{i=1}^n x_i
 \end{aligned}$$

•

$$l(\theta) = S_n \cdot \log(\theta) + (n - S_n) \log(1 - \theta).$$

•

$$l'(\theta) = S_n \frac{1}{\theta} + (n - S_n) \frac{-1}{1 - \theta} = \frac{S_n}{\theta} - \frac{n - S_n}{1 - \theta}.$$

$$\begin{aligned}
 f'(\theta) &\stackrel{!}{=} 0 \\
 \Leftrightarrow \quad \frac{S_n}{\theta} &= \frac{n - S_n}{1 - \theta} \\
 \Leftrightarrow S_n(1 - \theta) &= \theta(n - S_n) \\
 \Leftrightarrow S_n - S_n\theta &= n\theta - S_n\theta \\
 \Leftrightarrow \frac{S_n}{n} &= \theta_{\star}.
 \end{aligned}$$

•

$$\begin{aligned}
 f''(\theta) &= -\frac{S_n}{\theta^2} - (n - S_n) \frac{-1}{(1 - \theta)^2} \\
 &= -\underbrace{\left(\frac{S_n}{\theta^2} + \frac{n - S_n}{(1 - \theta)^2}\right)}_{\text{Nenner alle } > 0} \leq 0.
 \end{aligned}$$

Wissen:

$$0 \leq S_n \leq n$$

$$0 \leq n - S_n \leq n$$

Weil $n \geq 1$ und $S_n(n - S_n) = n \geq 1$
ist entweder $S_n > 0$ oder $n - S_n > 0$.

Damit ist $f''(\theta) < 0$

Damit ist $\frac{S_n}{n}$ der eindeutige Maximierer von $L(\theta)$!

Also

$$\hat{\theta}_{ML} = \operatorname{argmax}_{0 < \theta < 1} L(\theta) = \bar{x}_n$$

Vor Durchführung des Experimentes ist

$$\hat{\theta}_{ML} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

der ML-Schätzer.

Beachte: $\mathbb{E}_{\theta}(X_1) = \theta$.

Bemerkung: Hier stimmen ML- und MM- Schätzer überein.

Stetige Zufallsvariablen:

Betrachte i.i.d. Zufallsvariablen $X_i, i \geq 1$ mit Dichte

$$f(x|\theta_0), \quad \theta_0 \in \Theta \subseteq \mathbb{R}^p$$

Gegeben Beobachtungen x_1, \dots, x_n von X_1, \dots, X_n ist die **Likelihood** definiert als

$$L(\theta) = f(x_1|\theta) \cdot f(x_2|\theta) \cdot \dots \cdot f(x_n|\theta), \theta \in \Theta.$$

Alternativ zu $L(\theta)$ betrachtet man oft die Log-Likelihood

$$l(\theta) = \log L(\theta) = \sum_{i=1}^n \log f(x_i|\theta).$$



Bemerkung: $L(\theta)$ und $l(\theta)$ hängen von den Daten x_1, \dots, x_n ab.

Der Maximum-Likelihood Schätzer $\hat{\theta}_{ML}$ maximiert $L(\theta)$ bzw. $l(\theta)$ über $\theta \in \Theta$:

$$\begin{aligned} \hat{\theta}_{ML} &= \operatorname{argmax}_{\theta \in \Theta} L(\theta) \\ &= \operatorname{argmax}_{\theta \in \Theta} l(\theta). \end{aligned}$$



Bemerkung: Die Likelihood einer stetigen Zufallsvariable kann als Grenzfall der Likelihoods von diskreten Zufallsvariablen betrachtet werden.

Zur Approximation einer stetigen ZV durch diskrete ZV:

Sei X eine stetige ZV mit Dichte $f(x)$.

Für $\delta > 0$ definiert man eine diskrete ZV X_{δ} wie folgt:

Der Wertebereich von X_{δ} ist $\{k\delta : k \in \mathbb{Z}\}$, und die Wahrscheinlichkeitsfunktion $p_{\delta}(k\delta)$ ist:

$$\begin{aligned} p_{\delta}(k\delta) &:= \mathbb{P}(k\delta \leq X < (k+1)\delta) \\ &= \int_{k\delta}^{(k+1)\delta} f(x) dx. \end{aligned}$$

Vergleichen nun die Dichte $f(x)$ mit dem "Histogramm X_δ ".

Bei diesem "Histogramm" wird über jedem Intervall $[k\delta, (k+1)\delta)$ ein Balken mit Höhe $\frac{1}{\delta}\mathbb{P}_\delta(k\delta)$ gezeichnet.

Die Fläche eines solchen Balkens ist damit $\mathbb{P}_\delta(k\delta)$.

Fixiert man einen Punkt $x \in \mathbb{R}$, dann liegt dieser Punkt im Intervall $[k\delta, (k+1)\delta)$ für $k = \lfloor \frac{x}{\delta} \rfloor$ (da $\lfloor \frac{x}{\delta} \rfloor \leq \frac{x}{\delta} \leq \lfloor \frac{x}{\delta} \rfloor + 1$ ist).

Im Punkt x hat die Dichte den Wert $f(x)$.

Im Punkt x hat das "Histogramm" die Höhe:

$$\begin{aligned} \frac{1}{\delta}\mathbb{P}_\delta(\lfloor \frac{x}{\delta} \rfloor) &= \frac{1}{\delta} \int_{\lfloor \frac{x}{\delta} \rfloor \delta}^{(\lfloor \frac{x}{\delta} \rfloor + 1)\delta} f(x) dx = \\ &= \frac{F(\lfloor \frac{x}{\delta} \rfloor \cdot \delta + \delta) - F(\lfloor \frac{x}{\delta} \rfloor \cdot \delta)}{\delta}. \end{aligned}$$

...dies ist ein Differentialquotient.

Für $\delta \downarrow 0$ konvergiert $\lfloor \frac{x}{\delta} \rfloor \cdot \delta + \delta$ von oben gegen x , und $\lfloor \frac{x}{\delta} \rfloor \cdot \delta$ konvergiert von unten gegen x , sodass der Differentialquotient gegen die Ableitung von F an der Stelle x konvergiert.

M.a.W:

$$\lim_{\delta \downarrow 0} \frac{1}{\delta}\mathbb{P}_\delta(\lfloor \frac{x}{\delta} \rfloor) = f(x)$$

Beispiel 1.15 (Exponentialverteilung) X_1, \dots, X_n i.i.d. $\text{Exp}(\lambda_0)$, $\lambda_0 > 0$.

D.h. $\mathbb{E}(X_1) = \frac{1}{\lambda_0}$, und Dichte $f(x|\lambda_0) = \lambda_0 e^{-\lambda_0 x}$ ($x \geq 0$).

Für Beobachtungen x_1, \dots, x_n ist

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n f(x_i|\lambda) \\ &= \prod_{i=1}^n \lambda e^{-\lambda x_i} \\ &= \lambda^n e^{-\lambda S_n} \end{aligned}$$

wobei $S_n = \sum_{i=1}^n x_i$.

$$l(\lambda) = n \log \lambda - \lambda S_n.$$

$$\begin{aligned} l'(\lambda) &= \frac{n}{\lambda} - S_n \stackrel{!}{=} 0 \\ \Leftrightarrow \frac{n}{\lambda} &= S_n \\ \Leftrightarrow \lambda &= \frac{n}{S_n} \end{aligned}$$

Setze:

$$\hat{\lambda}_{ML} = \frac{n}{S_n} = \frac{1}{\frac{1}{n} S_n} = \frac{1}{\bar{X}_n}.$$

$$l''(\lambda) = \frac{d}{d\lambda} \left(\frac{n}{\lambda} - S_n \right) = -\frac{n}{\lambda^2} < 0.$$

Damit ist der Maximum-Likelihood-Schätzer für λ_0 gegeben durch

$$\hat{\lambda}_{ML} = \frac{1}{\bar{X}_n}.$$



Beachte: Da $\mathbb{E}(X_1) = \frac{1}{\lambda_0}$ ist, also $\lambda_0 = \frac{1}{\mathbb{E}(X_1)}$, ist der Maximum-Likelihood-Schätzer für λ_0 auch ein Momentenmethoden-Schätzer.

Beispiel 1.16 (Gleichverteiltes Skalenmodell) X_i i.i.d. $U([0, \theta_0])$, $\theta_0 > 0$.

Hier ist

$$f(x_1|\theta_0) = \begin{cases} \frac{1}{\theta_0} & : 0 \leq x \leq \theta_0, \\ 0 & : \text{sonst.} \end{cases}$$

und

$$\mathbb{E}_{\theta_0}(X_i) = \frac{\theta_0}{2}$$

$$L(\theta) = \prod_{i=1}^n f(x_i|\theta_0) = \begin{cases} \theta^{-n} & : \text{alle } x_i \text{ zwischen } 0 \text{ und } \theta \\ & 0 \leq \min(x_i) \wedge \max(x_i) = \theta \\ 0 & : \text{sonst.} \end{cases}$$

Achtung: $L(\theta)$ ist nicht differenzierbar an der Stelle $\theta = x_{(n)}$.

$L(\theta)$ wird maximal für $\theta = \max\{x_i : 1 \leq i \leq n\}$.

Damit ist der Max-Likelihood Schätzer $\hat{\theta}_{ML}$ gegeben durch

$$\hat{\theta}_{ML} = \max\{x_i : 1 \leq i \leq n\}$$

$\mathbb{E}(X_1) = \frac{\theta_0}{2}$, also $\theta_0 = 2\mathbb{E}(X_1)$, ist ein MM-Schätzer für θ_0 gegeben durch $\hat{\theta}_{MM} = 2\bar{X}_n$.

Hier ist $\hat{\theta}_{ML} \neq \hat{\theta}_{MM}$.

Bemerkungen:

- In dem Fall, wo $2\bar{X}_n < x_{(n)}$ liefert $\hat{\theta}_{MM}$ einen unsinnigen Wert $\hat{\theta}_{MM} < x_{(n)}$, also ist $\hat{\theta}_{MM}$ mit dem Daten nicht konsistent.
Mit $\hat{\theta}_{ML}$ kann genau das nicht passieren.
- Dagegen ist $\hat{\theta}_{MM}$ unverzerrt, $\hat{\theta}_{ML}$ dagegen nicht.

Definition 1.3 Betrachte ein Parametrisches Modell mit Parameter $\theta_0 \in \Theta \subseteq \mathbb{R}$. Für einen Schätzer $\hat{\theta}_n$ ist der **mittlere quadratische Fehler (MSE)** definiert als

$$MSE(\hat{\theta}_n, \theta) = \mathbb{E}_\theta \left[(\hat{\theta}_n - \theta)^2 \right].$$



Bemerkung:

- Ist $\hat{\theta}_n$ ein unverzerrter Schätzer dann ist::

$$MSE(\hat{\theta}_n, \theta) = \text{Var}_\theta(\hat{\theta}_n).$$

- Im Allgemeinen ist

$$MSE(\hat{\theta}_n, \theta) = \text{Var}_{\theta}(\hat{\theta}_n) + (\mathbb{E}_{\theta}(\hat{\theta}_n) - \theta)^2$$

$$MSE = \text{Varianz} + \text{Bias}^2.$$

Nachrechnen.

$$\begin{aligned} \mathbb{E}_{\theta} \left((\hat{\theta}_n - \theta)^2 \right) &= \mathbb{E}_{\theta} \left(\left((\hat{\theta}_n - \mathbb{E}_{\theta}(\hat{\theta}_n)) + (\mathbb{E}_{\theta}(\hat{\theta}_n) - \theta) \right)^2 \right) \\ &= \mathbb{E}_{\theta} \left((\hat{\theta}_n - \mathbb{E}_{\theta}(\hat{\theta}_n))^2 \right) + 2\mathbb{E}_{\theta}(\hat{\theta}_n - \mathbb{E}_{\theta}(\hat{\theta}_n))(\mathbb{E}_{\theta}(\hat{\theta}_n - \theta)) + \mathbb{E}_{\theta} \left((\mathbb{E}_{\theta}(\hat{\theta}_n) - \theta)^2 \right) \\ &= \underbrace{\text{Var}_{\theta}(\hat{\theta}_n)}_{\text{Varianz}} + 2 \underbrace{\left(\mathbb{E}_{\theta}(\hat{\theta}_n - \theta) \mathbb{E}_{\theta}(\hat{\theta}_n - \mathbb{E}_{\theta}(\hat{\theta}_n)) \right)}_{=\mathbb{E}(\hat{\theta}) - \mathbb{E}(\hat{\theta}) = 0} + \underbrace{(\mathbb{E}_{\theta}(\hat{\theta}_n) - \theta)^2}_{\text{Bias}^2}. \end{aligned}$$

□

Beispiel 1.17 X_1, \dots, X_n i.i.d. $U([0, \theta_0])$, $\theta_0 > 0$.

2 Schätzer:

$$\hat{\theta}_{MM} = 2\bar{X}_n \text{ und } \hat{\theta}_{ML} = \max_{1 \leq i \leq n} X_i = X(n)$$

MSE von $\hat{\theta}_{MM}$: $\hat{\theta}_{MM}$ ist unverzerrt, sodass:

$$\begin{aligned} MSE(\hat{\theta}_{MM}, \theta) &= \text{Var}_{\theta}(\hat{\theta}_{MM}) = \text{Var}_{\theta}(2\bar{X}_n) \\ &= 4\text{Var}_{\theta}(\bar{X}_n) \\ &= 4 \frac{\text{Var}_{\theta}(X_1)}{n} \\ &= 4 \frac{1}{n} \frac{\theta^2}{12} \\ &= \frac{\theta^2}{3n} \xrightarrow{\text{wie } \frac{1}{n}} 0. \end{aligned}$$

Für $Z \sim U([0, 1])$ ist $\mathbb{E}(Z) = \frac{1}{2}$ und $\text{Var}(Z) = \frac{1}{12}$.

Nun ist $\theta_0 Z \sim U([0, \theta_0])$, sodass

$$\begin{aligned} \mathbb{E}(X_1) &= \mathbb{E}(\theta_0 Z) = \theta_0 \mathbb{E}(Z) = \theta_0 \frac{1}{2} \\ \text{Var}(X_1) &= \text{Var}(\theta_0 Z) = \theta_0^2 \text{Var}(Z) = \theta_0^2 \frac{1}{12}. \end{aligned}$$

MSE von $\hat{\theta}_{ML}$: Die ZV $X_{(n)}$ hat die Verteilungsfunktion

$$\begin{aligned} F_{\theta}(t) &= \mathbb{P}_{\theta}(X_{(n)} \leq t) \\ &= \mathbb{P}_{\theta}(X_1 \leq t, \dots, X_n \leq t) \\ &= \underbrace{\mathbb{P}_{\theta}(X_1 \leq t)}_{\frac{t}{\theta}} \cdots \underbrace{\mathbb{P}_{\theta}(X_n \leq t)}_{\frac{t}{\theta}} \\ &= \left(\frac{t}{\theta} \right)^n \text{ für } 0 \leq t \leq \theta_0. \end{aligned}$$

\Rightarrow Dichte von $\hat{\theta}_{ML}$:

$$f_{\theta}(t) = F'(t) = \frac{n \cdot t^{n-1}}{\theta^n}.$$

- $\mathbb{E}_{\theta}(\hat{\theta}_{ML})$

$$\begin{aligned}\mathbb{E}_{\theta}(\hat{\theta}_{ML}) &= \mathbb{E}_{\theta}(X_{(n)}) = \int_0^{\theta} t f_{\theta}(t) dt = \int_0^{\theta} t \frac{nt^{n-1}}{\theta^n} dt = \int_0^{\theta} \frac{n}{\theta^n} t^n dt = \frac{n}{\theta^n} \Big|_0^{\theta} = \\ &= \frac{n}{\theta^n} \frac{\theta^{n+1}}{n+1} = \frac{n}{n+1} \theta < \theta\end{aligned}$$

- $Var_{\theta}(\hat{\theta}_{ML})$

$$\begin{aligned}Var_{\theta}(\hat{\theta}_{ML}) &= \mathbb{E}_{\theta}\left(\left(X_{(n)} - \frac{n}{n+1}\theta\right)^2\right) = \mathbb{E}_{\theta}(X_{(n)})^2 - \left(\frac{n}{n+1}\theta\right)^2 = \\ &= \int_0^{\theta} t^2 \frac{nt^{n-1}}{\theta^n} dt - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n}{\theta^n} \frac{t^{n+2}}{n+2} \Big|_0^{\theta} - \left(\frac{n}{n+1}\theta\right)^2 = \frac{n}{\theta^n} \frac{\theta^{n+2}}{n+2} - \left(\frac{n^2}{(n+1)^2}\theta^2\right) = \\ &= \frac{n}{n+2}\theta^2 - \left(\frac{n^2}{(n+1)^2}\theta^2\right) = \dots = \theta^2 \frac{n}{(n+1)^2(n+2)}\end{aligned}$$

- Also $MSE(\hat{\theta}_{ML}, \theta)$

$$\begin{aligned}MSE(\hat{\theta}_{ML}, \theta) &= \mathbb{E}\left((\hat{\theta}_{ML} - \theta)^2\right) = \theta^2 \frac{n}{(n+1)^2(n+2)} + \left(\frac{n}{n+1}\theta - \theta\right)^2 \\ &= \dots = \frac{2\theta^2}{(n+1)(n+2)} \xrightarrow{\text{wie } \frac{1}{n^2}} 0.\end{aligned}$$

Beispiel 1.18 (Beispiel aus Vorjahr)

X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma_0^2)$, $\mu_0 \in \mathbb{R}, \sigma_0^2 > 0$.

Hier ist der unbekannte Parameter $\theta_0 = \begin{pmatrix} \mu_0 \\ \sigma_0^2 \end{pmatrix} \in \Theta = \mathbb{R} \times (0, \infty)$.

Die Dichte von X_1 an der Stelle x ist

$$\Phi_{\mu_0, \sigma_0^2}(x) = \frac{1}{\sqrt{2\pi\sigma_0^2}} e^{-\frac{1}{2} \frac{(x-\mu_0)^2}{\sigma_0^2}}.$$

Für Beobachtungen x_1, \dots, x_n von X_1, \dots, X_n ist

$$\begin{aligned}L(\mu, \sigma^2) &= \prod_{i=1}^n \Phi_{\mu, \sigma^2}(x_i) \\ &= \prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2} \frac{(x_i - \mu)^2}{\sigma^2}} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}.\end{aligned}$$

$$l(\mu, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

Man sieht:

Für jeden festen Wert von σ^2 wird $l(\mu, \sigma^2)$ als Funktion von μ minimiert im Punkt $\mu = \bar{X}_n$. (Alternativ: Berechne $\frac{d}{d\mu} l(\mu, \sigma^2)$, Null setzen, nach μ auflösen.)
 $\mu = \bar{X}_n$ einsetzen ergibt

$$l(\bar{X}_n, \sigma^2) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \bar{X}_n)^2.$$

Um dies in σ^2 zu maximieren, setzt man die 1. Ableitung gleich 0:

$$\begin{aligned} \frac{dl(\bar{X}_n, \sigma^2)}{d\sigma^2} &= 0 - \frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \bar{X}_n)^2 \\ &= -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \bar{X}_n)^2. \end{aligned}$$

$$\begin{aligned} \frac{dl(\bar{X}_n, \sigma^2)}{d\sigma^2} &\stackrel{!}{=} 0 \\ \Leftrightarrow -\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \bar{X}_n)^2 &= 0 \\ \Leftrightarrow \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \bar{X}_n)^2 &= n \\ \Leftrightarrow \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X}_n)^2 &= \sigma^2 \\ &:= \tilde{\sigma}^2. \end{aligned}$$

Ist $\tilde{\sigma}^2$ ein Maximierer?

$$\begin{aligned} \frac{d^2 l(\bar{X}_n, \sigma^2)}{d(\sigma^2)^2} &= \frac{d}{d\sigma^2} \left(-\frac{n}{2} \frac{1}{\sigma^2} + \frac{1}{2} \frac{1}{\sigma^4} \sum_{i=1}^n (x_i - \bar{X}_n)^2 \right) \\ &= \frac{n}{2} \frac{1}{(\sigma^2)^2} - \frac{1}{2} 2 \frac{1}{(\sigma^2)^3} \sum_{i=1}^n (x_i - \bar{X}_n)^2 \\ &= \frac{n}{2} \frac{1}{(\sigma^2)^2} - \frac{n}{(\sigma^2)^3} \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X}_n)^2 \end{aligned}$$

Setzt man hier für σ^2 den Wert $\tilde{\sigma}^2$ ein, dann erhält man

$$\frac{n}{2} \frac{1}{(\tilde{\sigma}^2)^2} - \frac{n}{(\tilde{\sigma}^2)^3} \tilde{\sigma}^2 = \frac{n}{2} \frac{1}{(\tilde{\sigma}^2)^2} - \frac{n}{(\tilde{\sigma}^2)^2} = \frac{n}{\tilde{\sigma}^4} \left(\frac{1}{2} - 1 \right) < 0.$$

Also Maximum bei $\sigma^2 = \tilde{\sigma}^2$.

Damit ist der Maximum-Likelihood-Schätzer für $\begin{pmatrix} \mu_0 \\ \sigma_0^2 \end{pmatrix}$ gegeben durch

$$\begin{pmatrix} \hat{\mu}_{ML} \\ \hat{\sigma}_{ML}^2 \end{pmatrix} = \begin{pmatrix} \bar{X}_n \\ \frac{1}{n} \sum_{i=1}^n (x_i - \bar{X}_n)^2 \end{pmatrix}.$$

Beachte: Das ist auch ein Momentenmethoden-Schätzer für $\begin{pmatrix} \mu_0 \\ \sigma_0^2 \end{pmatrix}$.

Beispiel 1.19 (Capture/Recapture-Methode) (Beispiel aus Vorjahr)


Schätzung der Populationsgröße mit der Capture/Recapture Methode.

Gegeben eine Population von N Individuen.

Zur Vorbereitung des Experiments werden davon m Individuen markiert (Capture).

Im Experiment selbst werden n Individuen zufällig ausgewählt, und die Anzahl der davon markierten Individuen wird ermittelt (Recapture).

Modell:



N_0 ist unbekannt. $N_0 \geq \max\{m, n\}$, $N_0 \in \mathbb{N}$.

Es ist $\mathbb{E}(X) = \frac{m \cdot n}{N_0}$, also $N_0 = \frac{m \cdot n}{\mathbb{E}(X)}$.

Damit ist ein MM-Schätzer für N_0 gegeben durch

$$\hat{N}_{MM} = \frac{m \cdot n}{X}.$$

Beachte: Im Allgemeinen ist $\hat{N}_{MM} \notin \mathbb{N}$.

Suche nun ML-Schätzer.

Gegeben eine Beobachtung x von X ist

$$\begin{aligned} L(N) &= \mathbb{P}_N(X = x) \\ &= \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}}. \end{aligned}$$

$$\begin{aligned} D(N) &= \frac{L(N)}{L(N-1)} \\ &= \frac{\binom{m}{x} \binom{N-m}{n-x}}{\binom{N}{n}} \cdot \frac{\binom{N-1}{n}}{\binom{m}{x} \binom{N-1-m}{n-x}} \\ &= \frac{(N-m)!}{(n-x)!(N-m-n+x)!} \cdot \frac{n!(N-n)!}{N!} \cdot \frac{(N-1)!}{n!(N-1-n)!} \cdot \frac{(n-x)!(N-1-m-n+x)!}{(N-1-m)!} \\ &= \frac{(N-n)(N-m)}{N(N-m-n+x)}. \end{aligned}$$

Es ist

$$\begin{aligned}
 D(N) &> 1 \\
 \Leftrightarrow \frac{(N-n)(N-m)}{N(N-m-n+x)} &> 1 \\
 \Leftrightarrow (N-n)(N-m) &> N(N-m-n+x) \\
 \Leftrightarrow N^2 - nN - mN + mn &> N^2 - mN - nN + xN \\
 \Leftrightarrow N &< \frac{m \cdot n}{x}.
 \end{aligned}$$

Also:

- Für $N < \frac{m \cdot n}{x}$ ist $D(N) > 1$
- Für $N > \frac{m \cdot n}{x}$ ist $D(N) < 1$
- Für $N = \frac{m \cdot n}{x}$ ist $D(N) = 1$.

Zwei Fälle:

- Fall 1: $\frac{m \cdot n}{x} \notin \mathbb{N}$.

Wähle $N \in \mathbb{N}$, sodass $\frac{m \cdot n}{x} \in (N, N+1)$.

Damit ist $D(N) > 1$ und auch $D(\tilde{N}) > 1$ für alle $\tilde{N} < \frac{m \cdot n}{x}$.

Analog ist $D(N+1) < 1$ und auch $D(\tilde{N}) < 1$ für alle $\tilde{N} > \frac{m \cdot n}{x}$.

Schließlich ist $D(N+1) = \frac{L(N+1)}{L(N)} < 1$, also $L(N+1) < L(N)$.

Damit wird das Maximum von $L(\cdot)$ angenommen an der Stelle $N = \lfloor \frac{m \cdot n}{x} \rfloor$.

- Fall 2: $\frac{m \cdot n}{x} \in \mathbb{N}$.

Setze $N = \frac{m \cdot n}{x}$.

Wie im Fall 1 ist $D(\tilde{N}) > 1$ für $\tilde{N} < N$,

$D(\tilde{N}) < 1$ für $\tilde{N} > N$.

Schließlich ist $1 = D(N) = \frac{L(N)}{L(N-1)}$.

$\Rightarrow L(N) = L(N-1)$.

Hier wird $L(\cdot)$ maximiert an den Stellen $\frac{mn}{x}$ sowie $\frac{mn}{x} - 1$.

Zusammenfassend:

$$\hat{N}_{ML} = \lfloor \frac{mn}{x} \rfloor,$$

wobei \hat{N}_{ML} nicht eindeutig ist wenn $\frac{mn}{x} \in \mathbb{N}$.

1.4 Zulässigkeit, Effizienz und die Cramér-Rao-Schranke

Siehe zu diesem Kapitel S. 298-306. in *Rice (2007)*.



Was zeichnet einen "guten" Schätzer aus?

Betrachte durchwegs ein parametrisches Modell: X_1, \dots, X_n i.i.d. mit Dichte $f(x|\theta_0)$ (bzw. Wahrscheinlichkeitsfunktion $p(x|\theta_0)$ für $\theta \in \Theta \in \mathbb{R}^k$).

Gegeben einen Schätzer $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n) \in \mathbb{R}^k$ für θ_0 betrachtet man den **mittleren quadratischen Fehler**

$$MSE(\hat{\theta}_n, \theta_0) := \mathbb{E}_{\theta_0} \|\hat{\theta}_n - \theta_0\|^2 = \left(\sum_{i=1}^k \mathbb{E}_{\theta_0} (\hat{\theta}_n - \theta_0)_i^2 \right) = \sum_{i=1}^k MSE_{\theta_0} \left(((\hat{\theta}_n)_i, (\theta_0)_i)^2 \right)$$



Beachte: $MSE(\hat{\theta}_n, \theta)$ ist eine Funktion von θ .

Beim Vergleich zweier Schätzer $\hat{\theta}_n$ und $\tilde{\theta}_n$ muss man also die Funktionen $MSE(\hat{\theta}_n, \cdot)$ und $MSE(\tilde{\theta}_n, \cdot)$ vergleichen.

Beispiel 1.20	A	B	C	D
	4	2	1	2
	2	3	1	1
	1	1	1	1
	3	3	1	2

D ist besser als A.

A und B sind nicht vergleichbar.

C ist klassenbeste.

Im Folgenden sei κ eine Klasse von Schätzern für θ_0 , also Funktionen von X_1, \dots, X_n die Werte in Θ einnehmen. Oft ist κ die Klasse aller Schätzer bzw. die Klasse aller unverzerrter Schätzer.

Definition 1.4 Sei $\hat{\theta}$ ein Schätzer aus der Klasse κ .

- $\hat{\theta}$ heißt **unzulässig** (in der Klasse κ), wenn es einen Schätzer $\tilde{\theta}$ aus κ gibt sodass:
 $\forall \theta \in \Theta$ ist $MSE(\tilde{\theta}, \theta) \leq MSE(\hat{\theta}, \theta)$, und $\exists \theta \in \Theta$ sodass $MSE(\tilde{\theta}, \theta) < MSE(\hat{\theta}, \theta)$.
- $\hat{\theta}$ heißt **zulässig** (in der Klasse κ), wenn der vorherige Punkt nicht gilt.

Ist $\kappa = \{A, B, C, D\}$ dann ist C zulässig.

Ist $\kappa = \{A, D\}$ dann ist A unzulässig und D ist zulässig.

Ist $\kappa = \{A, B\}$ dann sind A und B beide zulässig.

Definition 1.5 Sei $\hat{\theta}$ ein Schätzer aus der Klasse κ . $\hat{\theta}$ heißt **effizient** (in der Klasse κ), wenn gilt:

$$\forall \theta \in \Theta \text{ ist } MSE(\hat{\theta}, \theta) = \min_{\tilde{\theta} \in \kappa} MSE(\tilde{\theta}, \theta).$$

Ist $\kappa = \{A, B, C, D\}$ dann ist C effizient.

Ist $\kappa = \{A, B, D\}$ dann ist D effizient.

Ist $\kappa = \{A, B\}$ dann sind niemand effizient.

Bemerkung: Effiziente Schätzer sind selten bekannt und müssen nicht unbedingt existieren. Aber es gibt einige Ausnahmen, die konzeptionell wichtig sind.
Oft kann man aber "asymptotisch effiziente" Schätzer finden. (für $n \rightarrow \infty$)



Bemerkung:



- effizient \Rightarrow zulässig; aber nicht umgekehrt.
- Diese beiden Begriffe hängen von κ und Θ ab.

Betrachte bis auf weiteres die Klasse κ der unverzerrten Schätzer.

Definition 1.6 Sei X eine Zufallsvariable X mit Dichte $f(x|\theta_0)$, $\theta_0 \in \Theta \subseteq \mathbb{R}^1$.
Die Größe

$$I(\theta_0) := \mathbb{E}_{\theta_0} \left[\left(\frac{d}{d\theta} \log f(x|\theta_0) \right)^2 \right]$$

ist die Fisher-Information (von X über θ_0), sofern diese wohldefiniert ist.

Satz 1.4 (Cramér-Rao-Schranke) Seien X_1, \dots, X_n i.i.d mit Dichte $f(x|\theta_0)$, $\theta_0 \in \Theta \subseteq \mathbb{R}^1$.
Weiters sei $\hat{\theta}$ ein unverzerrter Schätzer für θ_0 .
Dann gilt:

$$\text{Var}_{\theta_0}(\hat{\theta}) \geq \frac{1}{n_0 I(\theta_0)},$$

unter geeigneten Glattheitsbedingungen an $f(\cdot|\cdot)$, sodass die Schritte (*) und (**) im Beweis gültig sind.

Korollar 1.1 Ist $\hat{\theta}$ ein unverzerrter Schätzer für θ_0 , sodass $\forall \theta \in \Theta$, $\text{Var}_{\theta}(\hat{\theta}) = \frac{1}{nI(\theta)}$,
dann ist $\hat{\theta}$ effizient in der Klasse der unverzerrten Schätzer.

Es gibt auch eine multivariate Version der Cramér-Rao-Schranke, also für unverzerrte Schätzer, wo θ_0 hochdimensional sein kann.



Beweis. Setze $Z = \sum_{i=1}^n \frac{d}{d\theta} \log f(x_i|\theta_0)$.

Es gilt $|\text{Corr}_{\theta_0}(Z, \hat{\theta})| \leq 1$, also $\frac{\text{Cov}_{\theta_0}(Z, \hat{\theta})^2}{\text{Var}_{\theta_0}(Z) \text{Var}_{\theta_0}(\hat{\theta})} \leq 1$, bzw. $\frac{\text{Cov}_{\theta_0}(Z, \hat{\theta})^2}{\text{Var}_{\theta_0}(Z)} \leq \text{Var}_{\theta_0}(\hat{\theta})$.

Zu zeigen:

- $\text{Cov}_{\theta_0}(Z, \hat{\theta}) = 1$
- $\text{Var}_{\theta_0}(Z) = nI(\theta_0)$.

$$\begin{aligned}
\mathbb{E}_{\theta_0}(Z_i) &\stackrel{i.i.d.}{=} n\mathbb{E}_{\theta_0}\left(\frac{d}{d\theta}\log f(x_1|\theta_0)\right) \\
&= n\mathbb{E}_{\theta_0}\left(\frac{d}{d\theta}\bigg|_{\theta=\theta_0}\log f(x_1|\theta_0)\right) \\
&= n\int \frac{d}{d\theta}\bigg|_{\theta=\theta_0}\log f(x|\theta)f(x|\theta_0)dx \\
&= n\int \frac{\frac{d}{d\theta}\big|_{\theta=\theta_0}f(x|\theta)}{f(x|\theta_0)}f(x|\theta_0)dx \\
&= n\int \frac{d}{d\theta}\bigg|_{\theta=\theta_0}f(x|\theta)dx \\
&\stackrel{(*)}{=} \underbrace{n\frac{d}{d\theta}\bigg|_{\theta=\theta_0}\underbrace{\int f(x|\theta)dx}_{=1}}_{=0} = n \cdot 0 = 0.
\end{aligned}$$

Man sieht damit auch, dass $\mathbb{E}_{\theta_0}\left(\frac{d}{d\theta}\bigg|_{\theta=\theta_0}\log f(x_1|\theta)\right) = 0$ ist.

$$\begin{aligned}
\text{Var}_{\theta_0}(Z) &= \sum_{i=1}^n \text{Var}_{\theta_0}\left(\frac{d}{d\theta}\log f(x_1|\theta_0)\right) \\
&= n\text{Var}_{\theta_0}\left(\frac{d}{d\theta}\log f(x_1|\theta_0)\right) \\
&= n\mathbb{E}_{\theta_0}\left(\left(\frac{d}{d\theta}\log f(x_1|\theta_0)\right)^2\right) \\
&= nI(\theta_0).
\end{aligned}$$

Damit ist (ii) gezeigt. ✓

$$\begin{aligned}
\text{Cov}_{\theta_0}(Z, \hat{\theta}) &= \mathbb{E}_{\theta_0}(Z \hat{\theta}) - \overbrace{\mathbb{E}_{\theta_0}(Z) \mathbb{E}_{\theta_0}(\hat{\theta})}^{=0} \\
&= \underbrace{\int \dots \int}_{n\text{-mal}} \hat{\theta}(x_1, \dots, x_n) \left(\sum_{i=1}^n \frac{d}{d\theta} \log f(x_i | \theta_0) \right) \prod_{j=1}^n f(x_j | \theta_0) dx_1, \dots, dx_n \\
&= \int \dots \int \hat{\theta}(x_1, \dots, x_n) \left(\sum_{i=1}^n \frac{\frac{d}{d\theta} f(x_i | \theta_0)}{f(x_i | \theta_0)} \right) \prod_{j=1}^n f(x_j | \theta_0) dx_1, \dots, dx_n \\
&= \int \dots \int \hat{\theta}(x_1, \dots, x_n) \left(\sum_{i=1}^n \frac{d}{d\theta} f(x_i | \theta_0) \right) \prod_{j=1, i \neq j}^n f(x_j | \theta_0) dx_1, \dots, dx_n \\
&= \int \dots \int \hat{\theta}(x_1, \dots, x_n) \frac{d}{d\theta} \Big|_{\theta=\theta_0} \prod_{j=1}^n f(x_j | \theta_0) dx_1, \dots, dx_n \\
&\stackrel{(\times \times)}{=} \frac{d}{d\theta} \Big|_{\theta=\theta_0} \int \dots \int \hat{\theta}(x_1, \dots, x_n) \prod_{j=1}^n f(x_j | \theta_0) dx_1, \dots, dx_n \\
&= \frac{d}{d\theta} \Big|_{\theta=\theta_0} \mathbb{E}_{\theta_0}(\hat{\theta}) \\
&= \frac{d}{d\theta} \Big|_{\theta=\theta_0} \theta \\
&= 1.
\end{aligned}$$

Also gilt auch (i). ✓

□

Eine alternative Formel für $I(\theta_0)$:

Lemma 1.2 Die **Fisher-Information** lässt sich auch berechnen als

$$I(\theta) = -\mathbb{E}(\theta) \left(\frac{d^2}{d\theta^2} \log f(x|\theta) \right)$$

unter geeigneten Glattheitsbedingungen, sodass Schritte (a) und (b) im Beweis zulässig sind.

Beweis. Für jedes $\theta \in \Theta$ ist $\int f(x|\theta)dx = 1$.

$$\begin{aligned}
 0 &= \frac{d}{d\theta} \int f(x|\theta)dx \\
 &\stackrel{(a)}{=} \int \frac{d}{d\theta} f(x|\theta)dx \\
 &= \int \underbrace{\frac{\frac{d}{d\theta} f(x|\theta)}{f(x|\theta)}}_{\left(\frac{d}{d\theta} \log f(x|\theta)\right)} f(x|\theta)dx \\
 &= \int \left(\frac{d}{d\theta} \log f(x|\theta) \right) f(x|\theta)dx = (c). \\
 \Rightarrow 0 &= \frac{d}{d\theta} (c) \\
 &= \frac{d}{d\theta} \int \left(\frac{d}{d\theta} \log f(x|\theta) \right) f(x|\theta)dx \\
 &\stackrel{(b)}{=} \int \left(\frac{d^2}{d\theta^2} \log f(x|\theta) \right) f(x|\theta) + \left(\frac{d}{d\theta} \log f(x|\theta) \right) \underbrace{\frac{d}{d\theta} f(x|\theta)}_{\stackrel{s.o}{=} \left(\frac{d}{d\theta} \log f(x|\theta) \right) f(x|\theta)} dx \\
 &= \int \left(\frac{d^2}{d\theta^2} \log f(x|\theta) \right) f(x|\theta)dx + \int \left(\frac{d}{d\theta} \log f(x|\theta) \right)^2 f(x|\theta)dx \\
 &= \mathbb{E}_\theta \left(\frac{d^2}{d\theta^2} \log f(X|\theta) \right) + \underbrace{\mathbb{E}_\theta \left(\left(\frac{d}{d\theta} \log f(X|\theta) \right)^2 \right)}_{=I(\theta)} \\
 \Rightarrow I(\theta) &= -\mathbb{E}_{\theta_0} \left(\frac{d^2}{d\theta^2} \log f(X|\theta) \right).
 \end{aligned}$$

□



Bemerkung: Die Cramér-Rao-Schranke gilt auch für diskrete Zufallsvariablen:

Sind X_1, \dots, X_n i.i.d. diskrete Zufallsvariablen, verteilt wie X , mit Wahrscheinlichkeitsfunktion $p(x|\theta)$, $\theta \in \Theta \subseteq \mathbb{R}$, und ist $\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n)$ ein unverzerrter Schätzer für θ , dann gilt

$$\text{Var } \hat{\theta}_n \geq \frac{1}{nI(\theta)},$$

unter analogen Glattheitsbedingungen wie im letzten Satz.

Details: Siehe Übung.

Beispiel 1.21 (Bernoulli-Verteilung) Seien X_1, \dots, X_n i.i.d $B(p_0)$, $0 < p_0 < 1$.

Wissen: $\hat{p}_{ML} = \bar{X}_n = \hat{p}_{MM} = \frac{1}{n} \sum_{i=1}^n x_i$

ist unverzerrt für p_0 mit Varianz $\text{Var}_{p_0}(\bar{X}_n) = \frac{\text{Var}_{p_0}(X_1)}{n} = \frac{p_0(1-p_0)}{n}$.

$$p(x|p_0) = \begin{cases} p_0 & : x = 1, \\ 1 - p_0 & : x = 0 \end{cases}$$

$$= p_0^x (1 - p_0)^{1-x}, \quad x \in \{0, 1\}, \quad 0 < p_0 < 1.$$

$$\begin{aligned} \frac{d}{dp_0} \log p(x|p_0) &= \frac{d}{dp_0} (x \log p_0 + (1-x) \log(1-p_0)) \\ &= x \frac{1}{p_0} + (1-x) \frac{-1}{1-p_0} = \frac{x}{p_0} + \frac{1-x}{1-p_0} \end{aligned}$$

$$\begin{aligned} I(p_0) &= \mathbb{E}_{p_0} \left(\left(\frac{X}{p_0} + \frac{1-X}{1-p_0} \right)^2 \right) \\ &= \frac{1}{p_0^2} p_0 + \frac{1}{(1-p_0)^2} (1-p_0) \\ &= \frac{1}{p_0} + \frac{1}{1-p_0} = \frac{1-p_0+p_0}{p_0(1-p_0)} \\ &= \frac{1}{p_0(1-p_0)}. \end{aligned}$$

Die Cramér-Rao-Schranke in diesem Modell ist also

$$\frac{1}{nI(p_0)} = \frac{p_0(1-p_0)}{n} = \text{Var}_{p_0}(\bar{X}_n)$$

Der Schätzer \bar{X}_n für p_0 ist also effizient (in der Klasse der unverzerrten Schätzer) !

Beispiel 1.22 (Exponentialverteilung) X_1, \dots, X_n i.i.d. verteilt wie X , wobei X eine stetige Zufallsvariable ist mit $X \sim E_{\lambda}(\lambda_0)$, $\lambda_0 > 0$.

Dichte $f(x|\lambda_0) = \lambda_0 e^{-\lambda_0 x}$, ($x > 0$).

$\log f(x|\lambda_0) = \log \lambda_0 - \lambda_0 x$.

$\frac{d}{d\lambda} \log f(x|\lambda_0) = \frac{1}{\lambda_0} - x$.

Erinnerung: $E_{\lambda_0}(X) = \frac{1}{\lambda_0}$, $\text{Var}_{\lambda_0}(X) = \frac{1}{\lambda_0^2}$

$$\begin{aligned} I(\lambda_0) &= \mathbb{E}_{\lambda_0} \left(\left(\frac{d}{d\lambda} \log f(x|\lambda_0) \right)^2 \right) \\ &= \mathbb{E}_{\lambda_0} \left(\left(\frac{1}{\lambda_0} - X \right)^2 \right) = \text{Var}_{\lambda_0}(X) = \frac{1}{\lambda_0^2}. \end{aligned}$$

Cramér-Rao-Schranke:

$$\frac{1}{(nI(\lambda_0))} = \frac{\lambda_0^2}{n}.$$

Wissen: Der Schätzer $\frac{1}{\bar{X}_n} = \frac{1}{\frac{1}{n} \sum_{i=1}^n X_i} = \hat{\lambda}_{MM} = \hat{\lambda}_{ML}$

Aber dieser Schätzer ist verzerrt! Cramer-Rao-Schranke nicht anwendbar!

Beispiel 1.23 (Uparametrisierung der Exponentialverteilung) X_1, \dots, X_n i.i.d. $\text{Exp}\left(\frac{1}{\theta_0}\right)$, $\theta_0 > 0$.

Wissen: $\mathbb{E}_{\theta_0}(X) = \frac{1}{\theta_0} = \theta_0$, $\text{Var}_{\theta_0}(X) = \left(\frac{1}{\theta_0}\right)^2 = \theta_0^2$.

Dichte: $f(x|\theta_0) = \frac{1}{\theta_0} e^{-\frac{x}{\theta_0}}$, ($x > 0$).

$\log f(x|\theta_0) = -\log \theta_0 - \frac{x}{\theta_0}$.

$\frac{d}{d\theta_0} \log f(x|\theta_0) = -\frac{1}{\theta_0} + \frac{x}{\theta_0^2}$.

$$\begin{aligned} I(\theta_0) &= \mathbb{E}_{\theta_0} \left(\left(\frac{d}{d\theta_0} \log f(x|\theta_0) \right)^2 \right) \\ &= \mathbb{E}_{\theta_0} \left(\left(\frac{X - \theta_0}{\theta_0^2} \right)^2 \right) \\ &= \frac{1}{\theta_0^4} \mathbb{E}_{\theta_0} ((X - \theta_0)^2) \\ &= \frac{1}{\theta_0^4} \text{Var}_{\theta_0}(X) \\ &= \frac{1}{\theta_0^4} \theta_0^2 = \frac{1}{\theta_0^2}. \end{aligned}$$

Cramér-Rao-Schranke:

$$\frac{1}{(nI(\theta_0))} = \frac{\theta_0^2}{n}.$$

Beachte \bar{X}_n : $\mathbb{E}_{\theta_0}(\bar{X}_n) = \mathbb{E}_{\theta_0}(X) = \theta_0$,

$\text{Var}_{\theta_0}(\bar{X}_n) = \frac{\text{Var}_{\theta_0}(X_1)}{n} = \frac{\theta_0^2}{n}$.

Der Schätzer \bar{X}_n für θ_0 ist also unverzerrt und erreicht die Cramer-Rao-Schranke. \bar{X}_n ist effizient (in der Klasse der unverzerrten Schätzer).



Bemerkung: Die Effizienz von Schätzern kann von der Parametrisierung abhängen.

Beispiel 1.24 (Normalverteilung - Varianz bekannt) X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma^2)$, $\mu_0 \in \mathbb{R}$, $\sigma^2 > 0$ bekannt.

Wissen: $\bar{X}_n = \hat{\mu}_{ML} = \hat{\mu}_{MM}$ ist unverzerrt mit $\text{Var}_{\mu}(\bar{X}_n) = \frac{\sigma^2}{n}$.

Dichte: $f(x|\mu_0) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2\sigma^2}(x-\mu_0)^2}$.

$\log f(x|\mu_0) = -\frac{1}{2} \log(2\pi\sigma^2) - \frac{1}{2\sigma^2}(x-\mu_0)^2$.

$\frac{d}{d\mu_0} \log f(x|\mu_0) = \frac{1}{2\sigma^2} 2(x-\mu_0) = \frac{x-\mu_0}{\sigma^2}$.

$$\begin{aligned}
 I(\mu_0) &= \mathbb{E}_{\mu_0} \left(\left(\frac{d}{d\mu_0} \log f(X|\mu_0) \right)^2 \right) \\
 &= \mathbb{E}_{\mu_0} \left(\left(\frac{X - \mu_0}{\sigma^2} \right)^2 \right) \\
 &= \frac{1}{\sigma^4} \text{Var}_{\mu_0}(X) \\
 &= \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}.
 \end{aligned}$$

Cramér-Rao-Schranke:

$$\frac{1}{nI(\mu_0)} = \frac{\sigma^2}{n} = \text{Var}_{\mu_0}(\bar{X}_n).$$

\bar{X}_n ist damit effizient (in der Klasse der unverzerrten Schätzer).

Bemerkung: \bar{X}_n ist effizient in der Klasse

$$\kappa_+ = \left\{ \hat{\mu} = \hat{\mu}_n(X_1, \dots, X_n, \sigma^2) : \hat{\mu}_n \text{ unverzerrt} \right\}$$

\bar{X}_n hängt nicht von σ^2 ab.



Beispiel 1.25 (Normalverteilung - Beide unbekannt) X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma_0^2)$, $\mu_0 \in \mathbb{R}$, $\sigma_0^2 > 0$.

Sei κ die Klasse aller unverzerrten Schätzer für μ_0 :

$$\kappa = \left\{ \hat{\mu} = \hat{\mu}_n(X_1, \dots, X_n) : \hat{\mu}_n \text{ unverzerrt} \right\}$$

Wissen:

- (1) $\bar{X}_n \in \kappa$ (unverzerrt),
- (2) $\text{Var}_{\mu_0}(\bar{X}_n) = \min_{\hat{\mu}_n \in \kappa_+} \text{Var}_{\mu_0}(\hat{\mu}_n)$,
- (3) $\kappa \subseteq \kappa_+$.

Also:

$$\begin{aligned}
 \text{Var}_{\mu_0, \sigma_0^2}(\bar{X}_n) &= \min_{(2) \hat{\mu}_n \in \kappa_+} \text{Var}_{\mu_0, \sigma_0^2}(\hat{\mu}_n) \\
 &\leq \min_{(3) \hat{\mu}_n \in \kappa} \text{Var}_{\mu_0, \sigma_0^2}(\hat{\mu}_n) \\
 &\stackrel{(1)}{\leq} \text{Var}_{\mu_0, \sigma_0^2}(\bar{X}_n).
 \end{aligned}$$

$$\Rightarrow \text{Var}_{\mu_0, \sigma_0^2}(\bar{X}_n) = \min_{\hat{\mu}_n \in \kappa} \text{Var}_{\mu_0, \sigma_0^2}(\hat{\mu}_n)$$

Also ist \bar{X}_n effizient für μ_0 auch im Fall unbekannter Varianz. (in der Klasse κ).

Bemerkung: Es gibt eine Version der Cramér-Rao-Schranke für mehr-dimensionale Parameter θ_0 und für den Fall wo die X_1, \dots, X_n Zufallsvektoren sind.

Insbesondere gilt:

Sei X_1, \dots, X_n i.i.d. Zufallsvektoren mit $X_1 \sim N(\mu, \sigma^2 I_p)$ mit $\mu_0 \in \mathbb{R}^p$, $\sigma_0^2 > 0$ (p-dimensional), dann ist \bar{X}_n effizient (in der Klasse der unverzerrten Schätzer für μ_0).



Betrachte nun auch möglicherweise verzerrte Schätzer.

Proposition 1.1 Betrachte $X \sim N(\mu_0, I_p)$ mit $\mu_0 \in \mathbb{R}^p$. Der Maximum-Likelihood-Schätzer $\hat{\mu}_{ML} = X$ für μ_0 ist zulässig in der Klasse aller Schätzer für μ_0 , wenn $p = 1, 2$.

(Ohne Beweis).

? Was passiert für $p \geq 3$?



Überraschung: (James, Stein, 1961)

Für $X \sim N(\mu_0, I_p)$, $\mu_0 \in \mathbb{R}^p$, $p \geq 3$, gibt es einen Schätzer $\hat{\mu}_{JS}$ für μ_0 , sodass gilt:

$$\forall \mu_0 \in \mathbb{R}^p: \underbrace{MSE(\hat{\mu}_{JS}, \mu_0)}_{\text{J-S-Schätzer}} < \underbrace{MSE(X, \mu_0)}_{\text{ML-Schätzer}}$$

$$MSE(\hat{\mu}_{JS}, 0) = 2, \quad MSE(X, 0) = p.$$

Dieser Schätzer ist gegeben durch

$$\hat{\mu}_{JS} = \underbrace{\left(1 - \frac{p-2}{X'X}\right)}_{\text{Kontraktionsfaktor} \leq 1} \underbrace{X}_{\text{ML-Schätzer}}$$

Insbesondere ist der Maximum-Likelihood-Schätzer in diesem Modell unzulässig wenn $p \geq 3$.



Bemerkung:

In der Praxis wird der James-Stein-Schätzer fast nie verwendet. Aber als so genannter Shrinkage-Schätzer lieferte $\hat{\mu}_{JS}$ die Inspiration für zahlreiche moderne Methoden wie LASSO, SVM, LARS, Dantzig-Selektor, ...

Zur Motivation des James-Stein-Schätzers:

$$X \sim N(\mu, I_p), \quad \hat{\mu}_{JS} = \left(1 - \frac{p-2}{X'X}\right)X, \quad (p \geq 3).$$

Betrachte eine Approximation, wo $p \rightarrow \infty$ geht, wobei

$$\begin{array}{ccc} \text{Signal} \rightarrow & \frac{\|\mu\|^2}{\underbrace{p}_{\text{Noise}}} & \xrightarrow{p \rightarrow \infty} \rho^2 > 0 \in [0, 1]. \\ & \text{singal-to-noise ratio} & \end{array}$$


Zerlege X als $X = \mu + \epsilon$ (für $\epsilon = X - \mu$), sodass $\epsilon \sim N(0, I_p)$.




Beachte: Als Schätzer für μ ist X (im Mittel) "zu lang":

$$\begin{aligned}
 \text{Länge von } \mu &: \|\mu\|^2 \\
 \text{Länge von } X &: \mathbb{E}(\|X\|^2) = \mathbb{E}(X'X) \\
 &= \mathbb{E}((\mu + \epsilon)'(\mu + \epsilon)) \\
 &= \mathbb{E}(\mu'\mu + 2\mu'\epsilon + \epsilon'\epsilon) \\
 &= \mu'\mu + 0 + \underbrace{\mathbb{E}(\epsilon'\epsilon)}_{\mathbb{E}(\sum_{i=1}^p \epsilon_i^2) = p} \\
 &= \mu'\mu + p > \mu'\mu!
 \end{aligned}$$

Betrachte das Dreieck $0, \mu, X$ bzw. $0, \frac{1}{\sqrt{p}}\mu, \frac{1}{\sqrt{p}}X$:



Approximatives Dreieck ($p \rightarrow \infty$) (rechtwinklig):



$$\begin{aligned}
 \left\| \frac{1}{\sqrt{p}}\mu \right\|^2 &= \frac{\mu'\mu}{p} \rightarrow \rho^2. \\
 \left\| \frac{1}{\sqrt{p}}\epsilon \right\|^2 &= \frac{1}{p}\epsilon'\epsilon = \frac{1}{p}\sum_{i=1}^p \epsilon_i^2 \xrightarrow{p} 1 \text{ (LLN)}. \\
 \left\| \frac{1}{\sqrt{p}}X \right\|^2 &= \frac{1}{p}(\mu + \epsilon)'(\mu + \epsilon) = \underbrace{\frac{1}{p}\mu'\mu}_{\rightarrow \rho^2} + \underbrace{\frac{2}{p}\mu'\epsilon}_{(*)} + \underbrace{\frac{1}{p}\epsilon'\epsilon}_{\xrightarrow{p} 1} \xrightarrow{p} \rho^2 + 1.
 \end{aligned}$$

$(*) \sim N\left(0, \frac{4}{p^2}\mu'\mu\right)$, da $\text{Var}(\mu'\epsilon) = \mu' \text{VC}(\epsilon)\mu = \mu'\mu$.

Damit gilt: Für $c > 0$ ist

$$\begin{aligned}
 \mathbb{P}\left(\left|\frac{2}{p}\mu'\epsilon\right| > c\right) &\stackrel{\text{Chebyshev}}{\leq} \frac{1}{c^2} \text{Var}\left(\frac{2}{p}\mu'\epsilon\right) \\
 &= \frac{1}{c^2} \frac{4}{p^2} \mu'\mu \\
 &= \frac{4}{c^2} \underbrace{\frac{\mu'\mu}{p}}_{\rightarrow \frac{4}{c^2}\rho^2} \underbrace{\frac{1}{p}}_{\rightarrow 0} \\
 &\xrightarrow{p \rightarrow \infty} 0.
 \end{aligned}$$

Also ist $(*) = \frac{2}{p}\mu'\epsilon \xrightarrow{p} 0$.

Das legt nahe, dass $\epsilon, \mu \rightarrow 0$ strebt.

Nachrechnen: Betrachte den Cosinus des Winkels:

$$\begin{aligned} \frac{\mu' \epsilon}{\|\mu\| \cdot \|\epsilon\|} &= \frac{\frac{1}{p} \mu' \epsilon}{\|\frac{1}{\sqrt{p}} \mu\| \cdot \|\frac{1}{\sqrt{p}} \epsilon\|} = \frac{\frac{1}{p} \mu' \epsilon}{\left(\frac{\mu' \mu}{p}\right)^{\frac{1}{2}} \left(\frac{\epsilon' \epsilon}{p}\right)^{\frac{1}{2}}} \rightarrow \frac{0}{(\rho^2)^{\frac{1}{2}} (1)^{\frac{1}{2}}} = 0. \\ a^2 - (\alpha c)^2 &= b^2 - ((1 - \alpha)c)^2 \\ a^2 - \alpha^2 c^2 &= b^2 - (c^2 - 2\alpha c^2 + \alpha^2 c^2) \\ a^2 - \alpha^2 c^2 &= b^2 - c^2 + 2\alpha c^2 - \alpha^2 c^2 \\ \frac{a^2 - b^2 + c^2}{2c^2} &= \alpha. \\ \Rightarrow \alpha &= \frac{a^2 - b^2 + c^2}{2c^2} = \frac{2a^2}{2c^2} = \frac{c^2 - b^2}{c^2} = 1 - \frac{b^2}{c^2}. \end{aligned}$$

Im Dreieck $0, \mu, X$ ist

$$\begin{aligned} \alpha &= 1 - \frac{\epsilon' \epsilon}{X' X} \\ &= 1 - \frac{p}{X' X} \underbrace{\frac{1}{p} \epsilon' \epsilon}_{\xrightarrow{p} 1} \\ &\approx 1 - \frac{p}{X' X}. \end{aligned}$$

Das legt folgenden Schätzer für μ nahe:

$$\tilde{\mu} = \left(1 - \frac{p}{X' X}\right) X$$

- Das ist (fast) der James-Stein-Schätzer.

Fehler von X : $\|\mu - X\|^2 = \epsilon' \epsilon$.

Fehler von $\tilde{\mu}$: $\|\tilde{\mu} - X\|^2$.

Relativer Fehler:

$$\frac{\|\tilde{\mu} - X\|^2}{\|X - \mu\|^2} = \frac{\frac{1}{p} \|\tilde{\mu} - X\|^2}{\frac{1}{p} \|X - \mu\|^2} \xrightarrow{p} 1 - \frac{1}{1 + \rho^2} < 1$$

... hängt nur von $\rho^2 \approx \frac{\|\mu\|^2}{p}$ ab.

Es gilt sogar:

$\frac{MSE(\tilde{\mu}, \mu)}{MSE(X, \mu)}$ bzw. $\frac{MSE(\hat{\mu}_{JS}, \mu)}{MSE(X, \mu)}$ hängen von μ nur über $\|\mu\|^2$ bzw. $\frac{\|\mu\|^2}{p}$ ab.

1.5 Das Verhalten von ML-Schätzer in großen Stichproben



Siehe zu diesem Kapitel S. 274-279 in Rice (2007).

Kurz gesagt: Unter geeigneten Voraussetzungen sind Maximum-Likelihood-Schätzer konsistent, asymptotisch normalverteilt, und "asymptotisch effizient".

Betrachte durchwegs $X_i, i \geq 1$, i.i.d. mit Dichte (bzw. Wahrscheinlichkeitsfunktion)

$$f(x|\theta_0), \theta_0 \in \Theta \subseteq \mathbb{R}, 1 - \dim$$

und für die Stichprobe der Größe n den Maximum-Likelihood-Schätzer

$$\hat{\theta}_n = \hat{\theta}_n(X_1, \dots, X_n).$$

Satz 1.5 (Konsistenz) Unter geeigneten Voraussetzungen an $f(\cdot|\cdot)$ ist der Maximum-Likelihood-Schätzer $\hat{\theta}_n$ konsistent:

$$\hat{\theta}_n \xrightarrow{p} \theta_0,$$

für jeden Wert des wahren Parameters $\theta_0 \in \Theta$.

Beweisidee. $\hat{\theta}_n$ maximiert $l_n(\theta) = \prod_{i=1}^n f(X_i|\theta)$ bzw. $l_n(\theta) = \frac{1}{n} \sum_{i=1}^n \underbrace{\log f(X_i|\theta)}_{iid \text{ mit } \mathbb{E}_{\theta_0}(\log f(X_i|\theta))}$ bzw.

$\frac{1}{n} l_n(\theta)$ für jedes $\theta \in \Theta$.

Mit dem Gesetz der großen Zahlen gilt

$$l_n(\theta) \xrightarrow{p} \mathbb{E}_{\theta_0}(\log f(X_1|\theta)) := l_\infty(\theta).$$

für jedes $\theta \in \Theta$.

Idee:

$$\underbrace{\text{Maximierer von } \frac{1}{n} l_n(\theta)}_{\hat{\theta}_n} \approx \underbrace{\text{Maximierer von } l_\infty(\theta)}_{=\theta_0 \text{ (siehe unten)}}$$

? Maximierer von $l_\infty(\theta)$ = ?

$$\begin{aligned} \frac{d}{d\theta} l_\infty(\theta) &= \frac{d}{d\theta} \int \log f(x|\theta) \underbrace{f(x|\theta_0)}_{\text{dichte an der Stelle } \theta_0} dx \\ &= \int \frac{d}{d\theta} \log f(x|\theta) \cdot f(x|\theta_0) dx \\ &= \int \frac{\frac{d}{d\theta} f(x|\theta)}{f(x|\theta)} \cdot f(x|\theta_0) dx = (*). \end{aligned}$$

Für $\theta = \theta_0$ ist also

$$\begin{aligned} \frac{d}{d\theta} l_\infty(\theta_0) &= \frac{d}{d\theta} l_\infty(\theta) \Big|_{\theta=\theta_0} \\ (*) &= \int \frac{\frac{d}{d\theta} f(x|\theta_0)}{\cancel{f(x|\theta_0)}} \cancel{f(x|\theta_0)} dx \\ &= \int \frac{d}{d\theta} f(x|\theta_0) dx \\ &= \frac{d}{d\theta} \underbrace{\int f(x|\theta_0) dx}_{=1} \Big|_{\theta=\theta_0} \\ &= 0. \end{aligned}$$

? Ist θ_0 ein Maximierer für $l_\infty(\theta)$?

$$\begin{aligned}
 & \frac{d^2}{d\theta^2} \frac{d}{d\theta} \int \log f(x|\theta) f(x|\theta_0) dx = \\
 & = \int \frac{d^2}{d\theta^2} \log f(x|\theta) \cdot f(x|\theta_0) dx \Big|_{\theta=\theta_0} \\
 & = \int \frac{d^2}{d\theta^2} \log f(x|\theta_0) \cdot f(x|\theta_0) dx \\
 & = \mathbb{E}_{\theta_0} \left(\frac{d^2}{d\theta^2} \log f(X_1|\theta_0) \right) \\
 & = -I(\theta_0) \leq 0.
 \end{aligned}$$

Im nicht-trivialen Fall (stetige Zufallsvariablen), wo $I(\theta_0) > 0$ ist also θ_0 ein Maximierer von $l_\infty(\theta)$.

Weitere Details zum Beweis folgen im Masterstudium.

Für diskrete Zufallsvariablen funktioniert analog. □

Satz 1.6 (Asymptotische Normalität) Unter geeigneten Voraussetzungen an $f(\cdot)$, gilt:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{w} N\left(0, \frac{1}{I(\theta_0)}\right);$$

Beweisidee. (Für Stetige Zufallsvariablen, diskrete analog) $\hat{\theta}_n$ maximiert $l_n(\theta) = \sum_{i=1}^n \log f(X_i|\theta)$.

$$\begin{aligned}
 \Rightarrow 0 &= \frac{d}{d\theta} l_n(\theta) \Big|_{\theta=\hat{\theta}_n} \\
 &= \frac{d}{d\theta} l_n(\hat{\theta}_n) = l'_n(\hat{\theta}_n) \\
 &\approx l'_n(\theta_0) + (\hat{\theta}_n - \theta_0) l''_n(\theta_0) + \text{Rest.}
 \end{aligned}$$

Taylor-Entwicklung der
Ordnung 1 im Punkt θ_0

$$\begin{aligned}
 \Rightarrow \hat{\theta}_n - \theta_0 &\approx \frac{l'_n(\theta_0)}{-l''_n(\theta_0)} = \frac{\frac{1}{n} l'_n(\theta_0)}{-\frac{1}{n} l''_n(\theta_0)} \\
 \Rightarrow \sqrt{n}(\hat{\theta}_n - \theta_0) &\approx \frac{\sqrt{n} l'_n(\theta_0) \frac{1}{n}}{-l''_n(\theta_0) \frac{1}{n}} = \frac{\frac{1}{\sqrt{n}} l'_n(\theta_0)}{-\frac{1}{n} l''_n(\theta_0)} \quad (*)
 \end{aligned}$$

$$\begin{aligned}
 \frac{1}{\sqrt{n}} l'_n(\theta_0) &= \frac{1}{\sqrt{n}} \sum_{i=1}^n \underbrace{\frac{d}{d\theta} \log f(X_i|\theta) \Big|_{\theta=\theta_0}}_{\substack{\frac{d}{d\theta} \log f(X_i|\theta_0) \\ \text{i.i.d. mit E-Wert=0 und Varianz} \\ \mathbb{E}_{\theta_0} \left(\left(\frac{d}{d\theta} \log f(X_1|\theta_0) \right)^2 \right) = I(\theta_0)}}
 \end{aligned}$$

$\xrightarrow{w} N(0, I(\theta_0))$ wegen dem zentralen Grenzwertsatz.

$$\begin{aligned}
-\frac{1}{n}l_n''(\theta_0) &= \frac{1}{n}l_n''(\theta_0) \\
&= \frac{1}{n} \sum_{i=1}^n \underbrace{\left(-\frac{d^2}{d\theta^2} \log f(X_i|\theta_0) \right)}_{\substack{\text{i.i.d. mit E-Wert} \\ -\mathbb{E}_{\theta_0} \left(\frac{d^2}{d\theta^2} \log f(X_1|\theta_0) \right) = I(\theta_0)}} \\
&\xrightarrow{p} I(\theta_0) \text{ wegen dem Gesetz der großen Zahlen.}
\end{aligned}$$

Falls $I(\theta_0)$ folgt auch dass

$$\frac{1}{-\frac{1}{n}l_n''(\theta_0)} \xrightarrow{p} \frac{1}{I(\theta_0)}.$$

Also:

$$\frac{\frac{1}{\sqrt{n}}l_n'(\theta_0)}{-\frac{1}{n}l_n''(\theta_0)} = \underbrace{\frac{1}{\sqrt{n}}l_n'(\theta_0)}_{\xrightarrow{w} N(0, I(\theta_0))} \cdot \underbrace{\frac{1}{-\frac{1}{n}l_n''(\theta_0)}}_{\xrightarrow{p} \frac{1}{I(\theta_0)}}$$


Mit den Rechenregeln für \xrightarrow{p} und \xrightarrow{w} ergibt sich, dass

$$\frac{\frac{1}{\sqrt{n}}l_n'(\theta_0)}{-\frac{1}{n}l_n''(\theta_0)} \xrightarrow{w} N\left(0, \frac{1}{I(\theta_0)}\right).$$

Wenn der Approximationsfehler in $(*)$ für $n \rightarrow \infty$ vernachlässigbar ist, dann folgt daraus auch, dass

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{w} N\left(0, \frac{1}{I(\theta_0)}\right).$$


Weitere Details folgen im Masterstudium. □

Bemerkung: Für Inferenz über θ_0 benötigt man noch einen konsistenten Schätzer für $\frac{1}{I(\theta_0)}$ bzw. $I(\theta_0)$, der für $I(\theta_0)$ (unter geeigneten Voraussetzungen) gegeben ist durch 

$$\hat{I} = -\frac{1}{n} \sum_{i=1}^n \frac{d^2}{d\theta^2} \log f(X_i|\hat{\theta}_n)$$

oder durch

$$\tilde{I} = \frac{1}{n} \sum_{i=1}^n \left(\frac{d}{d\theta} \log f(X_i|\hat{\theta}_n) \right)^2.$$

Bemerkung: Falls $\hat{\theta}_n$ ein unverzerrter Maximum-Likelihood-Schätzer für θ_0 ist, dann gilt die Cramér-Rao-Schranke: 

$$\begin{aligned}\text{Var}_{\theta_0}(\hat{\theta}_n) &\geq \frac{1}{nI(\theta_0)} \\ \Rightarrow \text{Var}_{\theta}(\sqrt{n}(\hat{\theta}_n - \theta_0)) &= \text{Var}_{\theta_0}(\sqrt{n}\hat{\theta}_n) \\ &= n\text{Var}_{\theta_0}(\hat{\theta}_n) \\ &\geq n \frac{1}{nI(\theta_0)} = \frac{1}{I(\theta_0)}.\end{aligned}$$

Für allgemeine Maximum-Likelihood-Schätzer besagt der letzte Satz, dass

$$\text{Var}(\text{Grenzverteilung von } \sqrt{n}(\hat{\theta}_n - \theta_0)) = \frac{1}{I(\theta_0)}.$$

In diesem Sinne ist der Maximum-Likelihood-Schätzer asymptotisch effizient.

2. Testen von Hypothesen

2.1 Neyman-Pearson Paradigma

Siehe zu diesem Kapitel S. 329-341 in *Rice (2007)*.



... ein allgemeines Schema zum Testen von Hypothesen.

Gegeben:

Zufallsvariable (Daten) X_1, \dots, X_n ;
Nullhypothese H_0 (über die Verteilung der X_i);
Alternativ-Hypothese H_1 (über die Verteilung der X_i);
Signifikanzniveau α , $0 < \alpha < 1$.

Wahl:

Test-Statistik $T = T(X_1, \dots, X_n)$, sodass die **Verteilung von T unter H_0 bekannt** ist;
Verwerfungsbereich R , sodass $\mathbb{P}(T \in R | H_0) = \alpha$ (bzw. $\leq \alpha$).

Test:

~~H_0~~ falls $T \in R$;
 $\rightsquigarrow H_0$ falls $T \notin R$.

Dieser Test kann zwei Arten von Fehlern begehen:

- ~~H_0~~ , aber H_0 trifft zu - Fehler 1. Art. (gut kontrollierbar)
- $\rightsquigarrow H_0$ aber H_1 trifft zu - Fehler 2. Art. (schwierig zu kontrollieren)

Laut Konstruktion ist die Wahrscheinlichkeit 1. Art gleich

$$\mathbb{P}(\text{ ~~H_0~~ | } H_0) = \mathbb{P}(T \in R | H_0) = \alpha,$$

also das Signifikanzniveau des Tests.

Die Wahrscheinlichkeit eines Fehlers 2. Art wird von der Wahl von T und R beeinflusst.

Bezeichnungen:

- Für einen Test mit Signifikanzniveau α nennt man α auch die **"Size"** des Tests:

$$\text{Size} = \mathbb{P}(\text{ ~~H_0~~ | } H_0) = \alpha \text{ (je kleiner, desto besser).}$$

- Als **"Power"** des Tests bezeichnet man die Wahrscheinlichkeit, H_0 korrekterweise zu verwerfen:

$$\text{Power} = \mathbb{P}(\text{ ~~H_0~~ | } H_1) \text{ (je größer, desto besser).}$$



Bemerkung:

$$\text{Power} = 1 - \mathbb{P}(\leadsto H_0 | H_1) = 1 - \text{Wahrscheinlichkeit eines Fehlers 2. Art.}$$



Bemerkung: Vergrößert man den Ablehnungsbereich R eines Tests, dann ...
 ... steigt die Size ☹,
 ... steigt die Power ☺.
 Power und Size verhalten sich "antagonistisch".

Beispiel 2.1 (Futschik, 2002, Ist der Euro fair?) Kreiselexperiment:

Land	n	$T = \# \text{Kopf}$	c	$T - \frac{n}{2}$	
AUT	100	50	11	0	$\leadsto H_0$
GE	100	52	11	2	$\leadsto H_0$
IT	250	103	16	-22	$\leadsto H_0$
FR	250	158	16	33	$\leadsto H_0$

Für jedes Land ist X_1, \dots, X_n i.i.d. $B(p)$.

- $H_0: p = \frac{1}{2}$,
- $H_1: p \neq \frac{1}{2}$,
- $\alpha = 0.05$.

Wähle $T = \sum_{i=1}^n X_i \sim B(n, p)$. (Unter H_0 ist $T \sim B(n, \frac{1}{2})$).

Große Werte von $|T - \frac{n}{2}|$ sprechen gegen H_0 !

Verwerfe H_0 , wenn $|T - \frac{n}{2}| \geq c$ ist. Also

$$R = \left(-\infty, \frac{n}{2} - c\right] \cup \left[\frac{n}{2} + c, \infty\right),$$

und verwerfe H_0 falls $T \in R$.

Für $n = 100$ ist $c = 11$,

für $n = 250$ ist $c = 16$.

Bemerkung: Weil T diskret ist, kann das Signifikanzniveau α nicht exakt erreicht werden (im Allgemeinen).

Hier ist c so gewählt, dass die Wahrscheinlichkeit eines Fehlers 1. Art $\leq \alpha$ ist, und so, dass c möglichst klein (also R möglichst groß) ist.

Katapultexperiment:

Land	n	$T = \# \text{Kopf}$	c	$T - \frac{n}{2}$	
AUT	400	196	21	-4	$\leadsto H_0$
IT	150	71	13	-4	$\leadsto H_0$
FR	150	79	13	4	$\leadsto H_0$

Man sieht: Die Nullhypothese kann nur verworfen werden aber nicht bestätigt werden.

Was ist die Power dieses Tests:

$$\text{Power} = \mathbb{P}\left(\left|T - \frac{n}{2}\right| \geq c | H_1\right) \dots \text{hängt von } p\left(\neq \frac{1}{2}\right) \text{ ab.}$$

Setze

$$\Pi(p) = \mathbb{P}\left(\left|T - \frac{n}{2}\right| \geq c | p\right) = \mathbb{P}\left(\left|B(n, p) - \frac{n}{2}\right| \geq c\right),$$

falls X_i i.i.d. $B(p)$.

Beachte:

- Für $p \neq \frac{1}{2}$ ist $\Pi(p)$ die Power des Tests.
- Für $p = \frac{1}{2}$ ist $\Pi(p)$ die Size des Tests ($\leq \alpha$).

Bemerkung: Viele Tests sind von der Form ~~H_0~~ falls $|S| \geq c$, oder $S \geq c$, oder $S \leq c$.
Für solche Tests nennt man c den **kritischen Wert** des Tests (zum Signifikanzniveau α des Tests).

Beachte: $\mathbb{P}(\text{ ~~$H_0$~~ } | H_0) = \alpha$.



Bezeichnung: Für einen Test der oberen Form ist der **p-Wert** des Signifikanzniveaus jenes Test, bei dem der kritische Wert c ersetzt wird durch den beobachteten Wert der Test-Statistik.

Beachte: $0 \leq \text{p-Wert} \leq 1$.



Test	beobachteter Wert	p-Wert
H_0 falls $ S \geq c$	$ s $	$\mathbb{P}(S \geq s H_0)$... fällt in $ s $
H_0 falls $S \geq c$	s	$\mathbb{P}(S \geq s H_0)$... fällt in s
H_0 falls $S \leq c$	s	$\mathbb{P}(S \leq s H_0)$... steigt in s

Bemerkung: Der p-Wert misst, wie stark die Daten der Nullhypothese widersprechen.



Beispiel 2.2 (Futschik, 2002, Ist der Euro fair?) $S = T - \frac{n}{2}$, ~~H_0~~ falls $|S| \geq c$. $\alpha = 0.05$.
Kreiselexperiment:

Land	n	$T = \# \text{Kopf}$	c	$ s $		p-Wert
AUT	100	50	11	0	$\rightsquigarrow H_0$	1
GE	100	52	11	2	$\rightsquigarrow H_0$	0.69
IT	250	103	16	22	H_0	0.0054
FR	250	158	16	33	H_0	0.000028

Katapultexperiment:

Land	n	$T = \# \text{Kopf}$	c	$ s $		p-Wert
AUT	400	196	21	4	$\rightsquigarrow H_0$	0.69
IT	150	71	13	4	$\rightsquigarrow H_0$	0.52
FR	150	79	13	4	$\rightsquigarrow H_0$	0.52

Berechnung des p-Wertes in diesem Beispiel:

$T \sim \text{Bin}\left(n, \frac{1}{2}\right)$ unter H_0 .

$$\begin{aligned}
 \mathbb{P}(|S| \geq |s| | H_0) &= \mathbb{P}\left(\left|T - \frac{n}{2}\right| \geq |s| | H_0\right) \\
 &= \mathbb{P}\left(\left|\text{Bin}\left(n, \frac{1}{2}\right) - \frac{n}{2}\right| \geq |s|\right) \\
 &= \mathbb{P}\left(\text{Bin}\left(n, \frac{1}{2}\right) \leq \frac{n}{2} - |s|\right) + \mathbb{P}\left(\text{Bin}\left(n, \frac{1}{2}\right) \geq \frac{n}{2} + |s|\right).
 \end{aligned}$$



Bemerkung: Liefert ein Test einen p-Wert von $a \in (0, 1)$, dann wird in dem Test die Null-Hypothese verworfen auf jedem Signifikanzniveau $\alpha \geq a$.

Nachrechnen. Betrachte Test, wo ~~H_0~~ falls $S \geq c$ mit Signifikanzniveau α .

Nach Durchführung des Tests erhält man einen p-Wert von a und einen Wert s der Test-Statistik.

Es gilt:

$$\begin{aligned}
 \mathbb{P}(S \geq \tilde{c} | H_0) &= \tilde{\alpha} \geq a = \mathbb{P}(S \geq s | H_0) \\
 &\Leftrightarrow \tilde{c} \leq s \\
 &\Leftrightarrow s \geq \tilde{c}
 \end{aligned}$$

Beobachtbarer Wert der Test-Statistik
Kritische Wert des Tests

$\Leftrightarrow \text{ ~~H_0~~ }$

□

Bemerkung: Falls die Verteilungsfunktion F der Test-Statistik S (bzw. $|S|$) invertierbar ist, dann ist



der p-Wert vor der Durchführung des Experiments/Tests eine Zufallsvariable, die $U([0, 1])$ -verteilt ist.

Nachrechnen. Betrachte Test, wo ~~H_0~~ falls $S \leq c$:

Nach der Durchführung des Experiments ist der p-Wert gegeben durch $\mathbb{P}(S \leq s | H_0) = F(s)$.

Vor der Durchführung des Experiments ist der p-Wert gegeben durch $F(S)$.

Betrachte die Verteilungsfunktion der Zufallsvariable $Z = F(S)$:

$$\begin{aligned}
 \mathbb{P}(Z \leq x) &= \mathbb{P}(F(S) \leq x) \\
 &= \mathbb{P}(S \leq F^{-1}(x)) \\
 &= F(F^{-1}(x)) = x
 \end{aligned}$$

für $0 \leq x \leq 1$.

Für $x < 0$ ist $\mathbb{P}(Z \leq x) = 0$ da $Z \in [0, 1]$,

für $x > 1$ ist $\mathbb{P}(Z \leq x) = 1$ da $Z \in [0, 1]$.

Das heißt die Verteilungsfunktion von $Z = F(S)$, also die Verteilungsfunktion des p-Werts vor der Durchführung, ist gerade die Verteilungsfunktion der $U([0, 1])$; $Z \sim U([0, 1])$. \square

Beispiel 2.3 (Der z-Test) (Testen des Mittelwerts im Gauß'schem Modell mit bekannter Varianz).

Betrachte X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma^2)$, $\mu_0 \in \mathbb{R}$, $\sigma^2 > 0$ bekannt.

$H_0: \mu = \mu_z$ (Für einen bestimmten Wert μ_0).

Die sogenannte z-Statistik ist gegeben durch


$$\begin{aligned} Z &= \frac{1}{\sqrt{n}} \sum_{i=1}^n \underbrace{\frac{X_i - \mu_0}{\sigma}}_{\sim \text{i.i.d. } N(0,1) \text{ unter } H_0} \\ &\quad \underbrace{\hspace{10em}}_{\sim N(0,n) \text{ unter } H_0} \\ &\quad \underbrace{\hspace{10em}}_{\sim N(0,1) \text{ unter } H_0} \\ &= \sqrt{n} \frac{\bar{X}_n - \mu_0}{\sigma}. \end{aligned}$$

Zweiseitige Alternative:

$H_1: \mu_0 \neq \mu_z$.

~~H_0~~ falls $|Z|$ groß ist. Für Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right)$ und verwirft, wenn $|Z| \geq c$:

$$\begin{aligned} \mathbb{P}(\text{ ~~H_0~~$$




Linksseitige Alternative:

$H_1: \mu_0 < \mu_z$.

~~H_0~~ falls Z links von 0 liegt. Für Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = \Phi^{-1}(\alpha)$ und verwirft H_0 , wenn $Z \leq c$.

Signifikanzniveau dieses Tests:

$$\begin{aligned}
 \mathbb{P}(\cancel{H_0} | H_0) &= \mathbb{P}(Z \leq c | H_0) \\
 &= \mathbb{P}(N(0, 1) \leq c) \\
 &= \Phi(c) = \Phi(\Phi^{-1}(\alpha)) \\
 &= \alpha
 \end{aligned}$$




Rechtsseitige Alternative:

$$H_1: \mu_0 > \mu_z.$$

$\cancel{H_0}$ falls Z rechts von 0 liegt. Für Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = \Phi^{-1}(1 - \alpha)$ und verwirft H_0 , wenn $Z \geq c$ ist.

Signifikanzniveau dieses Tests:

$$\begin{aligned}
 \mathbb{P}(\cancel{H_0} | H_0) &= \mathbb{P}(z \geq c | H_0) \\
 &= \mathbb{P}(N(0, 1) \geq c) \\
 &= 1 - \mathbb{P}(N(0, 1) < c) \\
 &= 1 - \Phi(c) = 1 - \Phi(\Phi^{-1}(1 - \alpha)) \\
 &= 1 - (1 - \alpha) = \alpha
 \end{aligned}$$



Beispiel 2.4 (Der t-Test) (Testen des Mittelwerts im Gauß'schen Modell mit unbekannter Varianz).

Betrachte X_1, \dots, X_n i.i.d. $N(\mu_0, \sigma_0^2)$, $\mu_0 \in \mathbb{R}$, $\sigma_0^2 > 0$.

$$H_0: \mu_0 = \mu_z.$$

Setze

$$T = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{X_i - \mu_z}{\hat{\sigma}_n} = \sqrt{n} \frac{\bar{X} - \mu_z}{\hat{\sigma}_n}$$

mit $\sqrt{n}(\bar{x}_n - \mu_z) \sim N(0, \sigma^2)$; $\hat{\sigma}_n \sim \sqrt{\frac{\sigma^2 \chi_{n-1}^2}{n-1}}$

Beachte: Unter H_0 ist $T \sim t_{n-1}$ denn

$$\begin{aligned} T &\sim \frac{N(0, \sigma^2)}{\sigma \sqrt{\chi_{n-1}^2 / (n-1)}} \\ &\sim \frac{N(0, 1)}{\sqrt{\chi_{n-1}^2 / (n-1)}} \\ &\sim t_{n-1}. \end{aligned}$$

Zweiseitige Alternative:

$$H_1: \mu_0 \neq \mu_z.$$

Für ein Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = F_{n-1}^{-1}\left(1 - \frac{\alpha}{2}\right)$ und verwirft, wenn $|T| \geq c$.

Linksseitige Alternative:

$$H_1: \mu_0 < \mu_z.$$

Für Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = F_{n-1}^{-1}(\alpha)$ und verwirft, wenn $T \leq c$.

Rechtsseitige Alternative:

$$H_1: \mu_0 > \mu_z.$$

Für ein Signifikanzniveau $\alpha \in (0, 1)$ wählt man $c = F_{n-1}^{-1}(1 - \alpha)$ und verwirft, wenn $T \geq c$.

Beispiel 2.5 (2-Stichproben t-Test) Betrachte 2 Stichproben:

- X_1, \dots, X_n i.i.d. $N(\mu_x, \sigma_0^2)$
- Y_1, \dots, Y_m i.i.d. $N(\mu_y, \sigma_0^2)$.

Beide Stichproben sind voneinander unabhängig und haben die gleiche Varianz.

$$H_0: \mu_x = \mu_y \text{ und } \bar{X}_n = \bar{Y}_n.$$

Unter H_0 gilt:

$$\begin{aligned} \bar{X}_n &\sim N\left(\mu_x, \frac{\sigma_0^2}{n}\right), \\ \bar{Y}_m &\sim N\left(\mu_y, \frac{\sigma_0^2}{m}\right), \\ \bar{X}_n - \bar{Y}_m &\sim N\left(0, \sigma_0^2 \left(\frac{1}{n} + \frac{1}{m}\right)\right) \\ \frac{\bar{X}_n - \bar{Y}_m}{\sigma_0 \sqrt{\frac{1}{n} + \frac{1}{m}}} &\sim N(0, 1). \end{aligned}$$

\bar{X}_n und \bar{Y}_m sind unabhängig voneinander.

Setze

$$\hat{\mu} = \frac{1}{n+m} \left(\sum_{i=1}^n X_i + \sum_{i=1}^m Y_i \right)$$

$$\hat{\sigma}^2 = \frac{1}{m+n-1} \left(\sum_{i=1}^n (X_i - \hat{\mu})^2 + \sum_{i=1}^m (Y_i - \hat{\mu})^2 \right) \\ \sim \frac{\sigma_0^2 \chi_{m+n-1}^2}{n+m-1} \text{ unter } H_0.$$

Betrachte die Test-Statistik

$$T = \frac{\bar{X}_n - \bar{Y}_m}{\hat{\sigma} \sqrt{\frac{1}{m} + \frac{1}{n}}}.$$

Beachte:

$$T = \underbrace{\frac{\bar{X}_n - \bar{Y}_m}{\sigma_0 \sqrt{\frac{1}{m} + \frac{1}{n}}}}_{\sim N(0,1)} \cdot \underbrace{\frac{\frac{1}{\sqrt{\frac{\chi_{m+n-1}^2}{m+n-1}}}}{\frac{\sigma_0}{\hat{\sigma}}}}_{\sim t_{m+n-1}} \sim t_{m+n-1}.$$

$$\hat{\sigma}^2 \sim \frac{\sigma_0^2}{m+n-1} \chi_{m+n-1}^2, \\ \frac{\hat{\sigma}^2}{\sigma_0^2} \sim \frac{1}{m+n-1} \chi_{m+n-1}^2.$$

Linksseitige Alternative: $H_1: \mu_x < \mu_y$ (σ_x^2, σ_y^2 egal).

~~H_0~~ falls $T \leq c$ für $c = F_{m+n-1}^{-1}(\alpha)$.

Rechtsseitige Alternative: $H_1: \mu_x > \mu_y$ (σ_x^2, σ_y^2 egal).

~~H_0~~ falls $T \geq c$ für $c = F_{m+n-1}^{-1}(1 - \alpha)$.

Zweiseitige Alternative: $H_1: \mu_x \neq \mu_y$ (σ_x^2, σ_y^2 egal).

~~H_0~~ falls $|T| \geq c$ für $c = F_{m+n-1}^{-1}\left(1 - \frac{\alpha}{2}\right)$.

Beispiel 2.6 (Der F-Test) (Testen auf Gleichheit der Varianzen zweier normalverteilter Populationen).

Betrachte zwei Stichproben:

- X_1, \dots, X_n i.i.d. $N(\mu_x, \sigma_x^2)$
- Y_1, \dots, Y_m i.i.d. $N(\mu_y, \sigma_y^2)$.

Beide Stichproben sind unabhängig voneinander.

$H_0: \sigma_x^2 = \sigma_y^2$ (μ_x, μ_y egal).

Unter H_0 ist

$$\hat{\sigma}_x^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \sim \frac{\sigma_x^2}{n-1} \chi_{n-1}^2,$$

$$\hat{\sigma}_y^2 = \frac{1}{m-1} \sum_{i=1}^m (Y_i - \bar{Y}_m)^2 \sim \frac{\sigma_y^2}{m-1} \chi_{m-1}^2,$$

wobei $\hat{\sigma}_x^2$ und $\hat{\sigma}_y^2$ unabhängig voneinander sind.

Damit gilt unter H_0 :

$$\begin{aligned} F = \frac{\hat{\sigma}_x^2}{\hat{\sigma}_y^2} &\sim \frac{\frac{\sigma_x^2}{n-1} \chi_{n-1}^2}{\frac{\sigma_y^2}{m-1} \chi_{m-1}^2} \\ &\sim \frac{\frac{\chi_{n-1}^2}{n-1}}{\frac{\chi_{m-1}^2}{m-1}} \\ &\sim F_{n-1, m-1}, \end{aligned}$$

wobei $F_{n-1, m-1}$ die F-Verteilung mit $n-1$ und $m-1$ Freiheitsgraden ist.

Linksseitige Alternative: $\sigma_x^2 < \sigma_y^2$.


~~H_0~~ falls $F \leq c$ für $c = F_{n-1, m-1}^{-1}(\alpha)$.

Rechtsseitige Alternative: $\sigma_x^2 > \sigma_y^2$.

~~H_0~~ falls $F \geq c$ für $c = F_{n-1, m-1}^{-1}(1 - \alpha)$.

Zweiseitige Alternative: $\sigma_x^2 \neq \sigma_y^2$.

~~H_0~~ falls $F \leq c_1$ oder $F \geq c_2$ für $c_1 = F_{n-1, m-1}^{-1}\left(\frac{\alpha}{2}\right)$ und $c_2 = F_{n-1, m-1}^{-1}\left(1 - \frac{\alpha}{2}\right)$.



2.2 Likelihood-Ratio-Tests und das Neyman-Pearson Lemma

Betrachte ein parametrisches Modell X_1, \dots, X_n i.i.d. mit Dichte (Wahrscheinlichkeitsfunktion) $f(x|\theta)$, $\theta \in \Theta$.

Testproblem:

$H_0: \theta \in \Theta_0$ für $\Theta_0 \subseteq \Theta$,

$H_1: \theta \in \Theta \setminus \Theta_0$.

Bisher hatten wir z.B.:

- $\Theta = \mathbb{R}$, $\Theta_0 = \{\mu_\star\}$; $H_0 = \mu = \mu_\star$ vs $H_1: \mu \neq \mu_\star$ (z-Test 2-Seitig),
- $\Theta = (-\infty, \mu_\star)$ $\Theta_0 = \{\mu_\star\}$; $H_0 = \mu = \mu_\star$ vs $H_1: \mu \neq \mu_\star$ (z-Test 1-Seitig),
- $\Theta = \mathbb{R} \times (0, \infty)$, $\Theta_0 = \{\mu_0\} \times (0, \infty)$; $H_0 = \mu = \mu_\star$ vs $H_1: \mu \neq \mu_\star$ (t-Test),
- $\Theta = \mathbb{R} \times (0, \infty) \times \mathbb{R} \times (0, \infty)$, $\Theta_0 = \{(\mu_x, \sigma_x^2, \mu_y, \sigma_y^2) \in \Theta : \sigma_x^2 = \sigma_y^2\}$;
 $H_0 = \sigma_x^2 = \sigma_y^2$ vs $H_1: \sigma_x^2 \neq \sigma_y^2$ (F-Test).

Allgemeine Modell: Hier ist die Likelihood-Ratio-Statistik (L-R-Statistik) ist definiert als

$$\Lambda = \frac{L(\hat{\theta}_0)}{L(\hat{\theta})},$$

wobei $\hat{\theta}_0$ der ML-Schätzer für θ unter H_0 ist, also $\hat{\theta}_0 = \operatorname{argmax}_{\theta \in \Theta_0} L(\theta)$,

und wobei $\hat{\theta}$ der (unrestringierte) ML-Schätzer für θ ist, also $\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta)$.



Beachte: Wird $\Theta_0 \subseteq \Theta$, ist

$$\underbrace{\operatorname{argmax}_{\theta \in \Theta_0} L(\theta)}_{L(\hat{\theta}_0)} \leq \underbrace{\operatorname{argmax}_{\theta \in \Theta} L(\theta)}_{L(\hat{\theta})}$$

 Sodass $0 \leq \Lambda \leq 1$ liegt.

Der L-R-Test verwirft H_0 , wenn $\Lambda \leq c$ für einen geeigneten kritischen Wert $c < 1$.



Bemerkung: Λ kann interpretiert werden als

$$\frac{\text{Beste Beschreibung der Beobachtungen durch ein } \theta \in \Theta_0}{\text{Beste Beschreibung der Beobachtungen durch ein } \theta \in \Theta}.$$



Bemerkung: Einige der bisher vorgestellten Tests sind tatsächlich L-R-Tests.

Beispiel 2.7 (z-Test mit zweiseitiger Alternative) X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, σ^2 bekannt.

$$H_0: \mu_0 = \mu_\star, H_1: \mu_0 \neq \mu_\star.$$

$$\Theta = \mathbb{R}, \Theta_0 = \{\mu_\star\}$$

Likelihood für $\mu \in \Theta$ ist:

$$\begin{aligned} L(\mu) &= \prod_{i=1}^n \Phi_{\mu, \sigma^2}(X_i) \\ &= \prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(X_i - \mu)^2} \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu)^2}. \end{aligned}$$

$$\hat{\theta}_0 = \operatorname{argmax}_{\mu \in \{\theta_0\}} L(\mu) = \mu_\star.$$

$$\hat{\theta} = \operatorname{argmax}_{\mu \in \Theta} L(\mu) = \bar{X}_n.$$

$$\begin{aligned}
\Lambda &= \frac{L(\mu_\star)}{L(\bar{X}_n)} \\
&= \frac{(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu_\star)^2}}{(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \bar{X}_n)^2}} \\
&= \exp \left(-\frac{1}{2\sigma^2} \underbrace{\left(\sum_{i=1}^n (X_i - \mu_\star)^2 - \sum_{i=1}^n (X_i - \bar{X}_n)^2 \right)}_{(*)} \right).
\end{aligned}$$

L-R-Test verwirft H_0 , wenn Λ klein ist, also wenn $(*)$ groß ist.

$$\begin{aligned}
(*) &= \sum_{i=1}^n (X_i^2 - 2\mu_\star X_i + \mu_\star^2 - X_i^2 + 2\bar{X}_n X_i - \bar{X}_n^2) \\
&= -2\mu_\star \bar{X}_n \cdot n + \mu_\star^2 \cdot n + 2\bar{X}_n \bar{X}_n \cdot n - \bar{X}_n^2 \cdot n \\
&= n(\mu_\star^2 - 2\mu_\star \bar{X}_n + \bar{X}_n^2) \\
&= n(\bar{X}_n - \mu_\star)^2.
\end{aligned}$$

Damit ist $(*)$ genau dann groß, wenn $|\bar{X}_n - \mu_0|$ groß ist. Das ist dieselbe Entscheidungsregel wie beim z-Test.

Also: L-R-Test ist hier der z-Test (bei zweiseitiger Alternative).

Beispiel 2.8 (z-Test mit linksseitiger Alternative) X_1, \dots, X_n wie zuvor.

$$\begin{aligned}
H_0: \mu &= \mu_\star & \Theta_0 &= \{\mu_\star\} \\
&\equiv \\
H_1: \mu &< \mu_\star & \Theta &= (-\infty, \mu_\star]
\end{aligned}$$

Hier ist

$$\begin{aligned}
\hat{\theta}_0 &= \mu_\star \\
\hat{\theta} &= \min \{\bar{X}_n, \mu_0\}
\end{aligned}$$

Hier verwirft der L-R-Test, wenn

$$\begin{aligned}
&\frac{L(\mu_\star)}{L(\min \{\bar{X}_n, \mu_\star\})} \text{ klein ist } (\leq c < 1) \\
\Leftrightarrow &\text{ Nun ist } \frac{L(\mu_\star)}{L(\min \{\bar{X}_n, \mu_\star\})} \leq c < 1 \\
\Leftrightarrow &\frac{L(\mu_\star)}{L(\bar{X}_n)} \leq c < 1 \quad \text{und } \bar{X}_n < \mu_\star \\
\Leftrightarrow &(\bar{X}_n - \mu_0)^2 \quad \text{groß und } \bar{X}_n < \mu_\star \\
\Leftrightarrow &\bar{X}_n - \mu_\star \quad \text{Weit links von 0 (klein und negativ)}
\end{aligned}$$

Der Z-Test verwirft wenn $\frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0)$ klein ist ($\leq \phi^{-1}(\alpha)$). Also ist auch hier der L-R-Test das selbe wie die Z-Test.



Bemerkung: Für den t-Test gelten die Resultate analog zu den letzten beiden Beispielen.

Im folgenden **Neyman-Pearson Lemma** betrachtet man sogenannte **simple Hypothesen**, unter denen die Verteilung der Daten jeweils komplett spezifiziert ist:

X_1, \dots, X_n i.i.d. mit Dichte $f_\theta(x)$ (bzw. Wahrscheinlichkeitsfunktion $p_\theta(x)$), wobei $\theta \in \Theta = \{0, 1\}$. Teste:

$$\begin{array}{ccc} H_0: \theta = 0, & \swarrow & \\ & \text{simple Hypothesen} & \\ & \swarrow & \\ H_1: \theta = 1. & & \end{array}$$

Satz 2.1 (Neyman-Pearson Lemma) Unter allen Tests zwischen zwei simplen Hypothesen mit Signifikanzniveau $\alpha \in (0, 1)$ hat der entsprechende L-R-Test die größtmögliche Power. (Fehler 2. Art möglichst klein)



Bemerkung: Zwischen 2 einfache Hypothesen ist die entsprechende L-R-Statistik gegeben durch:

$$\Lambda = \frac{L(0)}{\max\{L(0), L(1)\}} (< 1).$$

Also wenn $\frac{L(0)}{L(1)} \leq c (< 1)$ ist .

Beweis. Zunächst für $n = 1$.

Betrachte $X = X_1$.

$L(\theta) = f_\theta(x)$, $\theta \in \{0, 1\}$.

Sei $\alpha \in (0, 1)$ und sei c der Kritische Wert der L-R-Test zum Signifikanzniveau α hat:

$$\alpha = \mathbb{P}(\Lambda \leq c | H_0) = \mathbb{P}\left(\frac{f_0(x)}{f_1(x)} \leq c | H_0\right).$$

Diesen Test entspricht eine 0 – 1-wertige Zufallsvariable d_{LR} :

$$d_{LR} = d_{LR}(X_1) = \begin{cases} 0 & : \left(\frac{f_0(x)}{f_1(x)}\right) > c, \\ 1 & : \left(\frac{f_0(x)}{f_1(x)}\right) \leq c, \end{cases}$$

Beachte $c < 1$,

Verteilung von d_{LR} unter H_0 :

$$\mathbb{P}(d_{LR} = 1 | H_0) = \mathbb{P}(\Lambda \leq c | H_0) = \mathbb{P}\left(\frac{f_0(x)}{f_1(x)} \leq c | H_0\right) = \alpha$$

Also: $d_{LR} \sim B(p)$ unter H_0 .

Betrachte nun einen weiteren Test mit Signifikanzniveau α , diesen Test entspricht eine Weitere 0 – 1-wertige Zufallsvariable $d = d(X)$, wobei

$$d(X) = \begin{cases} 0 & : \text{Test verwirft nicht} \\ 1 & : \text{Test verwirft} \end{cases}$$

$$\mathbb{P}(d = 1 | H_0) = \mathbb{P}(\text{Test verwirft } | H_0) = \alpha$$

Also: $d \sim B(p)$ unter H_0 .

Zu zeigen:

$$\begin{aligned} \text{Power von des neuen Tests } (d) &\leq \text{Power des L-R-Tests } (d_{LR}) \\ &\equiv \mathbb{P}(d = 1 | H_1) \leq \mathbb{P}(d_{LR} = 1 | H_1). \end{aligned}$$

Hilfsmittel:

$$\mathbb{P}(A) = \mathbb{P}(A \cap B) + \mathbb{P}(A \cap B^c); \quad A = d = 1; \quad B = d_{LR} = 1.$$

$$\begin{aligned} \mathbb{P}(d = 1 | H_1) &= \mathbb{P}(d = 1, d_{LR} = 1 | H_1) + \mathbb{P}(d = 1, d_{LR} = 0 | H_1) \\ &= \mathbb{P}(d_{LR} = 1 | H_1) - \mathbb{P}(d = 0, d_{LR} = 1 | H_1) + \mathbb{P}(d = 1, d_{LR} = 0 | H_1) \\ &= \mathbb{P}(d_{LR} = 1 | H_1) - \int_{\substack{x: d(x)=0, \\ d_{LR}(x)=1}} f_1(x) dx + \int_{\substack{x: d(x)=1, \\ d_{LR}(x)=0}} f_1(x) dx \\ &\leq \mathbb{P}(d_{LR} = 1 | H_1) - \frac{1}{c} \int_{\substack{x: d(x)=0, \\ d_{LR}(x)=1}} f_0(x) dx + \frac{1}{c} \int_{\substack{x: d(x)=1, \\ d_{LR}(x)=0}} f_0(x) dx \\ &= \mathbb{P}(d_{LR} = 1 | H_1) - \frac{1}{c} (\mathbb{P}(d = 0, d_{LR} = 1 | H_0) - \mathbb{P}(d = 1, d_{LR} = 0 | H_0)) \\ &= \mathbb{P}(d_{LR} = 1 | H_1) - \frac{1}{c} \left(\underbrace{\alpha - \mathbb{P}(d = 1, d_{LR} = 1 | H_0) - \mathbb{P}(d = 1, d_{LR} = 0 | H_0)}_{=\alpha} \right) \\ &= \mathbb{P}(d_{LR} = 1 | H_1) - \frac{1}{c} (\alpha - \alpha) \\ &= \mathbb{P}(d_{LR} = 1 | H_1). \end{aligned}$$

Also: $\mathbb{P}(d = 1 | H_1) \leq \mathbb{P}(d_{LR} = 1 | H_1) \checkmark$.

Der Fall für diskrete Zufallsvariable (mit W-Fkt) geht analog.

Für den Fall $n \geq 1$ argumentiert man ganz genauso (siehe Übung).

□

Korollar 2.1 Seien X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, $\mu \in (-\infty, \mu_0]$, $\sigma^2 > 0$ bekannt.
 Teste $H_0: \mu = \mu_0$ gegen $H_1: \mu < \mu_0$, für eine feste Zahl μ .
 Hier hat die L-R-Test mit Signifikanzniveau α die größtmögliche Power.

Power einen Test wenn $\mu = \mu_1 \leq$ Power den L-R-Test wenn $\mu \neq \mu_1$
 $\Pi(\mu_1) \leq \Pi_{LR}(\mu_1)$

Einen Test mit diesem Eigenschaft nennt man Uniformly Most Powerful (UMP)

Beweis. Sie $\mu_1 < \mu_0$. Zu zeigen: $\Pi(\mu_1) \leq \Pi_{LR}(\mu_1)$

Der beiden Tests entsprechen wieder 0 – 1 – Wertige Zufallsvariable d und d_{LR} .

Beachte: $\mathbb{P}(d_{LR} = 1 | H_0) = \mathbb{P}(d = 1 | H_0) = \alpha$.

Beide Tests haben die Signifikanzniveau α .

Betrachte dazu ein neues Testproblem:

$$\begin{array}{c}
 \tilde{H}_0: \mu = \mu_0, \\
 \swarrow \quad \searrow \\
 \text{simple Hypothesen} \\
 \swarrow \quad \searrow \\
 \tilde{H}_1: \mu = \mu_1.
 \end{array}$$

Beachte:

- $\mathbb{P}(d_{LR} = 1 | \tilde{H}_0) = \mathbb{P}(d_{LR} = 1 | H_0) = \alpha$.
 $\mathbb{P}(d = 1 | \tilde{H}_0) = \mathbb{P}(d = 1 | H_0) = \alpha$,
 D.h. beim Testen von \tilde{H}_0 gegen \tilde{H}_1 haben d_{LR} und d beide Signifikanzniveau α .
- Der L-R-Test zum Testen von \tilde{H}_0 gegen \tilde{H}_1 , verwirft H_0 , wenn

$$\begin{aligned}
 \tilde{\Lambda} &= \frac{L(\mu_0)}{L(\mu_1)} && \leq \tilde{c} < 1 \\
 \Leftrightarrow & \frac{(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu_0)^2}}{(2\pi\sigma^2)^{-\frac{n}{2}} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu_1)^2}} && \text{Soll klein sein} \\
 \Leftrightarrow & \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n ((X_i - \mu_0)^2) + \frac{1}{2\sigma^2} \sum_{i=1}^n ((X_i - \mu_1)^2)\right) && \text{Soll klein sein} \\
 \Leftrightarrow & \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i^2 - 2\mu_0 X_i + \mu_0^2 - X_i^2 + 2\mu_1 X_i - \mu_1^2)\right) && \text{Soll klein sein} \\
 \Leftrightarrow & \exp\left(-\frac{n}{2\sigma^2} ((\mu_0^2 - \mu_1^2) + 2(\mu_1 - \mu_0)\bar{X}_n)\right) && \text{Klein} \\
 \Leftrightarrow & n((\mu_0^2 - \mu_1^2) + 2\bar{X}_n(\mu_1 - \mu_0)) \underbrace{\quad}_{<0} && \text{groß} \\
 \Leftrightarrow & \bar{X}_n \text{ klein} \\
 \Leftrightarrow & \text{Genauer: } \bar{X}_n \text{ sodass } \mathbb{P}(\bar{X}_n \leq c | H_0) = \alpha
 \end{aligned}$$

- Der L-R-Test von H_0 gegen H_1 ist der Z-Test. Dieser Test verwirft H_0 (bzw. \tilde{H}_0) wenn

$$\begin{aligned}
 & \frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu_0) \text{ klein} \\
 \Leftrightarrow & \bar{X}_n - \mu_0 \text{ klein} \\
 \Leftrightarrow & \bar{X}_n \text{ klein.}
 \end{aligned}$$

Also: Der L-R-Test zwischen H_0 und H_1 , und der L-R-Test zwischen \tilde{H}_0 und \tilde{H}_1 stimmen überein.

Mit N-P-Lemma: Unter allen Tests von \tilde{H}_0 gegen \tilde{H}_1 mit Signifikanzniveau α hat der L-R-Test die Maximale Power.

Also:

$$\begin{aligned}
 \mathbb{P}(d = 1 | \tilde{H}_1) &\leq \mathbb{P}(d_{LR} = 1 | \tilde{H}_1) \\
 \mathbb{P}(d = 1 | \mu_1) &\leq \mathbb{P}(d_{LR} = 1 | \mu_1) \\
 \Pi(\mu_1) &\leq \Pi_{LR}(\mu_1)
 \end{aligned}$$



Bemerkung: Die obige Aussage gilt auch für rechtsseitige Alternativen ($\mu > \mu_0$), sowie im Fall unbekannter Varianz, d.h. für den t-Test. Bei 2-Seitige Alternative gibt es keinen UMP. 

Beispiel 2.9 Seien X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$ bekannt. Teste $H_0: \mu = \mu_0$ gegen $H_1: \mu \neq \mu_0$.

Hierfür existiert kein UMP-Test (Siehe hierzu auch R-Code vom 17.06.21).

Beweisidee. Fixiere $\alpha \in (0, 1)$. Angenommen es gibt einen UMP-Test. Sei d_{\times} die diesem entsprechende 0 – 1-wertige Zufallsvariable.

- Betrachte zunächst dem Fall $\mu_1 < \mu_0$, sowie das asymptotische Testproblem

$$\tilde{H}_0: \mu < \mu_0$$

$$\tilde{H}_1: \mu < \mu_1.$$

Sei \tilde{d} der L-R-Test zum Testen von \tilde{H}_0 gegen \tilde{H}_1 . Mit dem Neyman-Pearson-Lemma ist

$$\mathbb{P}(\tilde{d} = 1 | \mu = \mu_1) \geq \mathbb{P}(d_{\times} = 1 | \mu = \mu_1).$$

Weil d_{\times} UMP ist, gilt auch

$$\mathbb{P}(\tilde{d} = 1 | \mu = \mu_1) \leq \mathbb{P}(d_{\times} = 1 | \mu = \mu_1).$$

Die Power von d_{\times} und von \tilde{d} ist gleich.

\Rightarrow Die Tests d_{\times} und d_{LR} stimmen überein.
informell

Nun ist \tilde{d} den Z-Test (siehe letzte Beispiel):

$$\begin{aligned} d_{\times} &= \begin{cases} 1 & : \tilde{d} = 1, \\ 0 & : \tilde{d} = 0, \end{cases} \\ &= \begin{cases} 1 & : \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0) \leq \Phi^{-1}(\alpha) \\ 0 & : \text{sonst.} \end{cases} \end{aligned}$$

- Betrachte nun den Fall $\mu_1 > \mu_0$ und argumentiere wie zuvor.
Syntetisches Testproblem:

$$\tilde{\tilde{H}}_0: \mu = \mu_0$$

$$\tilde{\tilde{H}}_1: \mu = \mu_1.$$

Ist $\tilde{\tilde{d}}$ der entsprechende L-R-Test, dann stimmen wie zuvor die Tests $\tilde{\tilde{d}}$ und d_{\times} überein. Wieder ist $\tilde{\tilde{d}}$ ein Z-Test:

$$d_{\times} = \begin{cases} 1 & : \tilde{d} = 1, \\ 0 & : \tilde{d} = 0, \end{cases} \\ = \begin{cases} 1 & : \frac{\sqrt{n}}{\sigma}(\bar{X}_n - \mu_0) \geq \Phi^{-1}(1 - \alpha) \\ 0 & : \text{sonst.} \end{cases}$$

Die beiden Formeln für d_{\times} widersprechen einander.

Damit kann d_{\times} nicht einem UMP-Test entsprechen.

□



Bemerkung: Das oben beobachtete Phänomen tritt auch im Fall unbekannter Varianz (t-Test) auf. Darüber hinaus ist in vielen der hier beobachteten Modellen ($B(p)$, $F_{m-1, n-1}$, etc.) bei einseitigen Alternativen der entsprechende L-R-Test UMP, und für zweiseitige Alternativen existiert kein UMP.

2.3 L-R-Tests in großen Stichproben

Betrachte: X_1, \dots, X_n i.i.d. mit Dichte $f(x|\theta)$ (bzw. Wahrscheinlichkeitsfunktion $p(x|\theta)$), $\theta \in \Theta \subseteq \mathbb{R}^p$.

Teste:

$$H_0: \theta \in \Theta_0 \subseteq \Theta_1$$

$$H_1: \theta \in \Theta \setminus \Theta_0.$$

Betrachte der L-R-Statistik: $\Lambda = \frac{L(\hat{\theta}_0)}{L(\hat{\theta})}$

wobei: $\hat{\theta}_0 = \operatorname{argmax}_{\theta \in \Theta_0} L(\theta)$, $\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta)$.

Satz 2.2 (Wilks' Theorem) Unter geeigneten Voraussetzungen gilt unter H_0 :

$$-2 \log \Lambda_n \xrightarrow{w} \chi_{k-k_0}^2$$

wobei k (bzw. k_0) die Anzahl der freien Parameter in Θ (bzw. Θ_0) ist. Oft $k = \dim \Theta$, $k_0 = \dim \Theta_0$.

$$H_0: \mu = \mu, k_0 = 0$$

>

$$H_1: \mu < \mu_0, k = 1.$$

≠

(Ohne Beweis)

Damit erhält man einen Test (H_0 gegen H_1) mit nominaler Signifikanzniveau α wie folgt:

$$\text{falls } -2 \log \Lambda \geq c$$

Wähle c sodaß,

$$\begin{aligned}
\alpha &\approx \mathbb{P}(-2 \log \Lambda_n \geq c | H_0) \\
&= 1 - \mathbb{P}(-2 \log \Lambda_n \leq c | H_0) \\
&\approx 1 - \mathbb{P}(\chi_{k-k_0}^2 < c) = \% \\
&\uparrow \text{Wilks}
\end{aligned}$$

Setze $c = F_{k-k_0}^{-1}(1 - \alpha) \rightarrow$ Quantil der $\chi_{k-k_0}^2$

$$\begin{aligned}
\Rightarrow \% &= 1 - \mathbb{P}(\chi_{k-k_0}^2 \leq c) \\
&= 1 - (1 - \alpha) = \alpha \\
&\Rightarrow \mathbb{P}(\cancel{H_0} | H_0) \approx \alpha
\end{aligned}$$

Für $n \rightarrow \infty$ nähert sich das Signifikanzniveau dieses Tests dem Wert α an:

$$\begin{aligned}
&\lim_{n \rightarrow \infty} \mathbb{P}(-2 \log \Lambda_n \geq c | H_0) \\
&= \lim_{n \rightarrow \infty} 1 - \mathbb{P}(-2 \log \Lambda_n < c | H_0) \\
&= 1 - \lim_{n \rightarrow \infty} \mathbb{P}(-2 \log \Lambda_n < c | H_0) \\
&= 1 - \underbrace{\mathbb{P}(\chi_{k-k_0}^2 < c)}_{1-\alpha} \\
&= \alpha \checkmark
\end{aligned}$$

Beispiele für $k, k_0 : \lambda_i, \text{iid}, \mathbb{N}(\mu, \sigma^2)$

$$\begin{aligned}
H_0 &: \mu = \mu_0 \\
H_1 &: \mu \neq \mu_0 \\
\Theta &= \mathbb{R} \times (0, \infty) \dots k = 2 \\
\Theta_0 &= \{\mu_0\} \times (0, \infty) \dots k = 1
\end{aligned}$$

Beispiel 2.10 (Kategoriale Daten, einfache Nullhypothese) Betrachte:

X_1, \dots, X_n iid diskret mit Werten in $\{1, \dots, m\}$.

Wahrscheinlichkeitsfunktion $p(j) = \mathbb{P}(X_i = j), \theta = (p(j))_{j=1}^m$ unbekannt.

Weiters sei $p_0(j), 1 \leq j \leq m$, eine bestimmte Wahrscheinlichkeitsfunktion. Teste:

$$H_0 : p(j) = p_0(j) \text{ für alle } j = 1, \dots, m$$

$$H_1 : p(j) \neq p_0(j) \text{ für mindestens ein } j \in \{1, \dots, m\}$$

$$\Theta = \left\{ (p(j))_{j=1}^m \in [0, 1]^m : \sum_{j=1}^m p(j) = 1 \right\} \dots k = 1$$

$$\Theta_0 = \left\{ (p(j))_{j=1}^m \right\} \dots k_0 = 0$$

$$\hat{\theta}_0 = \operatorname{argmax}_{\theta \in \Theta_0} L(\theta) = (p_0(j))_{j=1}^m$$

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \Theta} L(\theta) = \left(\frac{O_j}{n} \right)_{j=1}^m, \text{ wobei } O_j = \#\{i = 1, \dots, n : X_i = j\}, 1 \leq j \leq m$$

$$O_j \text{ " Observed number of cases in class } j \text{ "}$$

Allgemein ist:

$$L((p(j))_{j=1}^m) = p(x_1) \cdot p(x_2) \cdot \dots \cdot p(x_n) =$$

$$p(1)^{O_1} \cdot p(2)^{O_2} \cdot \dots \cdot p(m)^{O_m}$$

$$-2 \log \Lambda = -2 \log \frac{L(\hat{\theta}_0)}{L(\hat{\theta})} = 2 \log \frac{L(\hat{\theta})}{L(\hat{\theta}_0)}$$

$$2 \log \frac{\prod_{j=1}^m \left(\frac{O_j}{n} \right)^{O_j}}{\prod_{j=1}^m (p_0(j))^{O_j}} = 2 \log \prod_{j=1}^m \left(\frac{O_j}{n \cdot p_0(j)} \right)^{O_j} =$$

$$2 \sum_{j=1}^m O_j \log \frac{O_j}{n p_0(j)} = 2 \sum_{j=1}^m O_j \log \frac{O_j}{E_j},$$

Wobei $E_j = n \cdot p_0(j)$, $1 \leq j \leq m$ "Expected number of cases in class j under H_0 "

Grenzverteilung von $2 \sum_{j=1}^m O_j \log \frac{O_j}{E_j}$ ist die χ_{m-1}^2 -Verteilung.



Bemerkung: Im Kontext des letzten Beispiels wird oft Pearson's χ^2 -Anpassungstest verwendet.

Die Statistik ist: $\chi^2 := \sum_{j=1}^m \frac{(E_j - O_j)^2}{E_j}$ ($\chi^2 \leftarrow$ nicht eine Verteilung).

Unter H_0 gilt $\chi^2 \xrightarrow{w} \chi_{m-1}^2$.

Tatsächlich sind hier der L-R-Test und der χ^2 -Anpassungstest äquivalent.



Bemerkung: Die Approximation

$$\mathbb{P}(-2 \log \Lambda \leq t | H_0) \approx \mathbb{P}(\chi_{m-1}^2 \leq t)$$

$$\mathbb{P}(\chi^2 \leq t | H_0) \approx \mathbb{P}(\chi_{m-1}^2 \leq t)$$

werden klein, wenn für jedes $j = 1, \dots, m$ die größte $E_j = n \cdot p_0(j)$ groß ist. Daumenregel: $E_j \geq 5$

Falls die Daumenregeln verletzt ist, kann man "Klassen zusammenlegen".

Beispiel 2.11 $\lambda_1, \dots, \lambda_n$ iid $\mathbb{N}(\mu, \sigma^2)$, $\sigma^2 > 0$ bekannt. Teste:

$$H_0 : \mu = \mu_0 \quad \Theta_0 = \{\mu_0\}$$

$$H_1 : \mu \neq \mu_0 \quad \Theta = \mathbb{R}$$

$\hat{\mu}_0$...ML Schätzer für μ_0 unter $H_0 = \mu_0$

$\hat{\mu}$...ML Schätzer "unrestringiert" = \bar{X}_n

$$\begin{aligned} \Lambda &= \frac{\prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(X_i - \mu_0)^2}}{\prod_{i=1}^n (2\pi\sigma^2)^{-\frac{1}{2}} e^{-\frac{1}{2\sigma^2}(X_i - \bar{X}_n)^2}} = e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n ((X_i - \mu_0)^2 - (X_i - \bar{X}_n)^2)} \\ &= -2 \log \Lambda = -2 \frac{(-1)}{2\sigma^2} \sum_{i=1}^n (X_i^2 - 2X_i\mu_0 + \mu_0^2 - X_i^2 + 2X_i\bar{X}_n - \bar{X}_n^2) \\ &= \frac{1}{\sigma^2} (-2\mu_0 n\bar{X}_n + n\mu_0^2 + \underbrace{2\bar{X}_n n\bar{X}_n - n\bar{X}_n^2}_{n\bar{X}_n^2}) \\ &= \frac{n}{\sigma^2} (\mu_0^2 - 2\mu_0\bar{X}_n + \bar{X}_n^2) \\ &= \frac{n}{\sigma^2} (\bar{X}_n - \mu_0)^2 \\ &= \left(\frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma} \right)^2 = (*) \end{aligned}$$

Unter H_0 ist

$$\bar{X}_n \mathbb{N}\left(\mu_0, \frac{\sigma^2}{n}\right)$$

$$\bar{X}_n - \mu_0 \mathbb{N}\left(0, \frac{\sigma^2}{n}\right)$$

$$\frac{\sqrt{n}}{\sigma} (\bar{X}_n - \mu_0) \mathbb{N}(0, 1)$$

$$\Rightarrow -2 \log \Lambda = (*) = \chi^2.$$

3. Zufallsvektoren und Zufallsmatrizen



Siehe zu diesem Kapitel S. 564-574. in Rice, J. A. (2007). *Mathematical statistics and data analysis*. Belmont, CA: Thomson/Brooks/Cole.



Dieses Kapitel haben wir im SS 2022 nicht gemacht, es bleibt aber vom Vorjahr hier!



Wissen: Für X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $\sigma^2 > 0$, ist

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

$$\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \sim \frac{\sigma^2}{n-1} \chi_{n-1}^2$$

und weiters sind \bar{X}_n und $\hat{\sigma}_n^2$ unabhängig. Damit ist insbesondere

$$\frac{\sqrt{n}}{\hat{\sigma}_n} (\bar{X}_n - \mu) \sim t_{n-1}.$$

3.1 Erwartungswerte und Varianz/Kovarianz-Matrizen

Definition 3.1 (Erwartungswert) Für zufällige Vektoren bzw. Matrizen wird der Erwartungswert komponentenweise definiert. Also:

(i) Ist $\mathbf{X} = (X_1, \dots, X_n)'$ ein Zufallsvektor, dann ist

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \vdots \\ \mathbb{E}(X_n) \end{pmatrix}.$$

(ii) Ist $\mathbf{M} = (M_{ij})_{i=1, j=1}^{n \ m}$ eine zufällige Matrix, dann ist

$$\mathbb{E}(\mathbf{M}) = \mathbb{E}\left((M_{ij})_{i=1, j=1}^{n \ m}\right)$$



Bemerkung: (i) ist ein Spezialfall von (ii), da man den n -Vektor \mathbf{X} auch als $n \times 1$ Matrix betrachten

kann.

Für Zufallsvariable Z ist der Erwartungswert linear für $a, b \in \mathbb{R}$,

$$\mathbb{E}(aZ + b) = a\mathbb{E}(Z) + b.$$

Proposition 3.1 (Linearität des Erwartungswertes) (i) Sei $\mathbf{X} = (X_1, \dots, X_n)'$ ein Zufallsvektor, \mathbf{A} eine $m \times n$ -Matrix und \mathbf{b} ein m -dimensionaler Vektor, dann ist

$$\mathbb{E}(\mathbf{AX} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}.$$

(ii) Sei \mathbf{M} eine zufällige $(n \times m)$ Matrix, \mathbf{A} eine $k \times n$ Matrix und \mathbf{B} eine $k \times m$ Matrix, dann ist

$$\mathbb{E}(\mathbf{AM} + \mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{M}) + \mathbf{B}.$$

Ist \mathbf{C} eine $m \times k$ Matrix und \mathbf{D} eine $n \times k$ Matrix, dann ist

$$\mathbb{E}(\mathbf{MC} + \mathbf{D}) = \mathbb{E}(\mathbf{M})\mathbf{C} + \mathbf{D}.$$

Beweis. Es genügt, (ii) zu zeigen, da (i) ein Spezialfall von (ii) ist.

Zeige: $\mathbb{E}(\mathbf{AM} + \mathbf{B}) = \mathbf{A}\mathbb{E}(\mathbf{M}) + \mathbf{B}$.

Vergleiche Eintrag in Zeile i und Spalte j links und rechts.

$$\begin{aligned} (\mathbb{E}(\mathbf{AM} + \mathbf{B}))_{ij} &= \mathbb{E}((\mathbf{AM} + \mathbf{B})_{ij}) \\ &= \mathbb{E}((\mathbf{AM})_{ij} + B_{ij}) \\ &= \mathbb{E}\left(\sum_{l=1}^n A_{il}M_{lj} + B_{ij}\right) \\ &= \sum_{l=1}^n A_{il}\mathbb{E}(M_{lj}) + B_{ij} \\ &= (\mathbf{A}\mathbb{E}(\mathbf{M}))_{ij} + B_{ij} \\ &= (\mathbf{A}\mathbb{E}(\mathbf{M}) + \mathbf{B})_{ij}. \end{aligned}$$

Zeige: $\mathbb{E}(\mathbf{MC} + \mathbf{D}) = \mathbb{E}(\mathbf{M})\mathbf{C} + \mathbf{D}$.

$$\begin{aligned} (\mathbb{E}(\mathbf{MC} + \mathbf{D}))_{ij} &= \mathbb{E}((\mathbf{MC} + \mathbf{D})_{ij}) \\ &= \mathbb{E}((\mathbf{MC})_{ij} + D_{ij}) \\ &= \mathbb{E}\left(\sum_{l=1}^m M_{il}C_{lj} + D_{ij}\right) \\ &= \sum_{l=1}^m \mathbb{E}(M_{il})C_{lj} + D_{ij} \\ &= (\mathbb{E}(\mathbf{M})\mathbf{C})_{ij} + D_{ij} \\ &= (\mathbb{E}(\mathbf{M})\mathbf{C} + \mathbf{D})_{ij}. \end{aligned}$$

□

Beispiel 3.1 X_1, \dots, X_n i.i.d. mit $\mathbb{E}(X_1) = \mu$.

Betrachte $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$.

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_n) \end{pmatrix} = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \boldsymbol{\iota}$$

für $\boldsymbol{\iota} = (1, \dots, 1)' \in \mathbb{R}^n$.

$$\mathbb{E}\left(\frac{1}{n} \boldsymbol{\iota}' \mathbf{X}\right) = \frac{1}{n} \boldsymbol{\iota}' \mathbb{E}(\mathbf{X}) = \frac{1}{n} \boldsymbol{\iota}' \mu \boldsymbol{\iota} = \frac{\mu}{n} \underbrace{\boldsymbol{\iota}' \boldsymbol{\iota}}_{=n} = \mu.$$



$$\mathbf{X} = \boldsymbol{\iota} \bar{X} + (\mathbf{X} - \boldsymbol{\iota} \bar{X})$$

orthogonal!

Beispiel 3.2

$$\begin{aligned} \mathbb{E}\left(\underbrace{\boldsymbol{\iota} \bar{X}}_{(n \times 1)}\right) &= \mathbb{E}\left(\boldsymbol{\iota} \frac{1}{n} \boldsymbol{\iota}' \mathbf{X}\right) \\ &= \frac{1}{n} \boldsymbol{\iota}' \mathbb{E}(\mathbf{X}) \\ &= \frac{1}{n} \boldsymbol{\iota}' \mu \boldsymbol{\iota} \\ &= \mu \frac{1}{n} \boldsymbol{\iota}' \boldsymbol{\iota} \\ &= \mu. \end{aligned}$$

Beispiel 3.3

$$\begin{aligned}
 \mathbb{E}(\mathbf{X} - \iota \bar{X}) &= \mathbb{E}\left(\mathbf{X} - \iota \frac{1}{n} \iota' \mathbf{X}\right) \\
 &= \mathbb{E}\left(\left(I_n - \iota \frac{1}{n} \iota'\right) \mathbf{X}\right) \\
 &= \left(I_n - \frac{1}{n} \iota \iota'\right) \mathbb{E}(\mathbf{X}) \\
 &= \left(I_n - \frac{1}{n} \iota \iota'\right) \boldsymbol{\mu} \\
 &= \boldsymbol{\mu} \left(\iota - \frac{1}{n} \iota \iota' \iota\right) \\
 &= \boldsymbol{\mu}(\iota - \iota) \\
 &= \mathbf{0}.
 \end{aligned}$$

Definition 3.2 (Varianz/Kovarianz-Matrix) Ist $\mathbf{X}_{(n \times 1)}$ ein Zufallsvektor, dann ist die so genannte Varianz/Kovarianz-Matrix von \mathbf{X} die $n \times n$ Matrix

$$VC(\mathbf{X}) = \left(VC(X)_{ij}\right)_{i,j=1}^n,$$

wobei

$$VC(\mathbf{X}) = \begin{cases} \text{Var}(X_i) & : i = j \\ \text{Cov}(X_i, X_j) & : i \neq j \end{cases}$$

mit $1 \leq i, j \leq n$.

$$VC(\mathbf{X}) = \begin{pmatrix} \text{Var}(X_1) & \text{Cov}(X_1, X_2) & \dots & \text{Cov}(X_1, X_n) \\ \text{Cov}(X_2, X_1) & \text{Var}(X_2) & \dots & \text{Cov}(X_2, X_n) \\ \vdots & \vdots & \ddots & \vdots \\ \text{Cov}(X_n, X_1) & \text{Cov}(X_n, X_2) & \dots & \text{Var}(X_n) \end{pmatrix}$$

Bemerkung: Weil $\text{Cov}(X_i, X_j) = \text{Cov}(X_j, X_i)$ ist, ist $VC(\mathbf{X})$ immer symmetrisch:

$$(VC(\mathbf{X}))' = VC(\mathbf{X})$$

Bemerkung: Ist \mathbf{X} ein 1-dimensionaler Vektor, dann ist $VC(\mathbf{X})$ die 1×1 Matrix $\text{Var}(\mathbf{X})$.

Proposition 3.2

$$VC(\mathbf{X}) = \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))').$$

Beweis. Sei $i, j \in \{1, \dots, n\}$.

$$\begin{aligned}
(\mathbb{E}(X - \mathbb{E}(X))(X - \mathbb{E}(X))')_{ij} &= (\mathbb{E}(X - \mathbb{E}(X))_i (X - \mathbb{E}(X))_j) \\
&= (\mathbb{E}(X_i - \mathbb{E}(X_i))(X_j - \mathbb{E}(X_j))) \\
&= \text{Cov}(X_i, X_j) \\
&= (\text{VC}(X))_{ij}.
\end{aligned}$$

Beachte: Für $i = j$ ist $\text{Cov}(X_i, X_j) = \text{Var}(X_i)$.

□

Proposition 3.3 Ist \mathbf{X} ein n -dimensionaler Zufallsvektor, \mathbf{A} eine $m \times n$ Matrix und $\mathbf{b} \in \mathbb{R}^m$, dann ist $\text{VC}(\mathbf{AX} + \mathbf{b}) = \mathbf{A} \text{VC}(\mathbf{X}) \mathbf{A}'$

Beweis.

$$\begin{aligned}
\text{VC}(\mathbf{AX} + \mathbf{b}) &= \mathbb{E}((\mathbf{AX} + \mathbf{b} - \mathbb{E}(\mathbf{AX} + \mathbf{b}))(\mathbf{AX} + \mathbf{b} - \mathbb{E}(\mathbf{AX} + \mathbf{b}))') \\
&= \mathbb{E}((\mathbf{AX} + \mathbf{b} - (\mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}))(\mathbf{AX} + \mathbf{b} - (\mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}))') \\
&= \mathbb{E}((\mathbf{AX} - \mathbf{A}\mathbb{E}(\mathbf{X}))(\mathbf{AX} - \mathbf{A}\mathbb{E}(\mathbf{X}))') \\
&= \mathbb{E}(\mathbf{A}(\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))' \mathbf{A}') \\
&= \mathbf{A} \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))' \mathbf{A}') \\
&= \mathbf{A} \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))') \mathbf{A}' \\
&= \mathbf{A} \text{VC}(\mathbf{X}) \mathbf{A}'.
\end{aligned}$$

□

Beispiel 3.4 X_1, \dots, X_n i.i.d., $\mathbb{E}(X_1) = \mu$, $\text{Var}(X_1) = \sigma^2$. $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix}$

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \mu \mathbf{1}.$$

$$\text{VC}(\mathbf{X}) = \begin{pmatrix} \sigma^2 & & & 0 \\ & \ddots & & \\ & & \ddots & \\ 0 & & & \ddots \\ & & & & \sigma^2 \end{pmatrix} = \sigma^2 \mathbf{I}_n$$

Betrachte \bar{X} , $\mathbf{X} - \iota \bar{X}$.

$\begin{pmatrix} \bar{X} \\ \mathbf{X} - \iota \bar{X} \end{pmatrix} \dots$ ein $(n+1)$ -dimensionaler Vektor.

$$\begin{pmatrix} \mathbb{E}(\bar{X}) \\ \mathbb{E}(\mathbf{X} - \iota \bar{X}) \end{pmatrix} = \begin{pmatrix} \mu \\ \mathbf{0} \end{pmatrix}.$$

Varianzkovarianzmatrix:

$$\begin{aligned}
\text{VC}(\mathbf{Z}) &= \mathbb{E} \left[\begin{pmatrix} \bar{X} - \mu \\ \mathbf{X} - \iota \bar{X} - \mathbf{0} \end{pmatrix} \begin{pmatrix} \bar{X} - \mu & (\mathbf{X} - \iota \bar{X} - \mathbf{0})' \end{pmatrix} \right] \\
&= \mathbb{E} \left[\begin{pmatrix} \bar{X} - \mu \\ \mathbf{X} - \iota \bar{X} \end{pmatrix} \begin{pmatrix} \bar{X} - \mu & (\mathbf{X} - \iota \bar{X})' \end{pmatrix} \right] \\
&= \mathbb{E} \left[\begin{pmatrix} (\bar{X} - \mu)(\bar{X} - \mu) & (\bar{X} - \mu)(\mathbf{X} - \iota \bar{X})' \\ (\mathbf{X} - \iota \bar{X})(\bar{X} - \mu) & (\mathbf{X} - \iota \bar{X})(\mathbf{X} - \iota \bar{X})' \end{pmatrix} \right] \\
&= \begin{pmatrix} \mathbb{E}(\bar{X} - \mu)^2 & \mathbb{E}((\bar{X} - \mu)(\mathbf{X} - \iota \bar{X})') \\ \mathbb{E}(\mathbf{X} - \iota \bar{X})(\bar{X} - \mu) & \mathbb{E}((\mathbf{X} - \iota \bar{X})(\mathbf{X} - \iota \bar{X})') \end{pmatrix} \\
&= \begin{pmatrix} \text{Var}(\bar{X}) & \mathbb{E}((\bar{X} - \mu)(\mathbf{X} - \iota \bar{X})') \\ \mathbb{E}(\mathbf{X} - \iota \bar{X})(\bar{X} - \mu) & \mathbb{E}((\mathbf{X} - \iota \bar{X})(\mathbf{X} - \iota \bar{X})') \end{pmatrix}.
\end{aligned}$$

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}.$$

$$\mathbb{E}((\bar{X} - \mu)(\mathbf{X} - \iota \bar{X})') = ?$$

Zwei Zwischenschritte:

$$\begin{aligned}
\bar{X} - \mu &= \left(\frac{1}{n} \iota' \mathbf{X} \right) - \left(\frac{1}{n} \iota' \mu \right) \\
&= \left(\frac{1}{n} \iota' \mathbf{X} \right) - \left(\frac{1}{n} \iota' \mathbb{E}(\mathbf{X}) \right) \\
&= \frac{1}{n} \iota' (\mathbf{X} - \mathbb{E}(\mathbf{X})),
\end{aligned}$$

und

$$\begin{aligned}
\mathbf{X} - \iota \bar{X} &= \mathbf{X} - \iota \frac{1}{n} \iota' \mathbf{X} \\
&= \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) \mathbf{X} \\
&= \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) (\mathbf{X} - \mathbb{E}(\mathbf{X})),
\end{aligned}$$

da

$$\begin{aligned}
\left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) \mathbb{E}(\mathbf{X}) &= \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) \mu \iota \\
&= \mu \left(\mathbf{I}_n \iota - \frac{1}{n} \iota \iota' \iota \right) \\
&= \mu \left(\iota - \frac{n}{n} \iota \right) \\
&= \mu (\iota - \iota) \\
&= \mathbf{0}.
\end{aligned}$$

$$\begin{aligned}
\mathbb{E}\left((\bar{X} - \mu)(\mathbf{X} - \iota\bar{X})'\right) &= \mathbb{E}\left(\left(\frac{1}{n}\iota'(\mathbf{X} - \mathbb{E}(\mathbf{X}))\right)\left((\mathbf{X} - \mathbb{E}(\mathbf{X}))'\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\right)\right) \\
&= \frac{1}{n}\iota'\mathbb{E}\left(\left((\mathbf{X} - \mathbb{E}(\mathbf{X}))\right)\left((\mathbf{X} - \mathbb{E}(\mathbf{X}))'\right)\right)\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right) \\
&= \frac{1}{n}\iota'VC(\mathbf{X})\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right) \\
&= \sigma^2\frac{1}{n}\iota'\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right) \\
&= \sigma^2\frac{1}{n}\left(\iota' - \iota'\iota\frac{1}{n}\iota'\right) \\
&= \sigma^2\frac{1}{n}(\iota' - \iota') \\
&= \mathbf{0}.
\end{aligned}$$

$$\begin{aligned}
\mathbb{E}\left((\mathbf{X} - \iota\bar{X})(\mathbf{X} - \iota\bar{X})'\right) &= VC(\mathbf{X} - \iota\bar{X}) \\
&= VC\left(\mathbf{X} - \iota\frac{1}{n}\iota'\mathbf{X}\right) \\
&= VC\left(\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\mathbf{X}\right) \\
&= \left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)VC(\mathbf{X})\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)' \\
&= \left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)' \\
&= \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)' \\
&= \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota' - \iota\frac{1}{n}\iota' + \iota\frac{1}{n}\iota'\iota\frac{1}{n}\iota'\right) \\
&= \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota' - \iota\frac{1}{n}\iota' + \iota\frac{1}{n}\iota'\right) \\
&= \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right).
\end{aligned}$$

Also:

$$VC\begin{pmatrix} \bar{X} \\ \mathbf{X} - \iota\bar{X} \end{pmatrix} = \begin{pmatrix} \frac{\sigma^2}{n} & \mathbf{0}' \\ \mathbf{0}' & \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right) \end{pmatrix}.$$

Man sieht: \bar{X} und $\mathbf{X} - \iota\bar{X}$ sind komponentenweise unkorreliert.



Bezeichnung: Für zwei Zufallsvektoren $\mathbf{X} \in \mathbb{R}^n$ und $\mathbf{Y} \in \mathbb{R}^m$ ist die $n \times m$ Matrix $\text{Cov}(\mathbf{X}, \mathbf{Y})$ definiert als $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{Y} - \mathbb{E}(\mathbf{Y}))')$.

Weiters ist die $m \times n$ Matrix $\text{Cov}(\mathbf{Y}, \mathbf{X})$ definiert als $\text{Cov}(\mathbf{Y}, \mathbf{X}) = \mathbb{E}((\mathbf{Y} - \mathbb{E}(\mathbf{Y}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))')$.

Beachte: $\text{Cov}(\mathbf{X}, \mathbf{Y}) = (\text{Cov}(\mathbf{Y}, \mathbf{X}))'$

Bemerkung: Zwei Zufallsvektoren \mathbf{X}, \mathbf{Y} sind unabhängig, wenn für beliebige Funktionen $f(x)$ und $g(y)$ die Beziehung $\mathbb{E}(f(x)g(y)) = \mathbb{E}(f(x))\mathbb{E}(g(y))$ gilt.



Proposition 3.4 Sind \mathbf{X}, \mathbf{Y} unabhängige Zufallsvektoren, dann ist $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbf{0}$.

Beweis. Siehe Übung.

□

Proposition 3.5 Ist \mathbf{X} ein Zufallsvektor mit $\text{VC}(\mathbf{X}) = \Sigma$, dann gilt

$$\begin{aligned}\Sigma' &= \Sigma, & (\text{symmetrisch}) \\ \Sigma &\geq 0. & (\text{positiv semidefinit})\end{aligned}$$

Beweis. Sei \mathbf{X} ein n -dimensionaler Zufallsvektor.

$$\begin{aligned}\Sigma' &= (\text{VC}(\mathbf{X}))' \\ &= (\mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))'))' \\ &= \mathbb{E}((\mathbf{X} - \mathbb{E}(\mathbf{X}))(\mathbf{X} - \mathbb{E}(\mathbf{X}))') \\ &= \text{VC}(\mathbf{X}) \\ &= \Sigma. \checkmark\end{aligned}$$

$\Sigma \geq 0 \dots$ d.h. für jeden Vektor $\alpha \in \mathbb{R}^n$ ist $\alpha' \Sigma \alpha \geq 0$. Sei also $\alpha \in \mathbb{R}^n \setminus \{0\}$. Betrachte die Zufallsvariable $\alpha' \mathbf{X}$:

$$\begin{aligned}0 &\leq \text{Var}(\alpha' \mathbf{X}) = \text{VC}(\alpha' \mathbf{X}) \\ &= \alpha' \text{VC}(\mathbf{X}) \alpha \\ &= \alpha' \Sigma \alpha. \checkmark\end{aligned}$$

□

Bemerkung: Ist $\Sigma = \text{VC}(\mathbf{X}) > 0$, dann ist für jeden Vektor $\alpha \in \mathbb{R}^n$, $\alpha \neq \mathbf{0}$, die Varianz von $\alpha' \mathbf{X}$ positiv (und umgekehrt): Für $\alpha \in \mathbb{R}^n \setminus \{0\}$ ist $\text{Var}(\alpha' \mathbf{X}) = \alpha' \Sigma \alpha$.



Erinnerung: Sei \mathbf{A} eine symmetrische Matrix ($n \times n$).

Seien $\lambda_1, \dots, \lambda_n$ die Eigenwerte, und seien $\mathbf{u}_1, \dots, \mathbf{u}_n$ die entsprechenden Eigenvektoren.

Setze $\mathbf{U} = (\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n)_{(n \times n)}$,

sowie

$$\mathbf{\Omega} = \begin{pmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{pmatrix}_{(n \times n)}.$$


Dann gilt: $\mathbf{A} = \mathbf{U} \mathbf{\Omega} \mathbf{U}'$.



Mit R-Beispiel vom 08.03.2021 (oder auch ganz allgemein) sieht man:
Sind λ_i die Eigenwerte und \mathbf{u}_i die Eigenvektoren von $\mathbf{A}_{(n \times n)}$, dann gilt

$$\begin{aligned} \mathbf{A}\mathbf{u}_i &= \lambda_i \mathbf{u}_i, \quad 1 \leq i \leq n. \\ &\equiv \mathbf{A}(\underbrace{\mathbf{u}_1, \dots, \mathbf{u}_n}_{\mathbf{U}}) = (\lambda_1 \mathbf{u}_1, \dots, \lambda_n \mathbf{u}_n) \\ &\equiv \mathbf{A}\mathbf{U} = \mathbf{U}\mathbf{\Omega} \\ &\Rightarrow \mathbf{A} \underbrace{\mathbf{U}\mathbf{U}'}_{\mathbf{I}_n} = \mathbf{U}\mathbf{\Omega}\mathbf{U}' \end{aligned}$$

Also: $\mathbf{A} = \mathbf{U}\mathbf{\Omega}\mathbf{U}'$.



$$\mathbf{A}^2 = \mathbf{A}\mathbf{A} = \mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{U}\mathbf{\Omega}\mathbf{U}' = \mathbf{U}\mathbf{\Omega}^2\mathbf{U}'.$$

$$\mathbf{A}^{\frac{1}{2}} := \mathbf{U}\mathbf{\Omega}^{\frac{1}{2}}\mathbf{U}'.$$

\uparrow
 $\text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n})$

$$\mathbf{A}^{\frac{1}{2}}\mathbf{A}^{\frac{1}{2}} = \mathbf{U}\mathbf{\Omega}^{\frac{1}{2}}\mathbf{U}'\mathbf{U}\mathbf{\Omega}^{\frac{1}{2}}\mathbf{U}' = \mathbf{U}\mathbf{\Omega}^{\frac{1}{2}}\mathbf{\Omega}^{\frac{1}{2}}\mathbf{U}' = \mathbf{A}.$$

Ist \mathbf{A} invertierbar, dann sind alle $\lambda_i \neq 0$, sodass $\mathbf{\Omega}^{-1} = \text{diag}\left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_n}\right)$ wohldefiniert ist.

Dann ist aber $\mathbf{A}^{-1} = \mathbf{U}\mathbf{\Omega}^{-1}\mathbf{U}'$, denn

$$\begin{aligned} \mathbf{A}\mathbf{U}\mathbf{\Omega}^{-1}\mathbf{U} &= \mathbf{U}\mathbf{\Omega} \underbrace{\mathbf{U}'\mathbf{U}}_{\mathbf{I}_n} \mathbf{\Omega}^{-1}\mathbf{U}' = \mathbf{U}\mathbf{U}' = \mathbf{I}_n. \\ \mathbf{U}\mathbf{\Omega}^{-1}\mathbf{U}'\mathbf{A} &= \dots = \mathbf{I}_n. \end{aligned}$$

Weiters ist dann

$$\mathbf{A}^{-\frac{1}{2}} = \mathbf{U}\mathbf{\Omega}^{-\frac{1}{2}}\mathbf{U}'$$

\uparrow
 $\text{diag}\left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_n}}\right)$

ebenfalls wohldefiniert und erfüllt die Beziehung

$$\mathbf{A}^{-\frac{1}{2}}\mathbf{A}\mathbf{A}^{-\frac{1}{2}} = \mathbf{I}_n \quad (\text{Details: Übung.})$$



Bemerkung: Ist \mathbf{X} ein n -dimensionaler Zufallsvektor mit Mittelwert $\mathbf{0}$ und VC-Matrix $\mathbf{\Sigma} > \mathbf{0}$, dann gilt für den Zufallsvektor $\mathbf{Y} = \mathbf{\Sigma}^{-\frac{1}{2}}\mathbf{X}$ (n -dim.):

$$\begin{aligned} \mathbb{E}(\mathbf{Y}) &= \mathbf{0} \\ \text{VC}(\mathbf{Y}) &= \mathbf{I}_n. \end{aligned}$$

Nachrechnen.

$$\mathbb{E}(\mathbf{Y}) = \mathbb{E}(\Sigma^{-\frac{1}{2}} \mathbf{X}) = \Sigma^{-\frac{1}{2}} \mathbb{E}(\mathbf{X}) = \Sigma^{-\frac{1}{2}} \cdot \mathbf{0} = \mathbf{0} \in \mathbb{R}^n. \checkmark$$

$$\begin{aligned} \text{VC}(\mathbf{Y}) &= \text{VC}(\Sigma^{-\frac{1}{2}} \mathbf{X}) \\ &= \Sigma^{-\frac{1}{2}} \text{VC}(\mathbf{X}) \underbrace{(\Sigma^{-\frac{1}{2}})' }_{\text{symmetrisch}} \\ &= \Sigma^{-\frac{1}{2}} \text{VC}(\mathbf{X}) \Sigma^{-\frac{1}{2}} \\ &= \Sigma^{-\frac{1}{2}} \underbrace{\Sigma}_{\Sigma^{\frac{1}{2}} \Sigma^{\frac{1}{2}}} \Sigma^{-\frac{1}{2}} \\ &= \underbrace{\Sigma^{-\frac{1}{2}} \Sigma^{\frac{1}{2}}}_{\mathbf{I}_n} \underbrace{\Sigma^{\frac{1}{2}} \Sigma^{-\frac{1}{2}}}_{\mathbf{I}_n} \\ &= \mathbf{I}_n. \checkmark \end{aligned}$$

□

Bemerkung: Ist \mathbf{Y} ein Zufallsvektor der Dimension n mit $\mathbb{E}(\mathbf{Y}) = \mathbf{0}$ und $\text{VC}(\mathbf{Y}) = \mathbf{I}_n$. Sei weiters $\Sigma_{(n \times n)}$, sodass $\Sigma' = \Sigma$ und $\Sigma \geq 0$.
Für $\mathbf{X} = \Sigma^{\frac{1}{2}} \mathbf{Y}$ gilt dann:



$$\mathbb{E}(\mathbf{X}) = \mathbf{0}$$

und

$$\text{VC}(\mathbf{X}) = \Sigma.$$

Nachrechnen.

$$\begin{aligned} \mathbb{E}(\mathbf{X}) &= \mathbb{E}(\Sigma^{\frac{1}{2}} \mathbf{Y}) = \Sigma^{\frac{1}{2}} \mathbb{E}(\mathbf{Y}) = \Sigma^{\frac{1}{2}} \mathbf{0} = \mathbf{0} \in \mathbb{R}^n. \checkmark \\ \text{VC}(\mathbf{X}) &= \text{VC}(\Sigma^{\frac{1}{2}} \mathbf{Y}) = \Sigma^{\frac{1}{2}} \text{VC}(\mathbf{Y}) \Sigma^{\frac{1}{2}} = \Sigma^{\frac{1}{2}} \mathbf{I}_n \Sigma^{\frac{1}{2}} = \Sigma^{\frac{1}{2}} \Sigma^{\frac{1}{2}} = \Sigma. \checkmark \end{aligned}$$

□

3.2 Die Multivariate Normalverteilung

Definition 3.3 Sei \mathbf{A} eine $n \times k$ Matrix und \mathbf{b} ein n -dim. Vektor.

Seien weiters Z_1, \dots, Z_k iid. $N(0, 1)$ -verteilte reellwertige Zufallsvariablen.

Setze $\mathbf{Z} = (Z_1, \dots, Z_k)'$ und $\mathbf{X} = \mathbf{A} \cdot \mathbf{Z} + \mathbf{b}$ ein n -dim. Zufallsvektor.

Die Verteilung von \mathbf{X} nennt man die (multivariate) Normalverteilung mit Mittelwert \mathbf{b} und VC Matrix $\mathbf{A}\mathbf{A}'$.

Kurz:

$$\mathbf{X} \sim N(\mathbf{b}, \mathbf{A}\mathbf{A}').$$

Nomination:

univariat	multivariat
σ^2	Σ
μ	μ (Vektor)

Proposition 3.6 Für $\mathbf{X} \sim N(\mu, \Sigma)$ gilt:

$$\mathbb{E}(\mathbf{X}) = \mu,$$

$$\text{VC}(\mathbf{X}) = \Sigma.$$

Beweis. Sei $\mu \in \mathbb{R}^n$ und $\Sigma_{(n \times n)}$.

Wähle $\mathbf{Z} = (Z_1, \dots, Z_n)'$, sodass Z_1, \dots, Z_n i.i.d. $N(0, 1)$.

Weiters sei $\Sigma^{\frac{1}{2}}$ die "Wurzel" von Σ .

Betrachte $\Sigma^{\frac{1}{2}}\mathbf{Z} + \mu$.

Laut Definition ist

$$\Sigma^{\frac{1}{2}}\mathbf{Z} + \mu \sim N\left(\mu, \Sigma^{\frac{1}{2}}\Sigma^{\frac{1}{2}'}\right) \equiv N(\mu, \Sigma).$$

Damit gilt:

$$\begin{aligned} \mathbb{E}(\mathbf{X}) &= \mathbb{E}\left(\Sigma^{\frac{1}{2}}\mathbf{Z} + \mu\right) \\ &= \Sigma^{\frac{1}{2}} \underbrace{\mathbb{E}(\mathbf{Z})}_{\mathbf{0} \in \mathbb{R}^n} + \mu \\ &= \mu. \end{aligned}$$

$$\begin{aligned} \text{VC}(\mathbf{X}) &= \text{VC}\left(\Sigma^{\frac{1}{2}}\mathbf{Z} + \mu\right) \\ &= \Sigma^{\frac{1}{2}} \text{VC}(\mathbf{Z}) \left(\Sigma^{\frac{1}{2}}\right)' \\ &= \Sigma^{\frac{1}{2}} \mathbf{I}_n \Sigma^{\frac{1}{2}} \\ &= \Sigma^{\frac{1}{2}} \Sigma^{\frac{1}{2}} \\ &= \Sigma. \end{aligned}$$

□

Proposition 3.7 (Reproduktionseigenschaft) Ist \mathbf{X} ein n -dim. Zufallsvektor mit $\mathbf{X} \sim N(\mu, \Sigma)$, ist \mathbf{A} eine $m \times n$ Matrix und \mathbf{b} ein m -dim. Vektor, dann ist

$$\mathbf{A}\mathbf{X} + \mathbf{b} \sim N(\mathbf{A}\mu + \mathbf{b}, \mathbf{A}\Sigma\mathbf{A}').$$

Beweis. Sei $\mathbf{Z} = (Z_1, \dots, Z_n)' \in \mathbb{R}^n$ mit Z_1, \dots, Z_n iid. $N(0, 1)$.

Dann gilt:

$$\Sigma^{\frac{1}{2}}\mathbf{Z} + \mu \sim N(\mu, \Sigma).$$

Also:

$$\Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \sim \mathbf{X}.$$

$$\begin{aligned} \Rightarrow \mathbf{AX} + \mathbf{b} &\sim \mathbf{A} \left(\Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \right) + \mathbf{b} \\ &= \mathbf{A} \Sigma^{\frac{1}{2}} \mathbf{Z} + \mathbf{A} \boldsymbol{\mu} + \mathbf{b} \\ &= \left(\mathbf{A} \Sigma^{\frac{1}{2}} \right) \mathbf{Z} + (\mathbf{A} \boldsymbol{\mu} + \mathbf{b}). \end{aligned}$$

Laut Definition ist die Verteilung von $(\mathbf{A} \Sigma^{\frac{1}{2}}) \mathbf{Z} + (\mathbf{A} \boldsymbol{\mu} + \mathbf{b})$ gegeben durch

$$\begin{aligned} N \left(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \left(\mathbf{A} \Sigma^{\frac{1}{2}} \right) \left(\mathbf{A} \Sigma^{\frac{1}{2}} \right)' \right) &= N \left(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{A} \Sigma^{\frac{1}{2}} \left(\Sigma^{\frac{1}{2}} \right)' \mathbf{A}' \right) \\ &= N \left(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{A} \Sigma \mathbf{A}' \right) \\ &\equiv N \left(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{A} \Sigma \mathbf{A}' \right). \end{aligned}$$

Also:

$$\begin{aligned} \mathbf{AX} + \mathbf{b} &\sim \mathbf{A} \Sigma^{\frac{1}{2}} \mathbf{Z} + \mathbf{A} \boldsymbol{\mu} + \mathbf{b} \\ &\sim N \left(\mathbf{A} \boldsymbol{\mu} + \mathbf{b}, \mathbf{A} \Sigma \mathbf{A}' \right). \end{aligned}$$

□

Bemerkung:

Die $N(\boldsymbol{\mu}, \Sigma)$ -Verteilung kann degeneriert sein, nämlich genau dann, wenn Σ nicht vollen Rang hat ($N(\boldsymbol{\mu}, \mathbf{0}) \equiv \boldsymbol{\mu}$ ist ein degenerierter Fall).



Siehe die folgenden Beispiele.

Beispiel 3.5 ($\mathbf{Z} \sim N(\mathbf{0}, \mathbf{1})$, $\mathbf{A} = \mathbf{0}$, $\mathbf{b} \in \mathbb{R}$.) Laut Definition ist

$$\mathbf{X} = \mathbf{A}_{(1 \times 1)} \mathbf{Z}_{(1 \times 1)} + \mathbf{b}_{(1 \times 1)} \sim N(\mathbf{b}, \mathbf{A} \mathbf{A}') = N(\mathbf{b}, \mathbf{0}).$$

$$\mathbf{X} = \mathbf{AZ} + \mathbf{b} = \mathbf{0} \cdot \mathbf{Z} + \mathbf{b} = \mathbf{b}.$$

Also: $N(\mathbf{b}, \mathbf{0}) \equiv \mathbf{b}$.

Beispiel 3.6 Seien X_1, \dots, X_n reellwertige Zufallsvariablen, i.i.d. mit $X_i \sim N(\mu, \sigma^2)$, $\sigma^2 > 0$.

Setze $\mathbf{X} = (X_1, \dots, X_n)'$.

Beachte:

$$\mathbb{E}(\mathbf{X}) = \begin{pmatrix} \mu \\ \vdots \\ \mu \end{pmatrix} = \boldsymbol{\mu}.$$

$$\text{VC}(\mathbf{X}) = \begin{pmatrix} \sigma^2 & & 0 \\ & \ddots & \\ 0 & & \sigma^2 \end{pmatrix} = \sigma^2 \mathbf{I}_n.$$

Sei $\mathbf{Z} = (Z_1, \dots, Z_n)$ mit Z_i iid. $N(0, 1)$.

Betrachte

$$\begin{aligned} \sigma \mathbf{Z} + \mu \iota &= \sigma \mathbf{I}_n \mathbf{Z} + \mu \iota \\ &\sim N(\mu \iota, \sigma \mathbf{I}_n (\sigma \mathbf{I}_n)') \text{ (aus Def.)} \\ &\equiv N(\mu \iota, \sigma^2 \mathbf{I}_n). \end{aligned}$$

Weiters gilt: $(\sigma \mathbf{Z} + \mu \iota)_i = \sigma Z_i + \mu \sim N(\mu, \sigma^2) \sim X_i$, und $(\sigma \mathbf{Z} + \mu \iota)_i$, $1 \leq i \leq n$, sind unabhängig, und X_i , $1 \leq i \leq n$, sind unabhängig.

Damit ist $\mathbf{X} \sim \sigma \mathbf{Z} + \mu \iota \sim N(\mu \iota, \sigma^2 \mathbf{I}_n)$.

Also ist $\mathbf{X} \sim N(\mu \iota, \sigma^2 \mathbf{I}_n)$.

Zerlege \mathbf{X} in $\mathbf{X} = \iota \bar{X} + (\mathbf{X} - \iota \bar{X})$.

Wissen:

$$\begin{aligned} \iota \bar{X} &= \iota \frac{1}{n} \iota' \mathbf{X} \\ &\sim N\left(\iota \frac{1}{n} \iota' \mu \iota, \left(\iota \frac{1}{n} \iota'\right) \sigma^2 \mathbf{I}_n \left(\iota \frac{1}{n} \iota'\right)'\right) \text{ (aufgrund der Reprod. Eigenschaft)} \\ &= N\left(\mu \iota \frac{1}{n} \iota' \iota, \sigma^2 \iota \frac{1}{n} \iota' \iota \frac{1}{n} \iota'\right) \\ &= N\left(\mu \iota, \frac{\sigma^2}{n} \iota \iota'\right), \end{aligned}$$

eine Normalverteilung die auf eine Gerade $[\iota]$ konzentriert ist.

Analog sieht man: $\mathbf{X} - \bar{X} \iota \dots$ eine Normalverteilung in $[\iota]^\perp$.

Wissen:

$$\begin{aligned} \mathbb{E}(\mathbf{X} - \bar{X} \iota \in \mathbb{R}^n) \\ \text{VC}(\mathbf{X} - \bar{X} \iota) = \sigma^2 \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right). \end{aligned}$$

Nun ist $\mathbf{X} - \bar{X} \iota = \mathbf{X} - \iota \frac{1}{n} \iota' \mathbf{X} = \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) \mathbf{X}$, sodass

$$\mathbf{X} - \iota \bar{X} \sim N\left(\mathbf{0}, \sigma^2 \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right)\right) \dots \text{ eine Normalverteilung in } [\iota]^\perp.$$

Proposition 3.8 Betrachte einen $m+n$ -dimensionalen Zufallsvektor $\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}$, wobei $\mathbf{X} \in \mathbb{R}^m$ und $\mathbf{Y} \in \mathbb{R}^n$, sodass

$$\begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \sim N(\boldsymbol{\mu}, \Sigma).$$

Ist $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \mathbf{0}$, dann sind \mathbf{X} und \mathbf{Y} unabhängig.

Erinnerung: Zufallsvektoren \mathbf{X}, \mathbf{Y} sind unabhängig, wenn für jede reellwertige Funktion $f(x)$ und für jede reellwertige Funktion $g(y)$ die Beziehung $\mathbb{E}(f(x)g(y)) = \mathbb{E}(f(x))\mathbb{E}(g(y))$ gilt.



Beweis. Partitioniere $\boldsymbol{\mu} = \mathbb{E} \begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} = \begin{pmatrix} \boldsymbol{\mu}_X \\ \boldsymbol{\mu}_Y \end{pmatrix}$ mit $m+n$ Zeilen und $m+n$ Spalten, sodass $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu}_X$, $\mathbb{E}(\mathbf{Y}) = \boldsymbol{\mu}_Y$, sowie

$$\boldsymbol{\Sigma}_{((m+n) \times (m+n))} = \begin{pmatrix} \boldsymbol{\Sigma}_X & \boldsymbol{\Sigma}_{XY} \\ \boldsymbol{\Sigma}_{YX} & \boldsymbol{\Sigma}_Y \end{pmatrix}$$

, sodass $\text{VC}(\mathbf{X}) = \boldsymbol{\Sigma}_X$, $\text{VC}(\mathbf{Y}) = \boldsymbol{\Sigma}_Y$ und $\text{Cov}(\mathbf{X}, \mathbf{Y}) = \boldsymbol{\Sigma}_{XY}$.

Laut Voraussetzung ist $\boldsymbol{\Sigma}_{XY} = \mathbf{0}$ ($m \times n$) und $\boldsymbol{\Sigma}_{YX} = \mathbf{0}$ ($n \times m$). Seien $Z_1, \dots, Z_{(m+n)}$ i.i.d $N(0, 1)$

und $\mathbf{Z} = \begin{pmatrix} Z_1 \\ \vdots \\ Z_{(m+n)} \end{pmatrix}$.

Partitioniere $\mathbf{Z} = \begin{pmatrix} \mathbf{Z}_X \\ \mathbf{Z}_Y \end{pmatrix}$ mit $m+n$ Zeilen.

$$\boldsymbol{\Sigma}^{\frac{1}{2}} = \begin{pmatrix} \boldsymbol{\Sigma}_X & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y \end{pmatrix}^{\frac{1}{2}} \stackrel{*}{=} \begin{pmatrix} \boldsymbol{\Sigma}_X^{\frac{1}{2}} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \end{pmatrix}$$

Nachrechnen von $*$:

$$\begin{pmatrix} \boldsymbol{\Sigma}_X^{\frac{1}{2}} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \end{pmatrix} \begin{pmatrix} \boldsymbol{\Sigma}_X^{\frac{1}{2}} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \end{pmatrix} = \begin{pmatrix} \boldsymbol{\Sigma}_X & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y \end{pmatrix}. \checkmark$$

Betrachte den Zufallsvektor

$$\begin{aligned} \boldsymbol{\Sigma}^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} &\sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma}^{\frac{1}{2}} \boldsymbol{\Sigma}^{\frac{1}{2}}) \\ &= N(\boldsymbol{\mu}, \boldsymbol{\Sigma}) \\ &\sim \begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}. \end{aligned}$$

Beachte:

$$\begin{aligned} \boldsymbol{\Sigma}^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} &= \begin{pmatrix} \boldsymbol{\Sigma}_X^{\frac{1}{2}} & \mathbf{0} \\ \mathbf{0} & \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \end{pmatrix} \begin{pmatrix} \mathbf{Z}_X \\ \mathbf{Z}_Y \end{pmatrix} + \begin{pmatrix} \boldsymbol{\mu}_X \\ \boldsymbol{\mu}_Y \end{pmatrix} \\ &= \begin{pmatrix} \boldsymbol{\Sigma}_X^{\frac{1}{2}} \mathbf{Z}_X + \boldsymbol{\mu}_X \\ \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \mathbf{Z}_Y + \boldsymbol{\mu}_Y \end{pmatrix} \sim \begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix}. \end{aligned}$$

Nun sind $\mathbf{Z}_X, \mathbf{Z}_Y$ unabhängig.

$\Rightarrow \boldsymbol{\Sigma}_X^{\frac{1}{2}} \mathbf{Z}_X + \boldsymbol{\mu}_X, \boldsymbol{\Sigma}_Y^{\frac{1}{2}} \mathbf{Z}_Y + \boldsymbol{\mu}_Y$ unabhängig.

$\Rightarrow \mathbf{X}, \mathbf{Y}$ unabhängig.

Zu zeigen: \mathbf{X}, \mathbf{Y} unabhängig.

Sei: $f(x)$ eine reellwertige Funktion von X und $g(y)$ eine reellwertige Funktion von Y . Zu zeigen: $\mathbb{E}(f(x)g(y)) = \mathbb{E}(f(x))\mathbb{E}(g(y))$.

$$\begin{aligned}\mathbb{E}(f(x)g(y)) &= \mathbb{E}\left(f\left(\Sigma_X^{\frac{1}{2}}\mathbf{Z}_X + \boldsymbol{\mu}_X\right)g\left(\Sigma_Y^{\frac{1}{2}}\mathbf{Z}_Y + \boldsymbol{\mu}_Y\right)\right) \\ &= \mathbb{E}\left(f\left(\Sigma_X^{\frac{1}{2}}\mathbf{Z}_X + \boldsymbol{\mu}_X\right)\right)\mathbb{E}\left(g\left(\Sigma_Y^{\frac{1}{2}}\mathbf{Z}_Y + \boldsymbol{\mu}_Y\right)\right) \\ &= \mathbb{E}(f(x))\mathbb{E}(g(y)).\end{aligned}$$

□

Beispiel 3.7 X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, $\mu \in \mathbb{R}$, $0 < \sigma^2 < \infty$. Setze $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$.

Wissen:

$$\begin{aligned}\begin{pmatrix} \bar{X} \\ \mathbf{X} - \iota \bar{X} \end{pmatrix} \dots \text{ eine lineare Funktion von } \mathbf{X} \\ = \begin{pmatrix} \frac{1}{n} \boldsymbol{\iota}' \\ \mathbf{I}_n - \iota \frac{1}{n} \boldsymbol{\iota}' \end{pmatrix} \mathbf{X} \sim \text{ Normalverteilung.}\end{aligned}$$

Siehe Beispiel ?? und 3.4.

$\Rightarrow \bar{X}, \mathbf{X} - \iota \bar{X}$ sind unabhängig!

$\Rightarrow \bar{X}, \hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \|\mathbf{X} - \iota \bar{X}\|^2$ sind unabhängig!



Erinnerung: Für Z_1, \dots, Z_n i.i.d. $N(0, 1)$, ist

$$\sum_{i=1}^n Z_i^2 \sim \chi_k^2.$$

Lemma 3.1 Ist $\mathbf{P}_{(n \times n)}$ die Matrix einer Orthogonalprojektion, dann gilt: $\mathbf{P}^2 = \mathbf{P}$ und $\mathbf{P} = \mathbf{P}'$.

Beweis. Für $\mathbf{X}, \mathbf{Y} \in \mathbb{R}^n$ ist

$$\mathbf{X} = \mathbf{P}\mathbf{X} + (\mathbf{I}_n - \mathbf{P})\mathbf{X} \quad (\text{orthogonale Zerlegung}).$$

$$\mathbf{Y} = \mathbf{P}\mathbf{Y} + (\mathbf{I}_n - \mathbf{P})\mathbf{Y} \quad (\text{orthogonale Zerlegung}).$$

$$\begin{aligned}\mathbf{X}'\mathbf{P}\mathbf{Y} &= (\mathbf{X})'\mathbf{P}\mathbf{Y} \\ &= (\mathbf{P}\mathbf{X} + (\mathbf{I}_n - \mathbf{P})\mathbf{X})'\mathbf{P}\mathbf{Y} \\ &= (\mathbf{X}'\mathbf{P}' + \mathbf{X}'(\mathbf{I}_n - \mathbf{P})')\mathbf{P}\mathbf{Y} \\ &= \mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y} + \underbrace{\mathbf{X}'(\mathbf{I}_n - \mathbf{P})'\mathbf{P}\mathbf{Y}}_{= (\mathbf{I}_n - \mathbf{P})\mathbf{X}'\mathbf{P}\mathbf{Y} = 0} \\ &= \mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y}.\end{aligned}$$

$$\begin{aligned}
\mathbf{X}'\mathbf{P}'\mathbf{Y} &= (\mathbf{P}\mathbf{X})'\mathbf{Y} \\
&= (\mathbf{P}\mathbf{X})'(\mathbf{P}\mathbf{Y} + (\mathbf{I}_n - \mathbf{P})\mathbf{Y}) \\
&= (\mathbf{X}'\mathbf{P}'(\mathbf{P}\mathbf{Y} + (\mathbf{I}_n - \mathbf{P})\mathbf{Y})) \\
&= \mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y} + \underbrace{\mathbf{X}'\mathbf{P}'(\mathbf{I}_n - \mathbf{P})\mathbf{Y}}_{\substack{= (\mathbf{P}\mathbf{X})'(\mathbf{I}_n - \mathbf{P})\mathbf{Y} \\ = 0}} \\
&= \mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y}.
\end{aligned}$$


$$\Rightarrow \mathbf{X}'\mathbf{P}\mathbf{Y} = \mathbf{X}'\mathbf{P}'\mathbf{Y}.$$

Da dies für beliebige $\mathbf{X}, \mathbf{Y} \in \mathbb{R}^n$ gilt, folgt $\mathbf{P} = \mathbf{P}'$.

Weiters ist $\mathbf{X}'\mathbf{P}\mathbf{Y} = \mathbf{X}'\mathbf{P}'\mathbf{P}\mathbf{Y}$

$$\begin{aligned}
\Rightarrow \mathbf{P} &= \mathbf{P}'\mathbf{P} = \mathbf{P}\mathbf{P} = \mathbf{P}^2. \\
&\quad \uparrow \\
&\quad \mathbf{P}' = \mathbf{P}
\end{aligned}$$

□

Es gilt auch die Umkehrung: Ist $\mathbf{P}_{(n \times n)}$ mit $\mathbf{P}^2 = \mathbf{P}$ und $\mathbf{P} = \mathbf{P}'$, dann ist \mathbf{P} die Matrix einer Orthogonalprojektion (ohne Beweis). 

Korollar 3.1 Ist $\mathbf{P}_{(n \times n)}$ die Matrix einer Orthogonalprojektion auf einen k -dimensionalen Teilraum ($0 \leq k \leq n$), dann sind genau k Eigenwerte von \mathbf{P} gleich 1 und der Rest ist 0.

Beweis. Spektralzerlegung $\mathbf{P} = \mathbf{U}\mathbf{\Omega}\mathbf{U}'$ (\mathbf{U} orthogonal: $\mathbf{U}'\mathbf{U} = \mathbf{U}\mathbf{U}' = \mathbf{I}_n$, $\mathbf{\Omega} = \text{diag}(\lambda_1, \dots, \lambda_n)$). $\mathbf{P}^2 = \mathbf{P}$, d.h.

$$\begin{aligned}
&\mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{U}\mathbf{\Omega}\mathbf{U}' = \mathbf{U}\mathbf{\Omega}\mathbf{U}' \\
\Leftrightarrow &\mathbf{U}\mathbf{\Omega}^2\mathbf{U}' = \mathbf{U}\mathbf{\Omega}\mathbf{U}' \\
\Leftrightarrow &\mathbf{U}\mathbf{\Omega}^2 = \mathbf{U}\mathbf{\Omega} \\
\Leftrightarrow &\mathbf{\Omega}^2 = \mathbf{\Omega}.
\end{aligned}$$

D.h. für $i = 1, \dots, n$ ist $\lambda_i^2 = \lambda_i$, also $\lambda_i = 0$ oder $\lambda_i = 1$.

Weiters ist

$$\begin{aligned}
\text{rang}(\mathbf{P}) &= k \\
&= \text{rang}(\mathbf{U}\mathbf{\Omega}\mathbf{U}') \\
&= \text{rang}(\mathbf{\Omega}) \\
&= \#\{i : 1 \leq i \leq n, \lambda_i = 1\}.
\end{aligned}$$

Also sind genau k Eigenwerte gleich 1 und $n - k$ Eigenwerte sind 0. □

Proposition 3.9 Ist $\mathbf{P}_{(n \times n)}$ die Matrix einer Orthogonalprojektion auf einen k -dimensionalen Teilraum ($1 \leq k \leq n$), und ist $\mathbf{Z} \sim N(0, 1)$. Dann gilt

$$\mathbf{Z}'\mathbf{P}\mathbf{Z} \sim \chi_k^2$$

Beweis. $\mathbf{Z}'\mathbf{P}\mathbf{Z} = \mathbf{Z}'\mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{Z}$.

Nun ist $\mathbf{U}'\mathbf{Z} \sim N(\underbrace{\mathbf{U}'\mathbf{0}}_{=0}, \underbrace{\mathbf{U}'\mathbf{I}_n\mathbf{U}}_{=\mathbf{U}'\mathbf{U}=\mathbf{I}_n}) \equiv N(0, \mathbf{I}_n)$.

Insbesondere ist $\mathbf{Z} \sim \mathbf{U}'\mathbf{Z}$. Für $\mathbf{\Omega} = \text{diag}(\underbrace{1, \dots, 1}_k, \underbrace{0, \dots, 0}_{n-k})$ ist damit

$$\begin{aligned}\mathbf{Z}'\mathbf{P}\mathbf{Z} &= \mathbf{Z}'\mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{Z} \\ &= (\mathbf{U}'\mathbf{Z})'\mathbf{\Omega}(\mathbf{U}'\mathbf{Z}) \\ &\sim \mathbf{Z}'\mathbf{\Omega}\mathbf{Z} \\ &= \sum_{i=1}^k Z_i^2 \\ &\sim \chi_k^2.\end{aligned}$$

□

Beispiel 3.8 Seien X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$, sodass $\mathbf{X} = \begin{pmatrix} X_1 \\ \vdots \\ X_n \end{pmatrix} \sim N(\mu^2 \cdot \sigma^2 \mathbf{I}_n)$.

$\mathbf{X} - \iota\bar{X} = \underbrace{\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)}_{:=\mathbf{P}}\mathbf{X} \dots$ Orthogonalprojektion von \mathbf{X} auf $[\iota]^\perp$, ein $(n-1)$ -dimensionaler

Teilraum.

Prüfe Eigenschaften:

$$\begin{aligned}\mathbf{P}^2 &= \left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right) \\ &= \mathbf{I}_n - \iota\frac{1}{n}\iota' - \iota\frac{1}{n}\iota' + \iota\frac{1}{n}\iota'\iota\frac{1}{n}\iota' \\ &= \mathbf{I}_n - \iota\frac{1}{n}\iota' - \iota\frac{1}{n}\iota' + \iota\frac{1}{n}\iota' \\ &= \mathbf{I}_n - \iota\frac{1}{n}\iota' \\ &= \mathbf{P}. \checkmark\end{aligned}$$

$$\mathbf{P}' = \left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)' = \mathbf{I}_n - \iota\frac{1}{n}\iota' = \mathbf{P}. \checkmark$$

Beachte: $\dim([\iota]^\perp) = n-1$.

? Verteilung von $\|\mathbf{X} - \iota\bar{X}\|^2$?

(Beachte: $\hat{\sigma}_n^2 = \frac{1}{n-1}\|\mathbf{X} - \iota\bar{X}\|^2$).

Wissen: $\mathbf{X} - \iota\bar{X} \sim N\left(0, \sigma^2\left(\mathbf{I}_n - \iota\frac{1}{n}\iota'\right)\right)$.

Für $\mathbf{Z} \sim N(0, \mathbf{I}_n)$ ist


$$\begin{aligned}
 \underbrace{\sigma \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right)}_P \mathbf{Z} &\sim N(0, \underbrace{\sigma \mathbf{P} \mathbf{I}_n \mathbf{P}' \sigma}_{\substack{= \sigma^2 \mathbf{P} \mathbf{P}' \\ = \sigma^2 \mathbf{P} \mathbf{P} \\ = \sigma^2 \mathbf{P}}}) \\
 &= N(0, \sigma^2 \mathbf{P}) \\
 &\sim \mathbf{X} - \iota \bar{X}. \\
 \|\mathbf{X} - \iota \bar{X}\|^2 &\sim \underbrace{\|\sigma \left(\mathbf{I}_n - \iota \frac{1}{n} \iota' \right) \mathbf{Z}\|^2}_P \\
 &= (\sigma \mathbf{P} \mathbf{Z})' (\sigma \mathbf{P} \mathbf{Z}) \\
 &= \sigma^2 \mathbf{Z}' \mathbf{P}' \mathbf{P} \mathbf{Z} \\
 &= \sigma^2 \mathbf{Z}' \mathbf{P} \mathbf{Z} \\
 &\sim \sigma^2 \chi_{n-1}^2. \\
 &\quad \uparrow \\
 &\text{Proposition}
 \end{aligned}$$

Proposition 3.10 Für X_1, \dots, X_n i.i.d. $N(\mu, \sigma^2)$ ist

$$\hat{\sigma}_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \sim \frac{\sigma^2}{n-1} \chi_{n-1}^2$$

und

$$\frac{\sqrt{n}}{\hat{\sigma}_n} (\bar{X} - \mu) \sim t_{n-1}.$$

Beweis. Erinnerung: Für Zufallsvariablen A, B , die unabhängig voneinander sind und so, dass $A \sim N(0, 1)$ und $B \sim \chi_k^2$ ist. 

$$\frac{A}{\sqrt{\frac{B}{n}}} \sim t_k$$

$$\frac{\sqrt{n}}{\hat{\sigma}_n} (\bar{X} - \mu) = \frac{\frac{\sqrt{n}}{\sigma} (\bar{X} - \mu)}{\frac{\hat{\sigma}_n}{\sigma}}$$

$$\frac{\sqrt{n}}{\sigma} (\bar{X} - \mu) \sim N(0, 1).$$

$$\begin{aligned}
\frac{\hat{\sigma}_n}{\sigma} &= \sqrt{\frac{\hat{\sigma}_n^2}{\sigma^2}} \\
&= \sqrt{\frac{1}{\sigma^2} \frac{1}{n-1} \underbrace{\sum_{i=1}^n (X_i - \bar{X})^2}_{\sim \sigma^2 \chi_{n-1}^2}} \\
&\sim \sqrt{\frac{1}{\sigma^2} \frac{1}{n-1} \sigma^2 \chi_{n-1}^2} \\
&\sim \sqrt{\frac{\chi_{n-1}^2}{n-1}}.
\end{aligned}$$

Zähler ist eine Funktion von \bar{X} und Nenner ist eine Funktion von $\mathbf{X} - \iota \bar{X}$
 \Rightarrow Zähler und Nenner sind unabhängig. Also ist

$$\frac{\frac{\sqrt{n}(\bar{X} - \mu)}{\frac{\hat{\sigma}_n}{\sigma}}}{\frac{\hat{\sigma}_n}{\sigma}} \sim t_{n-1}.$$

□

3.3 Der Multivariate Zentrale Grenzwertsatz

Satz 3.1 Sind \mathbf{X}_i , $i \geq 1$, k -dimensionale Zufallsvektoren, die i.i.d. sind mit $\mathbb{E}(\mathbf{X}_i) = \boldsymbol{\mu}_{(n \times 1)}$, $\text{VC}(\mathbf{X}_i) = \Sigma_{(n \times n)}$. Damit gilt für $\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$, dass

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu}) \xrightarrow{w} N(0, \Sigma)$$

3.4 Normalverteilungen - stetig und singular (degeneriert)

Betrachte $\mathbf{X} \sim N(\boldsymbol{\mu}, \Sigma)$, $\boldsymbol{\mu} \in \mathbb{R}^n$, $\Sigma_{(n \times n)}$. Es gilt $\text{rang}(\Sigma) \in \{0, 1, 2, \dots, n\}$.

Proposition 3.11 Ist $\text{rang}(\Sigma) = n$, dann besitzt \mathbf{X} eine Dichte, die gegeben ist durch

$$\Phi_{\boldsymbol{\mu}, \Sigma}(\mathbf{x}) = (2\pi)^{-\frac{n}{2}} (\det \Sigma)^{-\frac{1}{2}} e^{-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})}$$

für $\mathbf{x} = (x_1, \dots, x_n)' \in \mathbb{R}^n$.

Beweis. Betrachte Spektralzerlegung (Eigenwertzerlegung) von $\Sigma = \mathbf{U} \boldsymbol{\Omega} \mathbf{U}'$, wobei $\boldsymbol{\Omega} = \text{diag}(\lambda_1, \dots, \lambda_n)$, wobei alle $\lambda_i > 0$ sind.

$$\Sigma^{\frac{1}{2}} = \mathbf{U} \boldsymbol{\Omega}^{\frac{1}{2}} \mathbf{U}' \text{ mit } \boldsymbol{\Omega}^{\frac{1}{2}} = \text{diag}(\sqrt{\lambda_1}, \dots, \sqrt{\lambda_n}),$$

$$\Sigma^{-\frac{1}{2}} = \mathbf{U} \boldsymbol{\Omega}^{-\frac{1}{2}} \mathbf{U}' \text{ mit } \boldsymbol{\Omega}^{-\frac{1}{2}} = \text{diag}\left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_n}}\right),$$

$$\Sigma^{-1} = \mathbf{U} \boldsymbol{\Omega}^{-1} \mathbf{U}' \text{ mit } \boldsymbol{\Omega}^{-1} = \text{diag}\left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_n}\right).$$

Seien Z_1, \dots, Z_n i.i.d. $N(0, 1)$ und $\mathbf{Z} = (Z_1, \dots, Z_n)'$.

Dann ist

$$\Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \sim N(\boldsymbol{\mu}, \Sigma)$$

$$\sim \mathbf{X}.$$

Für $\mathbf{B} \in \mathbb{R}^n$ ist

$$\begin{aligned} \mathbb{P}(x \in \mathbf{B}) &= \mathbb{P}(\Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \in \mathbf{B}) \\ &= \int_{\substack{\mathbf{Z}=(Z_1, \dots, Z_n)': \\ \Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \in \mathbf{B}}} \dots \int \underbrace{\Phi(Z_1) \cdot \dots \cdot \Phi(Z_n)}_{\substack{= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{Z_1^2}{2}\right) \dots \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{Z_n^2}{2}\right) \\ = (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{Z_1^2}{2} - \frac{Z_2^2}{2} - \dots - \frac{Z_n^2}{2}\right) \\ = (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{1}{2} \sum_{i=1}^n Z_i^2\right) \\ = (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{1}{2} \mathbf{Z}' \mathbf{Z}\right)}} \cdot dz_1 \dots dz_n \\ &= \int_{\substack{\mathbf{Z}=(Z_1, \dots, Z_n)': \\ \Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu} \in \mathbf{B}}} \dots \int (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{1}{2} \mathbf{Z}' \mathbf{Z}\right) \cdot dz_1 \dots dz_n = \circledast. \end{aligned}$$

$$\mathbf{X} := \Sigma^{\frac{1}{2}} \mathbf{Z} + \boldsymbol{\mu}.$$

$$\mathbf{Z} = \Sigma^{-\frac{1}{2}} (\mathbf{X} - \boldsymbol{\mu}).$$

$$dz_1, \dots, dz_n = |\det \Sigma|^{-\frac{1}{2}}.$$

$$\begin{aligned} \circledast &= \int_{\substack{\mathbf{X}=(X_1, \dots, X_n)': \\ x \in \mathbf{B}}} \dots \int (2\pi)^{-\frac{n}{2}} \exp\left(-\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu})' \Sigma^{-\frac{1}{2}} \Sigma^{-\frac{1}{2}} (\mathbf{X} - \boldsymbol{\mu})\right) |\det \Sigma|^{-\frac{1}{2}} \cdot dx_1 \dots dx_n \\ &= \int_{\substack{\mathbf{X}=(X_1, \dots, X_n)': \\ x \in \mathbf{B}}} \dots \int \underbrace{(2\pi)^{-\frac{n}{2}} |\det \Sigma|^{-\frac{1}{2}} \exp\left(-\frac{1}{2} (\mathbf{X} - \boldsymbol{\mu})' \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu})\right)}_{\substack{\dots \text{ dies ist also die Dichte von } \mathbf{X} \\ = \Phi_{\boldsymbol{\mu}, \Sigma}(x)}} \cdot dx_1 \dots dx_n \end{aligned}$$

□

Proposition 3.12 Ist $k = \text{rang}(\Sigma)$ so, dass $0 < k < n$, dann lässt sich \mathbf{X} schreiben als

$$\mathbf{X} = \mathbf{B} \mathbf{W} + \boldsymbol{\mu},$$

wobei \mathbf{B} eine $m \times k$ Matrix mit orthogonalen ($\mathbf{B}' \mathbf{B} = \mathbf{I}_k$) Spalten ist und wobei \mathbf{W} ein k -dimensionaler Zufallsvektor ist mit

$$\mathbf{W} \sim N(0, \mathbf{D}),$$

mit $\mathbf{D} = \text{diag}(d_1, \dots, d_k) > 0$.

Beweis. Wieder $\Sigma = \mathbf{U} \boldsymbol{\Omega} \mathbf{U}'$. Laut Voraussetzung ($k = \text{rang}(\Sigma) < n$) kann man $\boldsymbol{\Omega}$ schreiben als $\boldsymbol{\Omega} = \text{diag}(\underbrace{\lambda_1, \dots, \lambda_k}_{k \text{ Komponente}}, \underbrace{0, \dots, 0}_{n \text{ Komponente}})$.

Mit anderen Worten:

$$\mathbf{\Omega} = \begin{pmatrix} \lambda_1 & & & & & 0 \\ & \ddots & & & & \\ & & \lambda_k & & & \\ & & & 0 & & \\ 0 & & & & \ddots & \\ & & & & & 0 \end{pmatrix} = \begin{pmatrix} \mathbf{\Omega}_1 & \mathbf{0}_{k,n-k} \\ \mathbf{0}_{n-k,k} & \mathbf{0}_{n-k,n-k} \end{pmatrix},$$

wobei $\mathbf{\Omega}_1 = \text{diag}(\lambda_1, \dots, \lambda_k)$.

Partitioniere $\mathbf{U} = (\mathbf{U}_1, \mathbf{U}_2)$.

$$\begin{aligned} \mathbf{X} - \boldsymbol{\mu} &= \mathbf{U}\mathbf{U}'(\mathbf{X} - \boldsymbol{\mu}) \\ &= (\mathbf{U}_1\mathbf{U}_1' + \mathbf{U}_2\mathbf{U}_2')(\mathbf{X} - \boldsymbol{\mu}) \\ &= \mathbf{U}_1\mathbf{U}_1'(\mathbf{X} - \boldsymbol{\mu}) + \mathbf{U}_2\mathbf{U}_2'(\mathbf{X} - \boldsymbol{\mu}). \end{aligned}$$

$$\underbrace{\mathbf{U}_1'(\mathbf{X} - \boldsymbol{\mu})}_{\sim N(0, \Sigma)} \sim N(0, \mathbf{U}_1'\Sigma\mathbf{U}_1).$$

$$\begin{aligned} \mathbf{U}_1'\Sigma\mathbf{U}_1 &= \mathbf{U}_1'\mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{U}_1 \\ &= \mathbf{U}_1'(\mathbf{U}_1 \quad \mathbf{U}_2)\mathbf{\Omega}\begin{pmatrix} \mathbf{U}_1' \\ \mathbf{U}_2' \end{pmatrix}\mathbf{U}_1 \\ &= (\mathbf{U}_1'\mathbf{U}_1 \quad \mathbf{U}_1'\mathbf{U}_2)\mathbf{\Omega}\begin{pmatrix} \mathbf{U}_1'\mathbf{U}_1 \\ \mathbf{U}_2'\mathbf{U}_1 \end{pmatrix} \\ &= \begin{pmatrix} \mathbf{I}_k & \mathbf{0}_{k,n-k} \end{pmatrix} \begin{pmatrix} \mathbf{\Omega}_1 & \mathbf{0}_{k,n-k} \\ \mathbf{0}_{n-k,k} & \mathbf{0}_{n-k,n-k} \end{pmatrix} \begin{pmatrix} \mathbf{I}_k \\ \mathbf{0}_{k,n-k} \end{pmatrix} \\ &= \begin{pmatrix} \mathbf{I}_k & \mathbf{0}_{k,n-k} \end{pmatrix} \begin{pmatrix} \mathbf{\Omega}_1 \\ \mathbf{0} \end{pmatrix} \\ &= \mathbf{\Omega}_1. \end{aligned}$$

Also: $\mathbf{U}_1'(\mathbf{X} - \boldsymbol{\mu}) \sim N(0, \mathbf{\Omega}_1)$. Beachte $\mathbf{\Omega}_1 > 0$.


$$\begin{aligned} \mathbf{U}_2'\Sigma\mathbf{U}_2 &= \mathbf{U}_2'\mathbf{U}\mathbf{\Omega}\mathbf{U}'\mathbf{U}_2 \\ &= \mathbf{U}_2'(\mathbf{U}_1 \quad \mathbf{U}_2)\mathbf{\Omega}\begin{pmatrix} \mathbf{U}_1' \\ \mathbf{U}_2' \end{pmatrix}\mathbf{U}_2 \\ &= (\mathbf{U}_2'\mathbf{U}_1 \quad \mathbf{U}_2'\mathbf{U}_2)\mathbf{\Omega}\begin{pmatrix} \mathbf{U}_1'\mathbf{U}_2 \\ \mathbf{U}_2'\mathbf{U}_2 \end{pmatrix} \\ &= \begin{pmatrix} 0 & \mathbf{I}_{n-k} \end{pmatrix} \begin{pmatrix} \mathbf{\Omega}_1 & \mathbf{0}_{k,n-k} \\ \mathbf{0}_{n-k,k} & \mathbf{0}_{n-k,n-k} \end{pmatrix} \begin{pmatrix} 0 \\ \mathbf{I}_{n-k} \end{pmatrix} \\ &= \begin{pmatrix} 0 & \mathbf{I}_{n-k} \end{pmatrix} \begin{pmatrix} 0 \\ 0 \end{pmatrix} \\ &= 0. \end{aligned}$$

Also:

$$\begin{aligned} \mathbf{U}_2'(\mathbf{X} - \boldsymbol{\mu}) &\sim N(0, 0) \\ &\sim \mathbf{0} \in \mathbb{R}^{n-k}. \end{aligned}$$

$$\begin{aligned}
\mathbf{X} - \boldsymbol{\mu} &= \mathbf{U}_1 (\mathbf{U}_1' (\mathbf{X} - \boldsymbol{\mu})) + \mathbf{U}_2 (\mathbf{U}_2' (\mathbf{X} - \boldsymbol{\mu})) \\
&\Leftrightarrow \mathbf{X} = \underbrace{\mathbf{U}_1 (\mathbf{U}_1' (\mathbf{X} - \boldsymbol{\mu}))}_{\sim N(0, \boldsymbol{\Omega}_1)} + \underbrace{\mathbf{U}_2 (\mathbf{U}_2' (\mathbf{X} - \boldsymbol{\mu}))}_0 + \boldsymbol{\mu}.
\end{aligned}$$

Setze $\mathbf{B} := \mathbf{U}_1$, $\mathbf{W} = \mathbf{U}_1' (\mathbf{X} - \boldsymbol{\mu})$, und bin fertig. □

Bemerkung: Ist $\text{rang}(\boldsymbol{\Sigma}) = 0$, dann ist $\mathbf{X} \sim 0\mathbf{Z} + \boldsymbol{\mu}$ für Z_1, \dots, Z_n i.i.d. $N(0, 1)$, denn hier ist $\boldsymbol{\Sigma} = \mathbf{0}_{(n \times n)}$.
Also $\mathbf{X} \sim 0\mathbf{Z} + \boldsymbol{\mu} \equiv \boldsymbol{\mu}$. 

Bemerkung: Mit den beiden letzten Propositionen ist auch sichergestellt, dass die $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ -Verteilung, wie in Abschnitt I.2 angegeben, auch wohldefiniert ist. 